Thema 1: Datenursprünge

Gabriel M Ahlfeldt

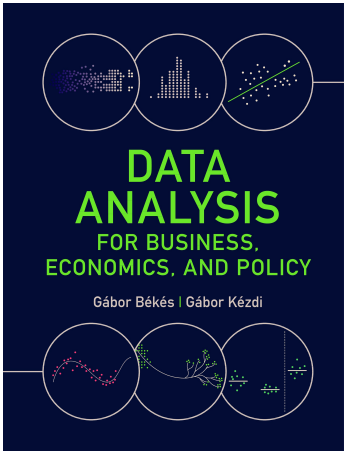
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 01**

Motivation

- Wir planen eine Reise nach Wien und suchen ein Hotel. Wir sind an einem Hotel interessiert, dass ein gutes Preis-Leistungsverhältnis bietet. Nicht unbedingt extrem günstig, aber bitte preiswert.
- Wie gehen wir vor?

Gehe zu `https://pingo.coactum.de`, *access number* 376132



Was sind Daten (*data*)

- Daten lassen sich am einfachsten als **Datentabelle** (*data table*) analysieren.
- Eine Datentabelle besteht aus
  - **Variablen** (*variables*): Beschreiben Merkmale (z.B. größe des Zimmers, Preis in €)
  - **Beobachtungen** (*observations*): Die Ausprägungen (z.B. 30, 100) der Merkmale für eine Untersuchungseinheit (hier Hotels).
  - In einer Datentabelle sind **Zeilen Beobachtungen und Spalten Variablen**
- Speicherung: *comma separated values* (Komma-getrennte Werte) .csv (.txt) weit verbreitet. Trennzeichen können beliebig sein: Komma(,), Semikolon (;) etc.
  - Umstellen des Dezimaltrennzeichens auf "." im System empfohlen
- Ein **Datensatz** (*data set*) ist oft eine Sammlung von Datentabellen
  - z.B. 10 Datentabellen zum selben Thema für 10 verschiedene Jahre
  - Können über eine **ID-Variable** in eine Datentabelle überführt werden (*merge*)

Datenstrukturen

- *Cross-sectional data*: Querschnittsdaten (xsec-Daten) enthalten Informationen zu vielen *units* (Einheiten), die zur gleichen Zeit beobachtet werden.
  - z.B. BIP mehrerer Länder in einem Jahr
- *Time-series data*: Zeitreihendaten (tseries-Daten) enthalten Informationen zu einer einzelnen *unit*, die viele Male beobachtet wird.
  - z.B. BIP eines Landes im Zeitverlauf
- *Multi-dimentional panel data*: Mehrdimensionale Daten (Panel-Daten) haben mehrere Dimensionen.
  - Viele *cross-sectional units*, die viele Male beobachtet werden.
  - z.B. BIP mehrer Länder im Zeitverlauf

Datenstrukturen

Einige zusätzliche Informationen zu *multi-dimensional panel data*

- Eine häufige Art von Panel-Daten enthält viele *units*, die jeweils mehrmals beobachtet werden. Solche Daten werden manchmal als *longitudinal data* oder *cross-section-time-series data* bezeichnet, manchmal abgekürzt als *xt Daten*.
- In xt Datentabellen werden Beobachtungen durch **zwei ID-Variablen** identifiziert: eine für die *cross-sectional units* (Querschnittseinheiten), z.B. Länder, und eine für die Zeit, z.B. Jahre.
  - ***Long format*** vs ***wide format*** (eine ID und mehrere Jahre in mehreren Variablen)
- Xt Daten gelten als ***balanced***, wenn alle *units* zu genau denselben Zeitpunkten beobachtet werden. Sie werden als *unbalanced* bezeichnet, wenn einige *units* öfter beobachtet werden als andere.

Finding a good deal among hotels: Datensammlung

- Willkommen in Wien, Österreich
- `hotels` Datensatz
- Von einer Preisvergleichswebsite. Anonymisiert.
- Wien, November 2017, Wochentag, $N = 428$
- Für jedes Hotel enthält die Daten Informationen über den Standort des Hotels, den Preis in EUR für die Nacht, durchschnittliche Kundenbewertung, wie viele Sterne, Entfernung zum Stadtzentrum.
- **Wie werden den Dantensatz verwenden, um preiswerte Hotels zu identifizieren**



Image: en.wikipedia.org/wiki/File:Montage_of_Vienna.jpg

Datenstrukturen

List of Observations (Auflistung von Beobachtungen)

hotel_id	accom_type	country	city	city_actual	dist	stars	rating	price
21894	Apartment	Austria	Vienna	Vienna	2.7	4	4.4	81
21897	Hotel	Austria	Vienna	Vienna	1.7	4	3.9	81
21901	Hotel	Austria	Vienna	Vienna	1.4	4	3.7	85
21902	Hotel	Austria	Vienna	Vienna	1.7	3	4	83
21903	Hotel	Austria	Vienna	Vienna	1.2	4	3.9	82

Quelle: Datensatz `hotels`. Wien, für einen Wochentag im November 2017

- 'accom_type' ist der Typ der Unterkunft
- 'city' ist die Stadt nach der gesucht wurde, 'city_actual' ist die gefundene

Q: Wie viele *observations* und wie viele *variables*?

Datenqualität

- **Datenqualität ist entscheidend**.
  - Wenn unsere Daten ungeeignet sind, um unsere Frage zu beantworten, werden die Ergebnisse unserer Analyse zwangsläufig nicht verlässlich sein...
  - ... ganz gleich, wie ausgefeilt die Methoden sind, die wir darauf anwenden.

- **Datenqualität ist ein relativer Begriff**!
  - Zuerst müssen Sie festlegen, was Ihre (Forschungs-)Frage ist!
  - Was möchten Sie untersuchen oder verstehen?
  - Wenn Sie eine klare Antwort haben, können Sie die Datenqualität beurteilen!

Datenqualität

1. *Content* (Inhalt): Was erfasst eine Variable tatsächlich. Immer Details überprüfen.
2. *Validity* (Gültigkeit): Entspricht der Inhalt der Variable dem beabsichtigten Inhalt. "Haltbarkeit" vs. "Qualität".
3. *Reliability* (Zuverlässigkeit): Wenn wir dieselbe Variable mehrfach für dieselbe Beobachtung messen würden, sollte sie dasselbe Ergebnis liefern.
4. *Comparability* (Vergleichbarkeit): Verschiedene Bebachtungen werden auf ähnliche Weise gemessen.
5. *Coverage* (Abdeckung): Idealerweise vollständige Abdeckung. In der Praxis sind möglicherweise nicht alle gewollten *units* enthalten (unvollständige Abdeckung).
6. *Unbiased selection* (Repräsentativität): Bei unvollständiger Abdeckung sollten die enthaltenen Beobachtungen ähnliche Merkmale aufweisen wie alle Beobachtungen, die abgedeckt werden sollten.

Nebenbemerkung

- Dies ist nicht die Art von Kurs, in dem Sie eine Liste auswendig lernen müssen.
- Sie sollten jedoch in der Lage sein, die Qualität von Variablen in Ihrer Arbeit beurteilen zu können.

- Und eines nicht vergessen: **GIGO**: *Garbage in, garbage out* (Müll rein, Müll raus).

Datenanalysten sollten ihre Daten kennen

- Bevor Daten verwendet werden, ist es wichtig zu **verstehen**:
  - Wer hat die Daten erhoben und mit welchem Ziel
  - Alle Einzelheiten der Messung, die für ihre Analyse relevant sein könnten
- Erhobene Daten müssen immer **sauber dokumentiert** werden, z.B. durch:
  - README.txt, der beschreibt, woher der Datensatz stammt.
  - VARIABLES.xls, der grundlegende Informationen zu Ihren Variablen bereitstellt (inklusive Masseinheiten).
- *Replication directories* sind Teil **transparenten** wissenschaftlichen Arbeitens
  - Von Anfang an Daten und Codes so organisieren, dass sie "vorzeigbar" sind

Pause and reflect...

- Was haben wir gelernt?

Gehe zu `https://pingo.coactum.de`, *access number* 376132

Data collection (Datenbeschaffung)

- *Automated data collection*: Automatisierte Datenerfassung
- *Survey*: Umfragen
- *Administrative and census data*: Daten aus der öffentlichen Verwaltung
- *Big Data*

Automated data collection

- *Application Programming Interface*, oder API - **Laden** von Daten **direkt in eine statistische Software**.
  - Eine API ist ein *software intermediary* (Softwarevermittler), or ein *interface* (Schnittstelle).
  - Es ermöglicht Programmen oder Skripten, miteinander zu kommunizieren.
- APIs zunehmend verbreitet.
  - Makrodaten: FRED - St. Louis Fed unter `research.stlouisfed.org/docs/api/fred/`, auch Weltbank usw.
  - Mikrodaten wie Wetterdaten auf: `openweathermap.org/api`
  - Räumliche Daten über die Google Places API

Automated data collection

- *Web scraping*: Sammeln von Daten von Online-Plattformen.
  - HTML-Code enthält Daten, die gefunden, analysiert und gesammelt werden können.
  - Erfordert **umfangreiche Bereinigung** (*data cleaning*).
  - Sobald ein Verfahren bereit ist (Code, Skript), kann es wiederholt werden.
  - Die Datenerfassung ist auf das beschränkt, was auf einer Website verfügbar ist.
    - Häufig ist die *coverage* eingeschränkt

Administrative and census data

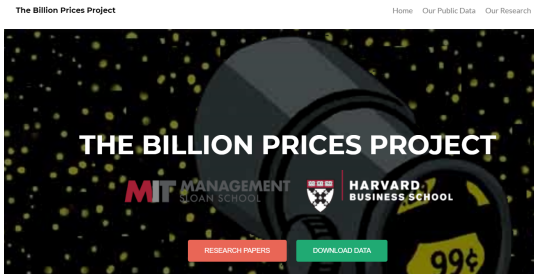
- Daten aus der öffentlichen Verwaltung, Steuern, Sozialversicherung
  - Z.B. Daten aus Volkszählungen zu zahlreinen Bevölkerungsmerkmalen
- Viele Vorteile
  - Hohe Abdeckung, wenige fehlende Werte (*missing values*), **verlässliche Inhalte**
  - Viele gut definierte und dokumentierte Variablen
- Einige Nachteile
  - Variablen sind für Geschäfts-/Regierungszwecke definiert.
    Enthalten nicht immer alle erforderlichen Informationen für eine Forschungsarbeit
  - Oft nicht detailliert/spezifisch genug
  - Großes Problem ist häufig **sehr begrenzter** Zugang auf Grund von Vertraulichkeit

Finding a good deal among hotels: data collection

- Der Datensatz über Hotels in Wien wurde durch **Web-Scraping** gesammelt.
  - Von einer Preisvergleichswebsite an einem bestimmten Datum.
- Der Zweck der Website besteht nicht darin, die Datenanalyse zu erleichtern...
  - Aber: Keine andere potenzielle Datenquelle vefügbar.
- Gute Qualität, aber *noise* (Rauschen)
  - **Bereinigung** unplausibler Werte **erforderlich**
  - Vermutlich durch Eingabefehler entstanden, offensichtlich keine Qualitätskontrolle
- Die **Abdeckung** ist gut, aber **nicht vollständig**.
  - Hotels, die auf diesen Websites werben, sind nicht unbedingt zufällige Teilmenge
  - also keine *unbiased selection*
    - Fehlende Hotels können bestimmte Merkmale aufweisen, z.B. ältere Stammkunden

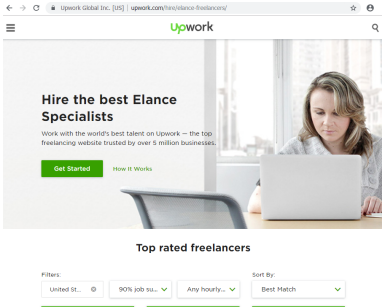
Comparing online and offline prices: data collection

- The Billion Prices Project (BDP) Datensatz wurde für akademische Forschung erhoben
  - Cavallo (2017, AER)
- 56 große Händler, die online und offline anbieten, in 10 Ländern.
- Wir werden den Datensatz verwenden, um zu untersuchen ob sich Online- und Offline-Preise unterscheiden.



Comparing online and offline prices: data collection

- BPP befasst sich mit der Messung von Preisen für dieselben Produkte, die über verschiedene Vertriebskanäle verkauft werden.
- *Mixed methods* (gemischte Methoden)
- Offline-Datensammlung über *Upwork Mechanical Turk crowdsourcing plattform*
- Online-Preise wurden gescraped
- Projektmanager versuchen Informationen zu genau denselben Produkten zu sammeln, die ungefähr zur gleichen Zeit erhältlich sind.



Data quality - billion prices project data

1. *Content*: welches Produkt, welcher Preis
2. *Validity*: Beabsichtigt ist die Erfassung des Preises des Zielprodukts im Geschäft.
   - Nicht trivial!
3. *Reliability*: Timing ist schwierig, insbesondere wenn sich die Preise häufig ändern.
4. *Comparability*: Sind Produkte *gleichermaßen* präzise erfasst? Laptop vs. Käse
5. *Coverage*: Nicht universell, spezifische Auswahl.
6. *Unbiased selection*: Zeitraubende Planung. Bei Elektrogeräten wird eine typische Auswahl an Fernsehern, Telefonen usw. benötigt.

Data collection: Survey

- *Surveys*:
  - *Respondents* (*Befragte*) werden **befragt** und ihre Antworten aufgezeichnet.
  - Antworten werden in Variablen umgewandelt (*encoding*).
  - Großer Vorteil: Sie können **genau das fragen, was Sie wissen möchten**
- Es gibt zwei Hauptarten von *surveys*:
  - *Self-administered surveys* (Selbstverwaltete Umfragen)
    - Befragte füllen selbständig einen *questionnaire* (Fragebogen) aus
    - Günstig und effizient, kann visuelle Hilfsmittel verwenden.
  - Interviews.
    - Web, Telefon, persönlich, gemischt (computergestütztes Interview).
    - Kann bei komplexen Sachverhalten Missverständnissen vorbeugen, aber teuer.

Sampling

- In manchen Fällen können wir Daten von allen Menschen, die uns interessieren, = *population* (Grundgesammtheit), sammeln. Oft ist dies jedoch nicht möglich...
- Aus Kostengründen oder aus Gründen der Zeitersparnis müssen wir uns auf ein *sample* (Stichprobe) beschränken - dies ist der Prozess des *Samplings*.
- ***Samples* sollen die *population* repräsentieren**. Eine *sample* ist *repräsentativ*
  - wenn die **Verteilung (*distribution*)** aller Variablen im *sample* dieselbe (oder sehr nah dran) ist wie die Verteilung in der *population*.
  - Die Verteilung von Variablen beschreibt die **Häufigkeit (*frequency*) der verschiedenen Merkmalausprägungen**, z.B. der Anteil der Frauen, Prozent mit Einkommen innerhalb einer bestimmten Spanne. (*Mehr dazu in Thema 03.*)

Sample: Representativeness

- Ob eine Stichprobe repräsentativ ist, lässt sich nicht direkt feststellen.
- Es gibt zwei Möglichkeiten abzuschätzen, ob eine Stichprobe repräsentativ ist:
  1. Beurteilung des **Datensammlungsprozesses**—subjektiv mit objektiven Elementen
     - Hotels mit bestimmten Merkmalen könnten eher auf der Online-Plattform erscheinen...
  2. *Benchmarking* (Vergleich) einiger Variablen, für die wir die **Verteilung in der *population*** kennen.
     - Zum Beispiel könnten nationale Statistiken für bestimmte Merkmale vorhanden sein.
     - Oder sehr ähnliche Unternehmen haben umfassende Daten gesammelt.
     - Ein Realitätscheck ist immer sehr nützlich.
     - Wir könnten überpruefen ob die Verteilung der Entfernungsvariable im Sampel der Verteilung in der *population* entspricht, wenn wir ein Register aller lizensierten Hotels von der Stadt Wien erhalten...

Sampling: Random samples (zufällige Stichproben)

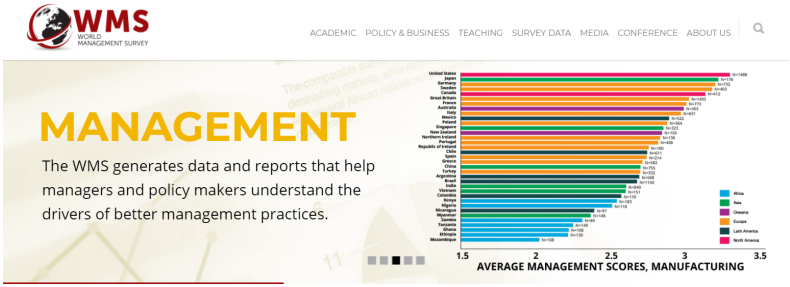
- *Random sampling* führt **am ehesten zu repräsentativen** Stichproben führt.
  - Alle Beobachtungen in der *population* haben die gleiche Chance, in die Stichprobe ausgewählt zu werden.
- In der Praxis: Zufallsregel (z.B. Münzwurf, bzw. *random number generator*).
  - Jede andere Methode, die Beobachtungen nicht zufällig auswählt, kann eine unerwartete *bias* (Verzerrung) verursachen und verhindern, dass unsere Stichprobe repräsentativ ist.
  - Andere Regeln sind grundsätzlich denkbar solange die **Auswahlkriterien von der Verteilung der relevanten Variablen unabhängig sind**
    - Wir werden eine repräsentative Preisverteilung erhalten, solange die Entscheidung das Hotel in der Online-Plattform zu praesentieren, nichts mit dem Preis zu tun hat.

Sampling: Random samples

- Sehr kleine Samples (Dutzende bis wenige Hundert) sind schwerlich repräsentativ
  - Zufallselement ist zu groß.
- Eine Stichprobe von mehreren tausend Beobachtungen kann aber genauso gut *populations* von fünfzigtausend oder zehn Millionen repräsentieren.
  - Die erforderliche Stichprobengröße hängt davon, was Sie messen möchten!
- Generell gilt: **Repräsentativität ist wichtiger als Grösse**

Management quality and firm size: data collection

- www.worldmanagementsurvey.org - Grosser Survey zu Unternehmensmerkmalen und -management.
- **Wir werden den Datensatz verwenden, um zu untersuchen, ob Unternehmen mit besserem Management erfolgreicher sind**



Management quality and firm size: data collection

- Befragen von mehr als 10.000 Industrieunternehmen (auch öffentlicher Sektor).
- Managementbefragung
  - *Scorecard* für 18 Überwachungs-, Zielsetzungs- und Anreizpraktiken.
  - Etwa 45-minütige Telefoninterviews mit Werksleitern in der Fertigung.
  - Ziel sind unvoreingenommene vergleichbare Antworten ("*double blind*")
    - Die Interviewer kennen die Leistung des Unternehmens nicht.
    - Die Manager werden nicht (im Voraus) darüber informiert, dass sie bewertet werden.
    - Die Durchführung erfolgt von London aus, mit derselben Schulung und Länderrotation.
  - Firmen zur Teilnahme am Interview bewegen
    - Als "Lean Manufacturing"-Interview vorgestellt, eine Abfrage von Finanzdaten.
    - Durchgeführt von über 100 MBA-Absolventen (mit Arbeitsserfahrung).

Management quality and firm size: data collection

- Beispielfrage: "Wie wird die Leistung evaluiert?"
- Moegliche "Scores"
  - **(1)**: Die evaluierten Kriterien spiegeln nicht direkt wieder, ob die allgemeinen Geschäftsziele erreicht werden. Bestimmte Prozesse werden überhaupt nicht beurteilt.
  - **(3)**: Die meisten wichtigen Leistungskennzahlen werden formell evaluiert. Die Evaluation wird von der Geschäftsleitung überwacht.
  - **(5)**: Die Leistung wird kontinuierlich und sowohl formell als auch informell mit einer Vielzahl von visuellen Management-Tools evaluiert und an alle Mitarbeiter kommuniziert.

Management quality and firm size: data collection

- Wie schätzen wir die Datenqualität für unsere Zwecke ein?

Gehe zu `https://pingo.coactum.de`, *access number* 376132

Was ist das Besodere an Big Data?

- **Big Data** bezieht sich auf:
  - (i) **massive** Datensätze
    - Bisweilen Milliarden von Beobachtungen (oft zu viel fuer einen PC).
  - (ii) typischer Weise automatisch und kontinuierlich gesammelt und gespeichert
    - **Automatische Erfassung** erfolgt **nicht für Ihren Zweck**—im Gegensatz zum Survey. Daten werden von Apps, Sensoren erfasst
  - (iii) häufig von **komplexer Natur**
    - Text (Video, Musik/Geräusche), Netzwerk, multidimensional, Karten
- **Achtung**: Nur weil ein Sample groß ist, muss sie nicht unbedingt repräsentativ sein!!!!

Sample selection bias

- Das gesammelte **Sample unterscheidet sich häufig von der *population***
  - z.B. können Menschen bestimmter Bevölkerungsgruppen stärker vertrete sein
- Schlußfolgerunge, die im Sample gelten, gelten nicht unbedingt in der *population*.
- Beispiel: Vorhersage bei Wahlen
  - 1936: Literary Digest. FD Roosevelt vs. Landon.
    - 10 Millionen Menschen befragt.
    - 2 Millionen antworteten.
    - Größte Umfrage aller Zeiten.
    - Landon wurde mit 57% Sieg vorhergesagt.

Rechtliche und ethische Aspekte

- Rechtliche Beschränkungen
  - Grundsätzlich die **Datenquelle immer prominent angeben**
  - Wissenschaftliche Arbeiten aus der die Daten hervorgeangen sind **immer zitieren**
- Besonders bei sensiblen Informationen können ethische Aspekte relevant sein
  - *General Data Protection Regulation, GDPR)* (Datenschutz-Grundverordnung, DSGVO))

Kommunizieren Sie immer mit den Eigentümer*innen der Datenquelle(n) und/oder mit Anwälten, wenn Sie vorhaben, möglicher Weise sensible Daten zu verwenden!

Datensammlung ist aufwändig, zeitaufwendig, kostspielig.

- Die Datensammlung ist eine **mühsame Aufgabe** und oft teuer.
  - In der Regel ist es nicht so einfach, wie Sie denken...
- **Der Aufwand lohnt sich** aber.
  - Mit der Datenqualität steht und fällt die Qualität jeder ökonometrischen Untersuchung!
- Datenqualität und -Verfügbarkeit muss von Anfang mitgedacht werden
  - Sobald die Forschungsfrage klar ist, auf Datensammlung konzentrieren
  - Wenn klar wird, dass die Daten nicht Verfügbar oder nicht gut genug sind:
    - **Projekt führzeitig abbrechen!** (*sunk cost fallacy* vermeiden)

Zusammenfassung

- Die Datenqualität, wie z.B. eine schlechte Abdeckung (hoher Anteil fehlender Beobachtungen), bestimmt, was Sie mit den Daten tun können.
- Die Daten können aus bestehenden Quellen stammen (wie Finanzbehörden, Weltbank) oder Sie müssen eine Umfrage durchführen. Umfragen können passender sein, sind jedoch teuer und zeitaufwändig.
- Eine repräsentative Stichprobe ist für jede Analyse unerlässlich. Auch bei Big Data.
- Die Einhaltung der Vertraulichkeit von Daten ist eine wichtige jurusitische und ethische Regel, die befolgt werden muss.

Literatur

- Cavallo, A. (2017): Are Online and Offline Prices Similar? Evidence from Large Multi-channel Retailers. American Economic Review, 107(1), 283-303.