# 02 Datenaufbereitung

**Gabriel M Ahlfeldt**

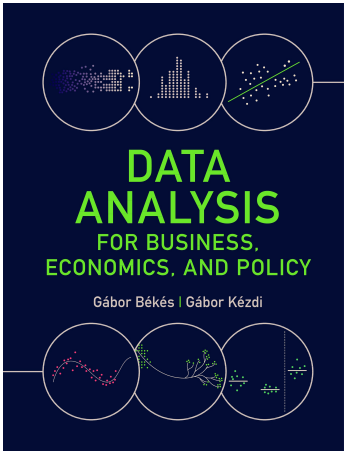
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

# Acknowledgements


- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

# Slideshow for the Békés-Kézdi Data Analysis textbook




- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 02**

# Topic 1

- Ist das wichtigste hängen geblieben?

Gehe zu https://pingo.coactum.de, *access number* 844405



# Motivation

- Wer war der **erfolgreichste Trainer in der englischen Fußballliga?**
  - Durchschnittliche Punkte pro Spiel während der Zeit bei einem Verein
  - Wir haben Daten zu Fußballspielen in einer professionellen Liga und Daten zu Trainern (*managers*) heruntergeladen, einschließlich bei welchem Team sie wann gearbeitet haben. Um die Forschungsfrage zu beantworten, müssen wir diese **Daten kombinieren**.

Gehe zu `https://pingo.coactum.de`, *access number* 844405

# *Variable types* (Variablentypen): *Qualitative vs quantitative*

- Daten können in verschiedenen Formen erfasst oder generiert werden. Variablen können die Qualität oder die Quantität eines Phänomens erfassen.

- ***Quantitative variables***: Sind von Geburt an **Zahlen**. Sie nehmen in der Regel viele Werte an
  - Auch numerische Variablen genannt
  - Ein besonderer Fall ist die Zeit (Datum)

- ***Qualitative variables***: Nehmen nur wenige Werte an, wobei jedem Wert eine spezifische Interpretation zugeordnet ist (Zugehörigkeit zu einer **Kategorie**)
  - Eine andere Bezeichnung ist *cateogrical variabe* oder *factor variabe*.
  - Beispiel Nationalität

# *Variable types—binary*

- Ein Sonderfall ist eine ***binary variable***, die zwei Werte annehmen kann.
  - Ja/Nein-Antwort auf die Frage nach Zugehoerigkeit zu bestimmter Gruppe.
  - Am besten kodiert man diese als 0- oder 1-Variablen dar: 0 für Nein, 1 für Ja.
  - Dann bezeichnen wir sie als ***dummies*** oder ***indicator variables***
- *Binary variables* werden of als *flag* verwendet:
  - Zum Anzeigen eines bestimmten Problems (z. B. fehlende Werte für eine andere Variable, Vorhandensein in einem anderen Datensatz)

# *Variable types*—formale Definition

1. **Nominal qualitative variables**: Nehmen Werte an, die *nicht eindeutig* geordnet werden können (z.B. gelb, gruen, blau).
2. **Ordinal variables**: Nehmen Werte an, die *eindeutig geordnet* sind. Alle *quantitative variables* können geordnet werden; einige *qualitative variables* können ebenfalls geordnet werden (sehr gut, gut, befriedigend, etc.).
3. **Interval variables**: Geordnete Variablen, wobei *Unterschiede zwischen Werten verglichen werden können*.
   - Temperatur (in Grad Celsius). 30-10 $>$ 20-10, aber 20 vs. 10 bedeutet nicht doppelt so viel Temperatur, 0 bedeutet nicht, das es keine Temperatur gibt
4. **Ratio variables** ($=$ *scale variables*): Variablen sind Intervallvariablen mit der zusätzlichen Eigenschaft: Ihre Verhältnisse bedeuten dasselbe.
   - Gewicht (in kg). 80 doppelt so schwer wie 40. 0 bedeutet, dass es keine Masse gibt.

# *Data wrangling* (Datenbereinigung )

***Data wrangling*** ist der Prozess der Umwandlung von **Rohdaten** (*raw data*) in eine Reihe von **Datentabellen**, die für verschiedene nachgelagerte (*downstream*) Zwecke wie Analysen verwendet werden können.

[1] Verstehen und Speichern

- Ausgangspunkt sind Rohdaten
- Struktur und Inhalt verstehen
- *tidy data tables* (übersichtliche Datentabellen) erstellen
- Zusammenhänge zwischen Tabellen verstehen

[2] Datenbereinigung

- Merkmale und Variablentypen verstehen
- Duplikate filtern
- Nach fehlenden Beobachtungen suchen und damit umgehen
- Mit Extremwerten umgehen

# Der *tidy data* Ansatz

Ein Leitfaden zur Organisation und Bereinigung von Daten ist der ***tidy data* Ansatz**:

1. **Eine *observation*** (Beobachtung) **pro *row*** (Zeile).
2. **Eine *variable*** (Variable) **pro *column*** (Spalte).
3. **Eine** *observational* ***unit*** (Beobachtungseinheit, z.B. Stadt, Land) **pro Tabelle**.
4. Jede *observation* hat eine **eindeutige Kennung** (ID)

Vorteile:

- Standarddatentabellen, die **leicht zu bearbeiten** sind.
- Das **Finden von Fehlern** und Problemen in den Daten ist einfacher
- **Transparent**, was anderen Nutzern hilft.
- **Einfach zu erweitern**. Neue Beobachtungen werden als neue Zeilen hinzugefügt; neue Variablen als neue Spalten.

# *Simple tidy data table*

Table: A simple tidy table

| | **Variables/columns** | | |
|---|---|---|---|
| | **hotel_id** | **price** | **distance from center** |
| **Observations/rows** | 21897 | 81 | 1.7 |
| | 21901 | 85 | 1.4 |
| | 21902 | 83 | 1.7 |

Source: hotels-vienna data. Vienna, 2017 November weekend.

# Tidy data Tabelle für *multi-dimensional data* (mehrdimensionale Daten)

- *long format* bei *xt* Paneldaten mit *cross-sectional* und *time* (Zeit) Dimension:
  - Eine ID Variable für ***cross-sectional unit*** (Querschnitseinheit)(z.B. Stadt)
  - Eine ID Variable für ***time-series period*** (Zeitreihenperiode) (z.B. Jahr)
  - Jede Zeile hat eine **einmalige Kombination** der Auspraegungen der ID Variablen
- *wide format*
  - Eine Zeile entspricht einer *observation* einer ***cross-sectional unit***
  - Verschiedene *periods* werden in verschiedenen **Spalten** gezeigt
  - Mehrere Beobachtungen (der gleichen *unit*) für verschiedene *periods*
- ***long format* besser für die Datenspeicherung und -analyse geeignet**
  - *Wide format* kann zur Illustration hilfreich sein
  - Saubere IDs für Wechsel zwischen den Formaten entscheidend (*reshape*)

# Displaying immunization rates across countries

- xt-Panel von Ländern mit jährlichen Beobachtungen,
- Heruntergeladen von der *World Development Indicators data website* der *World Bank*.
- Beachten Sie die Datenstruktur mit **Fokus auf den beiden ID-Variablen** (Land und Jahr) sowie den beiden anderen Variablen, Immunisierungsraten (*immunization rate*) und BIP pro Kopf (*GDP per capita*).

# Displaying immunization rates across countries – LONG

| Country | Year | imm | gdppc |
|---|---|---|---|
| India | 2015 | 87 | 5743 |
| India | 2016 | 88 | 6145 |
| India | 2017 | 88 | 6516 |
| Pakistan | 2015 | 75 | 4459 |
| Pakistan | 2016 | 75 | 4608 |
| Pakistan | 2017 | 76 | 4771 |

***long format*** der Länder-Jahres-Panel-Daten, **jede Zeile entspricht einem Land in einem Jahr**. imm: Rate der Immunisierung gegen Masern bei 12-13 Monate alten Säuglingen. gdppc: BIP pro Kopf, KKP, konstante USD von 2011. Quelle: `world-bank-vaccination` Daten.

# Displaying immunization rates across countries – WIDE

Umwandlung von *lopng* in *wide format*: `reshape wide imm gdppc, i(Country) j(Year)`

| Country | imm2015 | imm2016 | imm2017 | gdppc2015 | gdppc2016 | gdppc2017 |
|---|---|---|---|---|---|---|
| India | 87 | 88 | 88 | 5743 | 6145 | 6516 |
| Pakistan | 75 | 75 | 76 | 4459 | 4608 | 4771 |

Und zurück von *wide* in *ling format*: `reshape long imm gdppc, i(Country) j(Year)`

***wide format*** der Länder-Jahres-Panel-Daten, jede Zeile entspricht einem Land, **verschiedene Jahre sind verschiedene Variablen**. imm: Rate der Immunisierung gegen Masern bei 12-13 Monate alten Säuglingen. gdppc: BIP pro Kopf, KKP, konstante USD von 2011. Quelle: `world-bank-vaccination` Daten

# *Relational database* (Relationale Datenbank)

- Die ***Relational database*** ist ein Konzept zur Organisation von Informationen.
  - Es handelt sich um eine Datenstruktur, die es ermöglicht **Datentabellen zu verknüpfen**
- Jede Tabelle besteht aus Zeilen und Spalten.
  - Jede Zeile ist eine *observation* (Beobachtung), der mit einer eindeutigen Kennung *ID* (auch *key* genannt) identifiziert wird.
- ***observations*** in einer Tabelle lassen sich mit *observations* in anderen Tabellen **zusammenführen** (*merge*), wenn beide Datentabellen eine **eindeutige ID** (*unique ID*) enthalten.
  - Beispiel: Wir können anhand der Länder-ID das BIP unterschiedlicher Jahre zusammenführen und dann Wachstumsraten berechnen

# Identifying successful football managers

- **Wer waren die erfolgreichsten *football manager* (Trainer) in England?**
  - Wir kombinieren Daten aus zwei Quellen für diese Analyse
    - eine zu Teams und Spielen und eine andere zu *manager* (später)
  - Die Daten umfassen 11 Saisons der Spiele der englischen Premier League (EPL)
    - von 2008/2009 bis 2018/2019.
- Jede **Beobachtung ist ein einzelnes Spiel**. Die entscheidenden Variablen sind
  - das Datum des Spiels
  - der Name des Heimteams, der Name des Auswärtsteams,
  - Tore, die vom Heimteam erzielt wurden, Tore, die vom Auswärtsteam erzielt wurden
  - Letztendlich sind wir an Punkten pro Spiel interessiert...
- Die Daten stammen von der Website `www.football-data.co.uk`

# Identifying successful football managers

Table: Games data

| Date | HomeTeam | AwayTeam | Home goals | Away goals | Home points | Away points |
|---|---|---|---|---|---|---|
| 2018-08-19 | Brighton | Man United | 3 | 2 | 3 | 0 |
| 2018-08-19 | Burnley | Watford | 1 | 3 | 0 | 3 |
| 2018-08-19 | Man City | Huddersfield | 6 | 1 | 3 | 0 |
| 2018-08-20 | Crystal Palace | Liverpool | 0 | 2 | 0 | 3 |
| 2018-08-25 | Arsenal | West Ham | 3 | 1 | 3 | 0 |
| 2018-08-25 | Bournemouth | Everton | 2 | 2 | 1 | 1 |
| 2018-08-25 | Huddersfield | Cardiff | 0 | 0 | 1 | 1 |

```
browse if date==d(19aug2018) | date==d(20aug2018) | date== d(25aug2018)
```

**Tidy data table? Long / wide format?**

# Identifying successful football managers

- Für unsere Zwecke lässt sich die **Datenstruktur verbessern**
  - Wir sind schlussendlich allgemein an *points* interessiert
    - Und nicht speziell an *home* oder *away points*
  - Nicht ideal, wenn die Information in mehr als einer Variable ist
- Wir wollen alle Informationen zu *points* **in einer Variable/Spalte**
  - Dazu definieren wir eine Beobachtung/Zeile als ein von einem Team gespieltes Spiel
    - Wir sagen ***our unit of observation is team-match***
      (unsere Beobachtungseinheit ist Team-Spiel)
  - Intuitiv betrachten wir die Variablen aus der Sicht dieses Teams
    - Wann wurde gespielt, wer war der Gegner und was war das Ergebnis?

# Identifying successful football managers

Table: Games data - long table version

| Date | Team | Opponent team | Goals | Opponent goals | Home/away | Points |
|---|---|---|---|---|---|---|
| 2018-08-19 | Brighton | Man United | 3 | 2 | home | 3 |
| 2018-08-19 | Burnley | Watford | 1 | 3 | home | 0 |
| 2018-08-19 | Man City | Huddersfield | 6 | 1 | home | 3 |
| 2018-08-19 | Man United | Brighton | 2 | 3 | away | 0 |
| 2018-08-19 | Watford | Burnley | 3 | 1 | away | 3 |
| 2018-08-19 | Huddersfield | Man City | 1 | 6 | away | 0 |

- **Alle Spiele tauchen jetzt zwei mal auf!**
  - einmal für jedes der beiden spielenden Teams.
- Wir **können** jetzt...
  - ...z.B. einfach die **durchschnittliche Punktzahl eines Teams berechnen**
    - `sum Points if Team == "Brighton"`

# Identifying successful football managers

- Die *long format* Tabelle hat **doppelt so viele Zeilen** wie die Originaldatentabelle
  - Jedes Spiel erscheint in dieser Datentabelle zweimal
- Dafür haben wir nur noch **eine (statt zwei) *points* Variable**
  - Neue Variable zur Kennzeichnung, ob das Team bei diesem Spiel das Heim- oder Auswärtsteam war (*home/away*).
- Jetzt haben wir **zwei ID-Variablen**, eine zur Kennzeichnung des **Teams** und eine zur Kennzeichnung des **Datums** des Spiels
  - Die Identität des gegnerischen Teams ist eine qualitative Variable
    - nicht für die eindeutige Identifizierung einer Beobachtung notwendig
  - Ermöglicht weitere Team-Spieltag **Daten zu mergen**, z.B. *manager*
    - Im *wide* Format müssten wir für *home* und *away* separat mergen

# Identifying successful football managers

- Unsere zweite Datentabelle betrifft **Trainer (*manager*)**
- Eine Zeile entspricht einer **Trainer-Team-Beziehung**
  - Jeder Trainer kann in dieser Datentabelle mehrmals vorkommen, wenn er für mehrere Teams gearbeitet hat (Team-Trainer identifiziert Beobachtungen eindeutig).
- Für jede Beobachtung haben wir
  - den Namen des Trainers
  - seine Nationalität
  - den Namen des Teams (Vereins)
  - den Beginn seiner Arbeit beim Team
  - und das Ende.

# Identifying successful football managers

Table: Managers data

| Name | Nat. | Club | From | Until |
|---|---|---|---|---|
| Arsene Wenger | France | Arsenal | 1 Oct 1996 | 13 May 2018 |
| Unai Emery | Spain | Arsenal | 23 May 2018 | Present* |
| Ron Atkinson | England | Aston Villa | 7 June 1991 | 10 Nov 1994 |
| Brian Little | England | Aston Villa | 25 Nov 1995 | 24 Feb 1998 |
| John Gregory | England | Aston Villa | 25 Feb 1998 | 24 Jan 2002 |
| Dean Smith | England | Aston Villa | 10 Oct 2018 | Present* |
| Alan Pardew | England | Crystal Palace | 2 Jan 2015 | 22 Dec 2016 |
| Alan Pardew | England | Newcastle | 9 Dec 2010 | 2 Jan 2015 |

Source: `football` data. Present = 01 July 2019

# Identifying successful football managers

- Beide Tabellen bilden ein ***relational data set***
- Eine Datentabelle mit
  - **Team-Spiel**-Beobachtungen und eine Datentabelle mit
  - **Trainer-Team**-Beobachtungen.
- Um mit den Daten zu arbeiten, müssen wir eine einzelne Datentabelle auf
  - **Team-Spiel**-Ebene erstellen
  - Mit einer Variable, die anzeigt wer zum Zeitpunkt dieses Spiels der Trainer war.
    - Dafür müssen wir beiden Datentabellen zusammenführen...

# *Merging* (Zusammenführen) von *relational data*

- Den Prozess des Zusammenführens verschiedener Variablen aus verschiedenen Datentabellen anhand von ID Variablen wird als **merging**, machmal auch **linking**, **joining** oder **matching** bezeichnet.
  - **one-to-one (1:1) merge**: Jeweils eine Ausprägung der ID Variable(n) in beiden Tabellen.
    - Fußballteams und Stadien
  - **many-to-one (m:1) or one-to-many (1:m) merge**: Eine Beobachtung aus einer Tabelle kann mehreren Beobachtungen in der anderen zugeordnet werden
    - Fußballteams und ihre Spieler heute—viele Spieler in einem Team.
  - **many-to-many (m:m) merge**: Beobachtugen in beiden Tabellen können mehreren Beobachtugen in der anderen Tabelle zugeordnet werden können.
    - Fußballteams und ihre Trainer im Laufe der Zeit—einige Trainer haben für mehrere Teams gearbeitet..

# Identifying successful football managers

- Wir begannen mit einem *relational data set*.
  - Zwei Datentabellen zusammengeführt und eine Arbeitsdatei (*work file*) erstellt
    - Aus den *manager spells* (Start/Ende) erzeugen wir einen Datensatz mit **Manager–Team–Spieltag**
    - Diesen können wir dann einfach über **Team und Spieltag** mit den Spieldaten mergen
- Die Arbeitsdatei enthält 8360 **Team-Spiel**-Beobachtungen:
  - In jeder der 11 Saisons spielen 20 Teams 38 Spiele (19 Gegner-Teams zweimal; $11 \times 20 \times 38 = 8360$).
  - Für jede **Team-Spiel**-Beobachtung haben wir einen Trainer
  - Es gibt 137 Trainer in den Daten.

# Identifying successful football managers

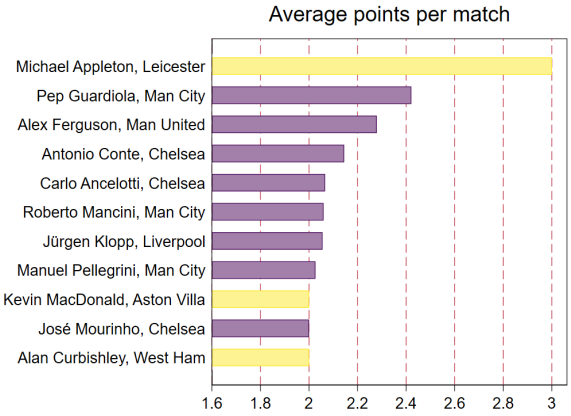
| season | date | team | points | team_opp | manager_name | date_from | date_until |
|---|---|---|---|---|---|---|---|
| 2008 | 16aug2008 | Arsenal | 3 | West Brom | Arsène Wenger | 01oct1996 | 13may2018 |
| 2008 | 16aug2008 | Blackburn | 3 | Everton | Paul Ince | 22jun2008 | 16dec2008 |
| 2008 | 16aug2008 | Bolton | 3 | Stoke | Gary Megson | 25oct2007 | 30dec2009 |
| 2008 | 16aug2008 | Everton | 0 | Blackburn | David Moyes | 15mar2002 | 01jun2013 |

- Wir können die durchschnittliche Punkteausbeute für einen Trainer betrachten!
  - Durchschnitt von `points` für alle `team-manager_name` Kombinationen
    - `egen AvPoints = mean(Points), by(team manager_name)`
      (erstellt eine zusätzliche Variable)
    - `collapse (mean) AvPoints = Points, by(team manager_name)`
      (reduzuert den Datensatz auf team-manager_name Ebene)

# Identifying successful football managers

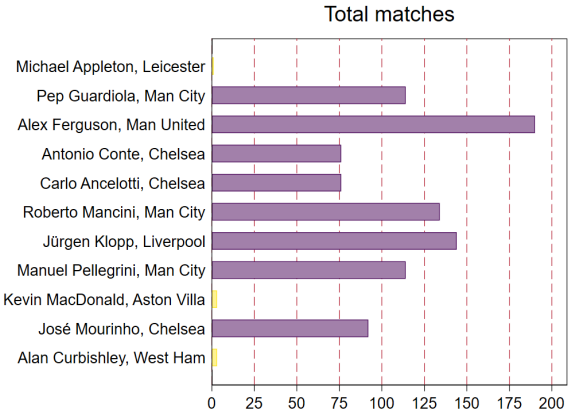
- Daten umfassen 11 Spielzeiten, EPL.
- *spells* (Amtszeiten): Wenn ein Trainer für zwei Teams gearbeitet hat, bedeutet das zwei *spells*.
- Durchschnittliche Punkte pro Spiel
- Aufgeführt werden Trainer mit einem Schnitt von mehr als 2.0 Punkten

Gehe zu
https://pingo.coactum.de,
*access number* 844405



# Identifying successful football managers

- Daten umfassen 11 Spielzeiten, EPL.
- *spells* (Amtszeiten): Wenn ein Trainer für zwei Teams gearbeitet hat, bedeutet das zwei *spells*.
- Anzahl der Spiele
- Aufgeführt werden Trainer mit einem Schnitt von mehr als 2.0 Punkten
- An *law of large numbers* (Gesetz der grossen Zahlen) ist vielleicht was dran...



# Tidy data: Zusammenfassung

- Erstellung von *tidy data tables*
  - Generierung eines Satzes von **Datentabellen, die einfach zu verstehen, zu kombinieren und in der Zukunft zu erweitern sind**
  - Oftmals liegen Rohdaten (*raw data*) nicht im übersichtlichen Format vor, und Sie müssen die Struktur, Beziehungen und einzelnen Bestandteile verstehen.
- Bei *relational data sets* sind **IDs entscheidend**
  - Für Analysen ist es meistens erforderlich, *tidy data tables* zu kombinieren.
  - Es muss immer eine ID or der eine Kombination mehrerer IDs geben, die eine *obervation* eindeutig identifiziert (***unique ID***)

# *Data wrangling: cleaning* (Datenbereinigung)

Bis wir mit den Daten arbeiten können ist es oftmals ein langer Weg...

- *Entity resolution*:
  - Umgang mit Duplikaten
  - Uneindeutige Zuordnung
  - *non-entity rows* (Zeilen ohne klare Zuordnung)
- *Missing values* (fehlende Werte)

# *Wrangling: Filter out Duplicates* (Entfernen von Duplikaten)

- Häufiges Problem: *duplicates* (Duplikate)
  - **Einige Beobachtungen erscheinen mehr als einmal in den Daten**.
  - Können das Ergebnis menschlicher Fehler oder der Merkmale der Datenquelle sein.
- Vorgehen:
  - Wiederholte Beobachtungen (*repeated observations*) entfernen wenn es keinen logischen Grund für das Vorhandensein gibt.
    - Stata: `duplicates drop`
  - Manchmal wird dieselbe Beobachtung sogar sehr häufig angezeigt.

# *Entity identification and resolution*

- Im Allgemeinen benötigen Sie eindeutige IDs.
  - Wenn das in den Rohdaten nicht gegeben ist, muss nachgebessert werden
- Zwei Beobachtungen mit der **gleichen ID gehören zu zwei *entities*** (Entitäten)
  - Beispiel: Jane Smith (ID)—es könnte diverse *entities* (hier Personen) geben.
  - Lösung: Eindeutige ID (*unique ID*) vergeben.
- Zwei **Beobachtungen derselben Entität haben unterschiedliche IDs**
  - Lösung: Eindeutige ID (*unique ID*) vergeben.

- **Unique IDs entscheidend. Numerische IDs sind meistens besser.**

# Entity resolution - football example

| Team ID | Unified name | Original name |
|---|---|---|
| 19 | Man City | Manchester City |
| 19 | Man City | Man City |
| 19 | Man City | Man. City |
| 19 | Man City | Manchester City F.C. |
| 20 | Man United | Manchester United |
| 20 | Man United | Manchester United F.C. |
| 20 | Man United | Manchester United Football Club |
| 20 | Man United | Man United |

```
foreach name in "Manchester City" "Man City" "Man.  City" "Manchester City F.C." {
replace Unified_name = "Man City" if Original_name == "‘name’"
}
```

# Entfernen von *non-entity observations*

- *non-entity observations*
  - Zeilen, die nicht zu einer Entität gehören, die nicht in die Datentabelle gehören
    - eine Zusammenfassungszeile in einer Tabelle, die Variablen für alle oder einige Entitäten aufaddiert oder mittelt
    - Eine Datentabelle, die von der Weltbank über Länder heruntergeladen wurde, enthält oft Beobachtungen über größere Regionen wie Subsahara-Afrika
  - Vorgehen: Finden und löschen.
    - `drop if Country == "Subsahara-Afrika"`

# *Missing values* (fehlende Werte)

- Werte einer Variablen sind nicht fuer alle Beobachtungen verfügbar.

1. Beschäftigen Sie sich mit der **Herkunft der Daten**. Gibt es Gründe anzunehmen, dass bestimmte Merkmale nicht erfasst werden (Datenqualität).
2. Fehlende Werte müssen identifiziert werden.
3. Die meisten Softwareprogramme kennzeichnen *missing values* (Stata ".").
4. Fehlende Werte sollten gezählt werden. Fehlende Werte bedeuten weniger Beobachtungen mit gültigen Informationen.
5. Überprüfen auf **selection bias**. Sind die *missing values* zufällig oder fehlen Werte bei Beobachtungen mit bestimmten Merkmalen in anderen Variablen?

# *Missing values*: Was können wir tun?

| Hotel | Price | Stars | Distance |
|---|---|---|---|
| 19 | 121 | 4 | 0.5 |
| 19 | 85 | 3 | . |
| 19 | 68 | 2 | 7.1 |

1. Beschränken Sie die Analyse auf **Beobachtungen mit nicht fehlenden Werten** für alle in der Analyse verwendeten Variablen.
   - Bei *selection bias* problematisch
2. *Imputation* - Hinzufügen fehlender Werte aus, z.B. Mittelwert oder Medianwert.
   - Boebachtungen mit imputierten Werten unbedingt kennzeichnen.
     - `sum Distance`
     - `gen MissingDistance = Distance == .`
     - `replace Distance = r(mean) if Distance == .`

# *Data wrangling*: Übliches Vorgehen

**Schreiben sie einen Code** für die Datenbereinigung (für Sie und andere replizierbar)

1. **Verstehen** Sie die Struktur des Datensatzes, erstellen Sie Datentabellen, erkennen Sie Verknüpfungen. Erstellen Sie ein Schema.
2. Beginnen Sie damit, die Datentabelle(n) auf **Probleme** zu untersuchen.
3. Speichern Sie Daten in ***tidy data tables***. Stellen Sie sicher, dass eine Zeile in den Daten eine Beobachtung darstellt, und löschen Sie Duplikate.
4. Bringen Sie jede Variable in ein **geeignetes Format** (z.B. double für numerische Variablen, string für Text).
5. Erstellen Sie eine Beschreibung der Variablen und verwenden sie ***variable labels***
6. Stellen Sie sicher, dass die Werte in sinnvollen Bereichen liegen; korrigieren Sie **nicht zulässige Werte** oder setzen Sie sie als *missing*.
7. Identifizieren Sie *missing values* und speichern Sie sie in einem geeigneten Format. Nehmen Sie bei Bedarf eine **Imputation** vor.