03 Explorative Datenanalyse

Gabriel M. Ahlfeldt

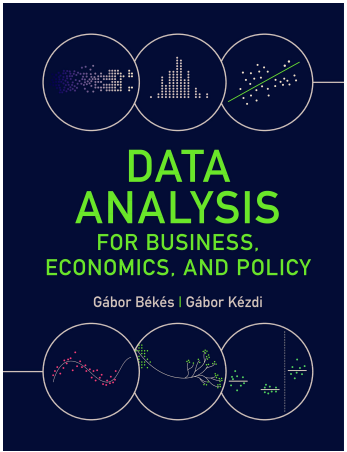
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 03**

Motivation

- Wir wollen **Hotels in Wien finden, die preiswert sind**
- Bevor wir mit der eigentlichen Analyse anfange, sollten wir uns erst mal **mit den Daten vertraut machen**
  - Wie **beschreiben** wir die Daten und präsentieren die wichtigsten Merkmale?
  - Wie überprüfen wir, ob die Daten **geeignet** für (weitere) Analysen sind?

Exploratory data analysis (EDA) (Explorative Datenanalyse)

Fünf gute Gründe für die EDA!

1. Um die **Datenbereinigung** (*data wrangling*) zu überprüfen
   - Teil eines iterativen Prozesses: Bereinigen, überprüfen, bereinigen, etc.
2. Um **empirische Strategie** zu entwickeln.
   - Gibt es Besonderheiten wie *non-linearities* (spater mehr) auf die wir achten müssen?
3. Um den **Kontext** der Ergebnisse nachfolgender Analysen zu geben
   - Z. B. Wir gross sind geschätzte Effekte relativ zu Durchschnittspreisen?
4. Um zusätzliche Fragen zu stellen (für die Spezifizierung der **Forschungsfrage**).
   - Z.B. Unterscheiden sich bestimmte Muster für verschiedene Hotels?
5. Um erste **Antworten** zu erhalten
   - Sehen wir das erwartete Muster mit einfachen, transparenten Methoden?

Variablen beschreiben (*describe variables*)

- **Bevor wir analysieren**: Verstehen wir, was in unseren Variablen steckt?

Drei Fragen an jede wichtige Variable

- Welche Werte kommen vor?
- Wie häufig kommen sie vor?
- Gibt es auffällige/extreme Werte?

Zwei Werkzeuge

- Tabellen und Grafiken zur Verteilung
- *Descriptive statistics*: Mittelwert, Median, Streuung, Quantile

Ziel: Variablen verstehen, Fehler erkennen, Vergleiche vorbereiten

Frequency und *distribution* (Häufigkeit und Verteilung)

- ***Frequency* (Häufigkeit)**
  - Die *absolute frequency* oder *count* ist die Anzahl der Beobachtungen mit einem bestimmten Wert.
  - Die *relative frequency* ist der Anteil der Beobachtungen mit diesem Wert.
  - Bei *missing values*: deutlich machen, ob sich Anteile auf alle Beobachtungen oder nur auf nicht-fehlende Beobachtungen beziehen.
- ***Distribution* (Verteilung)**
  - Die *distribution* einer Variable zeigt die *frequency* jedes Werts der Variable.
  - Sie kann mit absoluten oder relativen *frequencies* beschrieben werden.
  - Sie beschreibt die Variable vollständig, so wie sie in den Daten vorkommt.
  - **Immer** die Verteilung der wichtigsten Variablen betrachten.

Histograms (Histogramme)

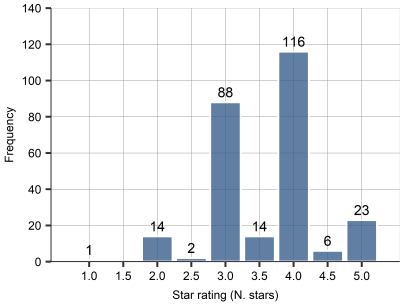
- Das *histogram* enthüllt **wichtige Eigenschaften einer *distribution***.
  - Was ist die Anzahl und Lage der *modes* (Modi oder Modalwerte)?
    - Die Spitzen in einer *distribution*, die sich von ihrer unmittelbaren Umgebung abheben.
  - Wo sind *center* (Zentrum) und *tails* (Schwänze) der *distribution*?
    - In welchen Wertebereich sind die meisten Beobachtungen?
  - Ist die *distribution* (symmetrisch) oder nicht
    - *asymmetric distributions* haben links order rechts einen *long* (lang) *tail*
  - Gibt es *extreme values* (Extremwerte)?
    - Werter am Ende der *tails*.
- Einfach von Statistiksoftware erstellen lassen
    - `hist x`

Extreme values (Extremwerte)

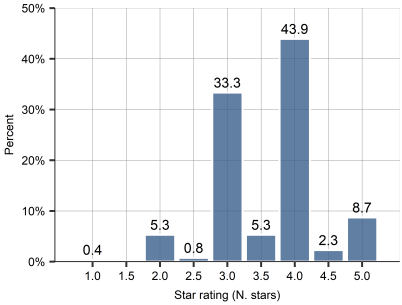
- Was tun mit *extreme values*?
  - Einige wenige Beobachtungen die **besonders groß oder klein** sind
  - Wenn sie sich stark von allen anderen Werten absetzen, nennen wir sie auch *outlier* (Ausreißer)
- Vorgehen.
  - Handelt es sich wahrscheinlich um einen **Messfehler**? (Eingabefehler)
    - Entfernen oder ersetzen
  - Zwar kein Fehler, aber **nicht Teil des Wertebereichs, der uns interessiert**?
    - Entfernen
  - Handelt es sich um ein wesentliches Merkmal der Daten?
    - Behalten

Hotel price histograms

(a) Absolute frequency (count)



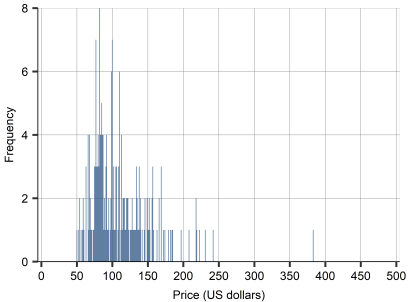
(b) Relative frequency (percent)



Source: `hotels-vienna` dataset. Vienna, Hotels only, for a 2017 November weekday

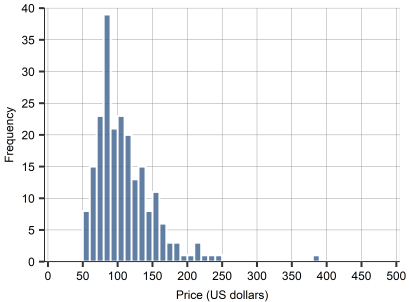
Hotel price histograms

(a) Histogram: 1$ bins (Behälter)




```
hist price, width(1)
```

(b) Histogram: 20$ bins (Behälter)

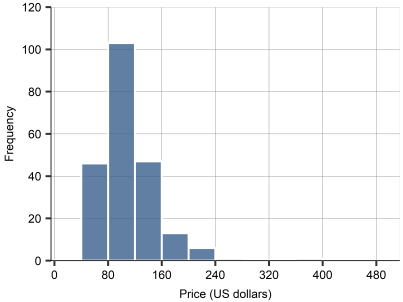



```
hist price, width(20)
```

Hinweis: *Panel (a) zeigt einzelne Werte - dies zeigt, wo sich die meisten Werte befinden. Panel (b) ist ein Histogramm mit 20$ Bins - es ist nützlicher, um die frequency zu erfassen.* Source: `hotels-vienna` dataset. Vienna, 3-4 stars hotels only, for a 2017 November weekday

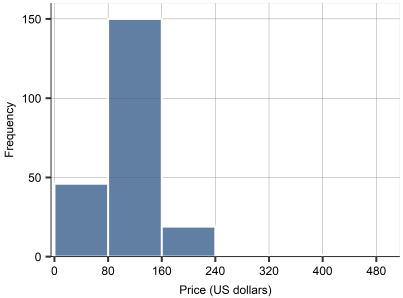
Hotel price histograms

(a) Histogram: 40$ bins



`hist price, width(40)`

(b) Histogram: 80$ bins



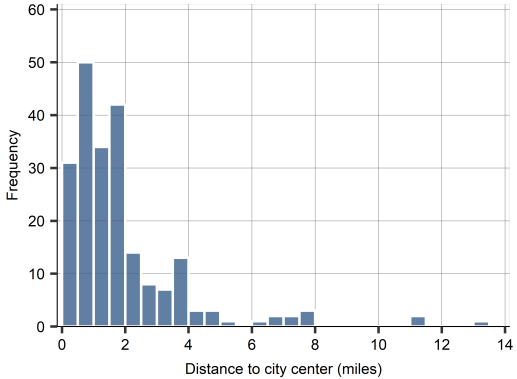
`hist price, width(80)`

Hinweis: *Die bin-size (Bin-Groesse) ist entscheidend. Groessere Bins geben den Eindruck einer gleichmäßigeren distribution.*

Hotel density plot

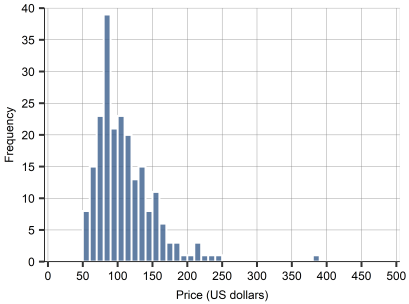
- Alle Hotels in Wien, 3-4 Sterne
- Gezeigt werden die *absolute frequencies* (counts)
- Verwendet werden Bins mit einer Breite von 0,5 Meilen. So können wir die Extremwerte besser sehen.
- Sehr weit entfernte Hotels wurden entfernt (*dropped*)—nicht in Wien

Figure: Histogram of distance to the city center.

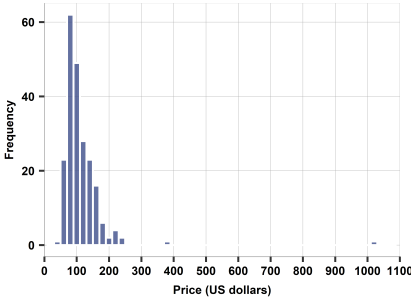


Hotel price histograms

(a) Histogram: 20$ wie gesehen



(b) Mit *extreme values* ueber 1000$



Source: `hotels-vienna` dataset. Vienna, 3-4 stars hotels only, for a 2017 November weekday

Summary statistics (Zusammenfassende Statistiken)

- *Statistic* (Statistik):
  - Eine aussagekräftige Zahl, die wir aus einem Datensatz berechnen können.
- *summary statistics*:
  - Beschreiben die wichtigsten Merkmale der Verteilung einer Variable.

- Das sollte Ihnen bekannt vorkommen (wenn nicht, Zeit fuer eine Wiederholung)...

Gehe zu `https://pingo.coactum.de`, *access number* 134884

Sample mean (Stichprobenmittelwert)

- Die am häufigsten verwendete Statistik ist der *mean* (Mittelwert):

$$\bar{x} = \frac{\sum x_i}{n} \tag{1}$$

  - wobei x_i den Wert der Variable x für Beobachtung i im Datensatz darstellt, der insgesamt n Beobachtungen hat.
    - `sum x`

- Zwei wichtige Eigenschaften:

$$\overline{x + a} = \overline{x} + \overline{a} \tag{2}$$

$$\overline{x \cdot b} = \overline{x} \cdot \overline{b} \tag{3}$$

Expected value (Erwartungswert)

- *Expected value*
  - Wert, den man für eine **zufällig ausgewählte Beobachtung** erwarten kann.
- Notation
  - $E[x]$ oder $\mathbb{E}(x)$.
- Für eine quantitative Variable ist der *expected value* der *mean* (Mittelwert).
  - Für eine qualitative Variable kann er nur bestimmt werden, wenn numerische Werte zugeordnet werden.

Median und andere *quantiles* (Quantile)

- *Quantiles*:
  - Werte, der die Beobachtungen der Variable x in n gleich goße Gruppen aufteilen.
    - `pctile PCTvalue = x, nq(10)` liefert die 9 Werte wenn $n = 10$ Gruppen
    - `xtile PCTgrup = x, nq(10)` ordnet die Beobachtungen den $n = 10$ Gruppen zu
- *Median*
  - mittlere Wert der Verteilung—die Hälfte der Beobachtungen hat einen niedrigeren Wert, und die andere Hälfte hat einen höheren Wert.
- *Quartiles*
  - teilen die Daten in vier gleich grosse Gruppen von Beobachtungen auf (Viertel).
  - Es gibt drei *quartiles*; jedes trennt ein Viertel der Beobachtungen von einem anderen
  - Ähnlich: *terciles* (drei Gruppen), *quintiles* (fünf Gruppen), *deciles* (10 Gruppen)
- *Percentiles* (Perzentile)
  - teilen die Daten in 100 gruppen auf; je ein Prozent der Beobachtungen.

Mode (Modus)

- *Mode*
  - Wert mit der höchsten *frequency* in den Daten.
    - `egen Mode = mode(x)`
- Einige Verteilungen sind *unimodal*, andere haben mehrere *modes* (Modi).
  - Verschiedene *modes* liegen voneinander entfernt
  - Heben sich jeweils in ihrer "Nachbarschaft" hervor
  - Können unterschiedliche *frequencies* aufweisen.

Central tendency (Maße der zentralen Tendenz)

- Verschiedene Maße der *central tendency* können sinnvoll sein.
  - Alle Messen **Zentralität innerhalb einer Verteilung**
- Typische Maße
  - *Mean*:
    - Intuitiv, der Wert, den man für eine zufällig ausgewählte Beobachtung erwarten kann.
    - Aussagekräftig in symmetrischen Verteilungen, da stark von *outlier* beeinflusst
  - *Median*:
    - Der mittlere Wert.
    - Nützlich wenn *outlier* vorliegen, da diese den *median* nict beeinflussen
  - *Mode*:
    - Der häufigste Wert.
    - Wird häufig bei *qualitative variables* verwendet

Spread of distributions (Streuung)

- *Spread of distributions*:
  - Mißt den **relevanten Wertebereich** einer Variable
- Relevante *statistics* sind:
  - The *range* (Spannweite):
    - Die Differenz zwischen dem höchsten Wert (dem Maximum) und dem niedrigsten Wert (dem Minimum) einer Variable.
  - *Inter-quantile ranges* (Interquartilsbereiche):
    - Die Differenz zwischen zwei *quantiles*, z.B. dem dritten *quartile* (dem 75. *percentile*) und dem ersten *quartile* (dem 25. *percentile*).
  - *Inter-decile range*:
    - Gibt die Differenz zwischen dem 90. *percentile* und dem 10. *percentile* an.
    - Geeignet um den Wertebereich zu identifizieren, in dem sich der Großteil der *observations* (ohne *extreme values*) befindet.

Standard deviation (Standardabweichung)

- Die *variance* (Varianz)
  - Durchschnittliche quadrierte Unterschied jedes beobachteten Werts vom Mittelwert
  - Nicht sehr intuitiv, aber einfach zu handhaben, da selbst ein Durchschnittswert

$$Var[x] = \frac{\sum(x_i - \overline{x})^2}{n} \tag{4}$$

- *Standard deviation* ist die Quadratwurzel der *variance*.
  - Das am häufigsten verwendete Maß für die Streuung (*spread*)
  - Erfasst den typischen Unterschied zwischen einer zufällig ausgewählten Beobachtung und dem Mittelwert (in der gleichen Maßeinheit wie $x \Rightarrow$ **intuitiv**).

$$Std[x] = \sqrt{\frac{\sum(x_i - \overline{x})^2}{n}} \tag{5}$$

  - `sum x`

Skewness (Schiefe)

- Eine *distribution* ist ***skewed*, wenn sie nicht symmetrisch ist**.
  - Sie kann auf zwei Arten asymmetrisch *asymmetric* sein:
    - *left-skewed*, d.h. mit einem *long left tail* oder
    - *right-skewed*, d.h. mit einem *long right tail*.
  - Beispiel:
    - Einige wenige Hotels mit sehr hohen Preisen resultieren in einem *long right tail*.
- *Skewness* und *extreme values*
  - Bei Verteilungen mit *long tails* sind Werte, die weit vom Zentrum (*extreme values*) oder sogar allen anderen Werten (*outlier*) entfernt sind wahrscheinlicher.
  - Wenn *extreme values* für die Analyse wichtig sind, ist auch die Schiefe der *distribution* wichtig.

Skewness (Schiefe)

- Die einfachste Maßzahl ist die *mean-median measure of skewness*:

$$Skewness = \frac{(\overline{x} - median(x))}{Std[x]} \tag{6}$$

- Wenn die *distribution* symmetrisch ist, sind der *mean* und der *median* identisch.
  - Bei einem *long right tail*
    - ist der *mean* größer als der *median*.
  - Wenn eine *distribution* einen *long left tail* aufweist
    - ist *mean* kleiner als *median*.
  - Für eine bessere Vergleichbarkeit verwenden wir eine standardisierte Maßeinheit
    - Normalisierung um die *standard deviation*.
  - Nerdwissen:
    - *"mean-median measure of skewness"* $\times 3 =$ *"Pearson's second measure of skewness"*, da $mean - mode \approx 3 \times (mean - median)$

Vienna vs London

- Wir wollen vergleichen wie sich die Hotelmärkte in zwei Städten unterscheiden.
  - Wien vs. London
- Wir verwenden das `hotels-europe` Datenset.
  - Eingrenzung auf Jahr 2017, November, unter der Woche, 3-4-Sterne-Hotels, nur "Hotels" (keine Apartments), unter 1000 Dollar.
    - `keep if year==2017 & month==11 & weekend==0 & accommodation_type== "Hotel" & stars>=3 & stars<=4`
  - Dazu beschränken wir uns auf Beobachtungen in *actual city*=Vienna ODER *actual city*=London (schließen Sie nahegelegene Dörfer aus).
    - `keep if city_actual== "Vienna" | city_actual=="London"`
- N=207 für Vienna, N=435 für London

London vs Vienna

Figure: Vienna Austria

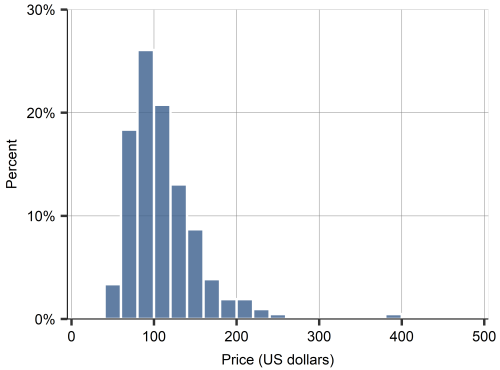
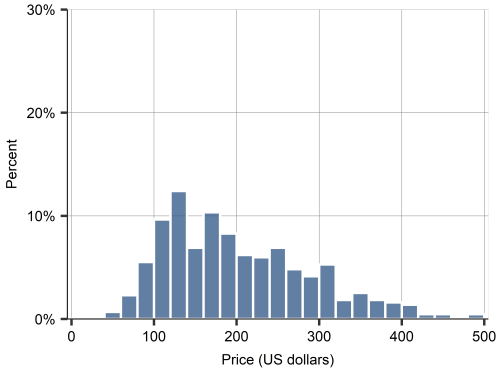


Figure: London, UK



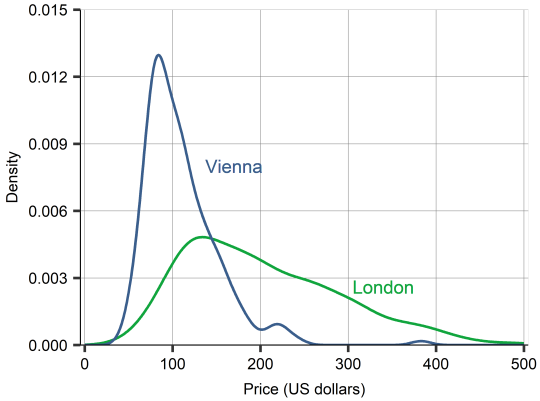
Density plots

- *Density plots*
  - auch als *kernel density estimates* (Kerndichteschätzungen) bezeichnet
    - `kdensity x`
- Alternative zu Histogrammen
  - anstelle von Balken zeigen Density Plots **kontinuierliche Kurven**.
  - Kurven, die sich um die entsprechenden Histogramme legen.
- Kann für den direkten Vergleich nützlich sein
  - Mehrere *distributions* in einer Abbildung
  - Kurven sind geglättet und daher schneller zu erfassen

The density plot

- Density Plot
- Wengier Information als Histogramm
- Aber oft klareres Muster
- Gut für vergleiche geeignet

Welche Stadt hat:
i) höheren *mean*
ii) höhere *standard deviation*
iii) höhere *skewness*



Case study hotels: descriptive statistics

Table: Descriptive statistics for hotel prices in two cities.

City	N	Mean	Median	Min	Max	Std	Skew
London	435	202.36	186	49	491	88.13	0.186
Vienna	207	109.98	100	50	383	42.22	0.236

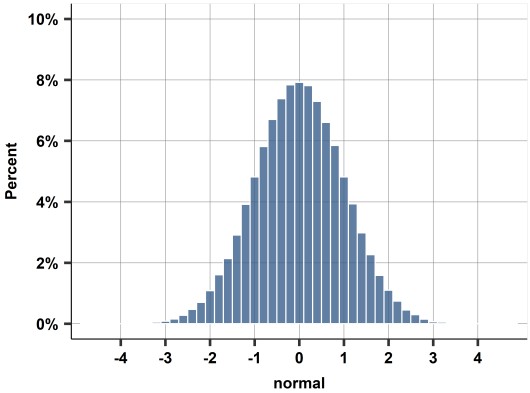
Source: `hotels-europe` dataset. Vienna and London, weekday, November 2017

Theoretical distributions (Theoretische Verteilungen)

- **Theoretische Verteilungen**
  - Beschreiben Variablen in einer idealisierten, abstrakten Umgebung.
  - Sie zeigen, mit welcher *likelihood* verschiedene Werte auftreten.
  - Man kann sie als hypothetischen *Datensatz* oder als *population* verstehen.
- Sie werden durch wenige *parameters* bestimmt.
  - Diese *parameters* beschreiben zentrale Eigenschaften der gesamten Verteilung.
  - Beispiele sind *mean* und *standard deviation* bei der Normalverteilung.
- **Sind nützlich?**
  - Ihre *properties* sind gut bekannt.
  - Wir können diese Eigenschaften nutzen, wenn sie Variablen gut approximieren.
  - Wichtig für *generalizing from data* — Thema 05.

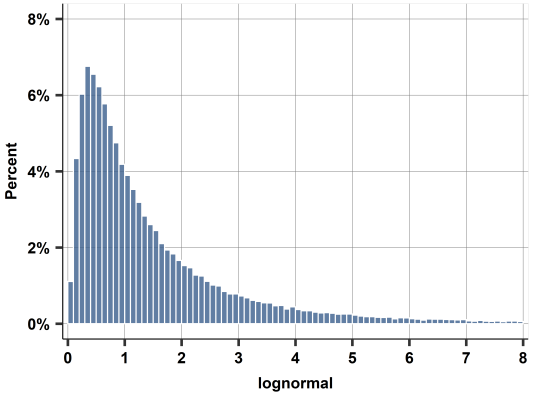
The Normal distribution (Standardnormalverteilung)

- Das Histogramm hat eine *bell-shaped* (glockenförmige) Form
  - *outcome* (Ereignis) kann jeden Wert annehmen
- Die Verteilung wird von zwei Parametern bestimmt
  - μ ist der *mean*
    - *median* und Auch *mode*
  - σ die *standard deviation*
- Beispiele:
  - **Körpergröße, IQs**



The log-normal distribution (Logarithmische Normalverteilung)

- Asymmetrisch verteilt
  - *long right tails*.
- Um log-normal Variable zu erstellen:
  - von einer *normally distributed random variable* (normalverteilte Zufallsvariable) X ausgehen,
  - diese wie folgt transformieren: e^x
  - Die *log-normal* verteilte Variable ist immer nicht-negativ
- Beispiele:
  - **Einkommen, Unternehmensgröße**



Normal vs. log-normal

- Viele Variablen im wirklichen Leben ähneln einer ***normal distribution***
  - Insbesondere, wenn sie sich aus Prozessen ergeben die **additiv** sind
  - Schlecht bei Asymmetrie und *extreme values*
- Variablen werden gut durch die ***log-normal distribution*** approximiert, wenn sie
  - wenn sie sich aus Prozessen ergeben die **multiplikativ** sind
  - der natürliche Logarithmus von ihnen ist also eine Summe
- Einfach mal ausprobieren (do file anfertigen):

```
clear
set obs 1000
gen outcome = runiform(0.95 ,1.05)
forval num =1/1000 {
gen var‘num’ = runiform(0.95 ,1.05)
 replace outcome = outcome + var‘num’
}
hist outcome
```

```
clear
set obs 1000
gen outcome =runiform(0.95 ,1.05)
forval num =1/1000 {
gen var‘num’ =runiform(0.95 ,1.05)
replace outcome = outcome * var‘num’
}
hist outcome
```

Income and log-income

Figure: income

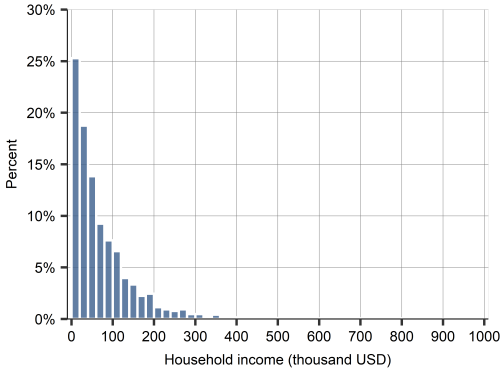
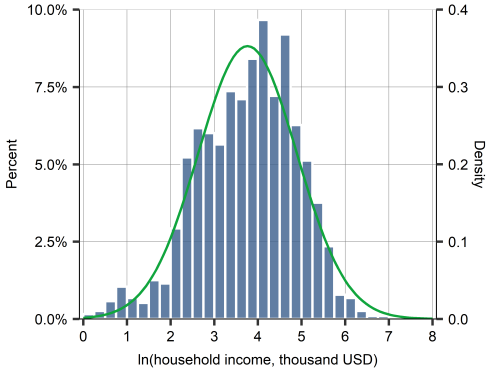
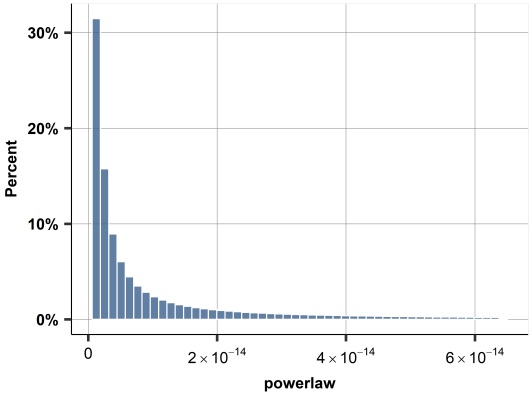


Figure: log income



Power law distribution

- Auch Pareto-Verteilung genannt
  - Sehr große *extreme values* werden gut approximiert
  - *Scale-invariant*: Durch Multiplikation bleiben Werte relativ zueinander unveraendert
  - Häufig eine gute approximation fuer ein *long tail*
- Beispiele
  - **Häufigkeit von Wörtern, Bevölkerung von Städten, Vermögen**



Data visualization (Datenvisualisierung)

- **Zu wichtig, um sich von Standardeinstellungen leiten zu lassen!**
- Worauf kommt es an?
  1. *usage* (Verwendung): was Sie zeigen möchten und für wen - Entscheidung über Zweck, Fokus und **Zielgruppe**
  2. *ecoding* (Codierung): Schlüsselelemente der Diagramme, die zeigen, wie Sie Ihre **Botschaft** präsentieren möchten
  3. *scaffolding* (Gerüst): wie Sie Elemente präsentieren möchten, die das **Verständnis** unterstützen, wie Achsen und Legenden
  4. *annotation* (Annotation): was Sie hinzufuegen, um bestimmte Elemente zu **betonen**

Data visualization: usage

- Welche Botschaft möchten Sie vermitteln?
  - Generell sollte **ein Diagramm eine Botschaft** vermitteln.
- Wer ist die Zielgruppe?
  - allgemeines Publikum vs. Fachpublikum.
- Generell gilt:
  - Einfacher ist besser.
  - Für ein Fachpublikum sind kompliziertere Diagramme oft in Ordnung
    - Aber auch Fachleute möge eine klare Botschaft
  - Jede Abbildung sollte **selbsterklärend** sein!
    - Notfalls mit Hilfe der *notes*

Data visualization: encoding

- Wie Sie Ihre Botschaft vermitteln.
  - Auswahl des **Diagrammtyps** (*graph type*), zusätzliche Merkmale und Farben.
    - *Graph type*: *bar chart* (Balkendiagramm), *scatter plot* (Streudiagramm) usw.
    - Wie Informationen dargestellt werden (*dots* (Punkte), *lines* (Linien), *bars* (Balken))
  - *encoding* zur Vereinfachung von Vergleichen
    - z.B. *bar charts* für separate Gruppen unter Verwendung unterschiedlicher **Farben**.
- Generell gilt:
  - **Eine Information, ein *encoding***
    - Es kann aber Sinn machen, neben Informationen nicht nur über Farben sondern auch über **Formen** zu encoden (schwarzweiss Druck, Farbenblindheit)

Data visualization: scaffolding

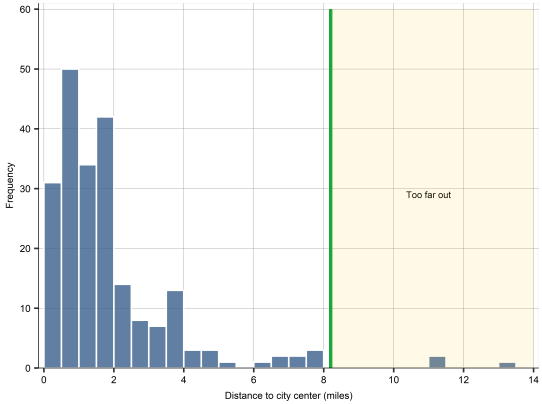
- Wie Sie Elemente präsentieren, die das **Verständnis unterstützen**
  - Stellen Sie sicher, dass ein Diagramm Folgendes enthält:
    - Titel
    - Achsentitel und verständliche Beschriftungen!!!
    - Legende
    - **Notes**
  - Gute Lesbarkeit:
    - Inhalt sowie Formatierung wie Schriftart und -größe.
  - *Notes* (Anmerkungen)
    - Alles was zum Verständnis notwendig ist, anführen
- **Jede Abbildung sollte selbsterklärend sein**.
  - Ihre Nachbarn sollten die Abbildung ohne weitere Erklärung verstehen können

Data visualization: annotations

- Wenn es noch etwas gibt, das Sie betonen möchten...
  - zusätzliche Hinweise können nützlich sein, insbesondere um
  - **einen bestimmten Aspekt der Informationen zu betonen**:
    - Eingefärbter Bereich
    - Umkreiste Beobachtungen
    - Pfeil
    - Text
    - usw.

Data visualization: Beispiel

- Usage:
  - Die Verteilung Enfernungen von Hotels zum Stadtzentrum fuer eine *general audience* (breites Publikum) darstellen
- Encoding:
  - Als *graph type* wird ein *bar chart* (histogram) gewählt, mit einer bin size von 0.5
- Scaffolding:
  - Achsen klar beschriftet mit Titel und Dimension (miles) + *grid* (Gitter)
- Annotation:
  - Hotels, die aussergewöhnlich weit entfernt sind, werden optisch abgesetzt



Zusammenfassung

- EDA ist der **Startpunkt** der eigentlichen empirischen Untersuchung
  - Hilft dabei, die Daten zu beschreiben und die Analyse zu planen
  - Kann abe rauch dazu führen, dass weitere Datenarbeit notwendig wird
- **Überprüfen** Sie immer Ihre wichtigsten **Variablen** mit Sorgfalt.
  - Betrachten Sie *summary statistics*, um wichtige Merkmale zu verstehen
    - *central tendency*, *spread* und *skewness*
- Werfen Sie einen Blick auf **Histogramme**
  - um ein Bild der Verteilung zu erhalten
  - zu prüfen, ob es mehrere *modes* oder *extreme values* gibt.
- **Der erste Eindruck zählt**
  - Datenvisualisierung muss besonders sorgfältig durchgeführt werden.