04 Vergleiche and Korrelationen

Gabriel M Ahlfeldt

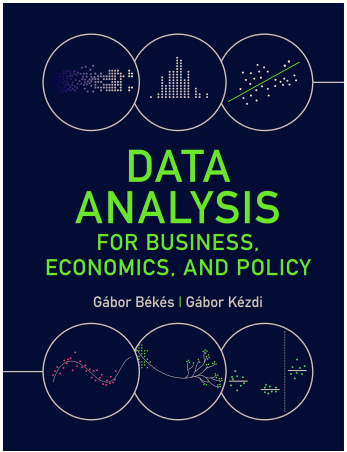
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 04**

Motivation

- **Werden größere Unternehmen besser gemanagt?**
- Um diese Frage zu beantworten, haben wir **Daten aus dem World Management Survey** heruntergeladen
  - Wie sollten wir die Daten verwenden, um die Unternehmensgröße und die Qualität des Managements zu messen?
  - Wie können wir bewerten, ob größere Unternehmen besser gemanagt werden?



Das y und das x

- **Vergleich der Werte einer y-Variable mit den Werten einer x-Variable**
  - oder mehrerer x-Variablen.
  - Oft das Herz der Datenanalyse
- Ziel ist es, die **patterns of association** (Assoziationsmuster) zu erkennen
  - ob Beobachtungen einer Variabe y dazu tendieren, bestimmte Werte annehmen, wenn die x Variable bestimmte Werte annimmt
- **Wir sind in erster Linie an dern Werten von y interessiert**
  - Heute: Qualität des Managements
- **Wir vergleichen Beobachtungen, die sich in ihren x-Werten unterscheiden**
  - Heute: Die Unternehmensgröße

Das y und das x

Wenn wir y und x in Beziehung setzen, können wir **zwei Ziele** verfolgen.

1. ***Prediction*** (Vorhersage) des Werts einer *y*-Variable
   - Mit Hilfe einer *x*-Variablen oder mehrerer Variablen wie x_1, x_2, ...
     - Wenn wir die Werte der *x* kennen, aber nicht den Wert der *y*-Variable.
   - Beispiel
     - Wie kann ich den Marktwert einer Immobilie im Ist-Zustand bestimmen?
2. Den ***causal effect*** (kausalen Effekt) einer Veränderung in *x* auf *y* verstehen.
   - Entscheidend für *counterfactuals* (kontrafaktische Analysen)
     - Wenn wir wissen wollen welchen Wert *y* haben würde, wenn wir *x* ändern würden.
   - Beispiel
     - Was wäre der Marktwert einer Immobilie wenn es einen U-Bahnanschluss gäbe?

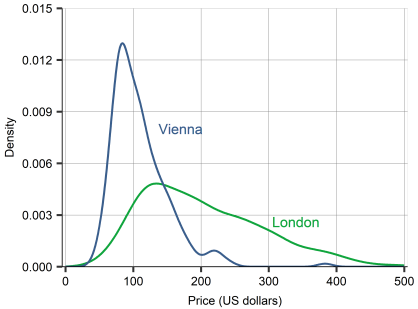
Comparison and conditioning (Vergleich und Konditionierung)

- Wir vergleichen y anhand der Werte von x
  - wir **konditionieren** (*condition*) y auf x oder
  - finden y *gegeben* x.
    - $y \rightarrow$ *outcome variable* (Ergebnisvariable).
    - $x \rightarrow$ ist die *conditioning variable* (konditionierende Variable).

- Wir haben die Preise von Hotels (y) in verschiedenen Städten (x) verglichen $\rightarrow$
  - Preis des Hotels ist das *outcome*.
  - Die Art der Stadt ist die *conditioning variable*.

Conditional distributions (Bedingte Verteilungen)

- Die ***conditional distribution*** einer Variablen
  - ist die Verteilung der *outcome variable* unter Berücksichtigung der *conditioning variable*.
- Einfach, wenn die *conditioning variable* qualitativ ist, insbesondere wenn sie binär ist.
  - Z.B. Vergleich anhand von *histograms* oder *density plots*, separat für verschiedene Städte



Conditional statistic (Bedingte Statistik)

- *conditional mean* (bedingter Mittelwert)
  - *mean* einer Variablen für jeden Wert der *conditioning variable*.
- Die *conditional expectation* (bedingter Erwartungswert) der Variable y für verschiedene Werte der Variable x ist

$$E[y|x]$$

- Dies ist eine Funktion
  - Für einen Wert von x gibt die *conditional expectation* eine Zahl an, die den erwarteten Wert der Variable y für Beobachtungen angibt, die diesen x-Wert haben.
  - **Liefert den y-Wert, den wir für gegebenen x-Wert erwarten**.

Conditional means darstellen

- Ein ***scatterplot*** ist ein zweidimensionaler Graph
  - Die **Werte jeder der beiden Variablen sind auf den beiden Achsen** aufgetragen
    - Jede Beobachtung im Datensatz ist ein Punkt mit den ensprechenden x/y Werten.
  - Funktioniert gut, wenn der Datensatz relativ klein ist.
    - `scatter y x`
- "Bin scatter"
  - Bei größeren Stichproben können wir Werte in *bins* (Behälter) gruppieren
  - Ein *bin scatter* zeigt bedingte Mittelwerte für die von uns erstellten Bins.
    - `binscatter y x`

Management quality and firm size

- Kontext
  - Einige Unternehmen werden besser gemanagt werden als andere—warum?
  - Große und kleine Unternehmen könnten sich unterscheiden...
- Konkrete Forschungsfrage
  - **Werden größere Unternehmen besser gemanaged?**
    - Zusammenhang zwischen x (Größe) und y (Managementqualität)
    - Forschungsfrage mit ökonometrischen Methoden **grundsätzlich beantwortbar**
  - Wir können Daten aus dem World Management Survey verwenden
    - Forschungsfrage **empirisch beantwortbar**

Management quality and firm size

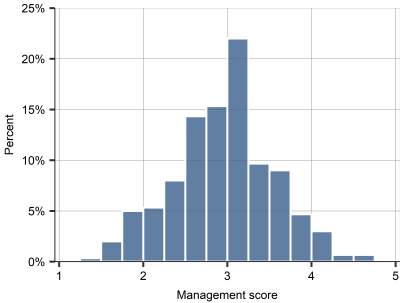
- Interviews mit CEOs/leitenden Manager
  - Auf der Grundlage wird eine Bewertung vorgenommen.
  - Die Managementqualität wird als *score* quantifiziert.
- Jede ***score*** ist eine **Einschätzung** einer Managementpraktik durch den Interviewer
  - verschiedene Bereiche
  - tracking von Performancezielen
  - Zeithorizont und Breite der Ziele usw.
  - Gemessen auf einer **Skala von 1 (schlechteste Praxis) bis 5 (beste Praxis)**

Management quality and firm size

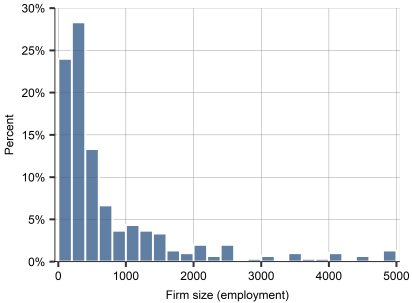
- Unser y ist die *management score*
  - einfach der *average* (Durchschnitt) der 18 speizfischen scores
  - Konstruktionsbedingt ist der Wertebereit 1 bis 5
- Unser x ist die Unternehmensgröße
  - Gemessan an der Anzahl der Mitarbeiter
- Sample
  - *cross section* von **mexikanischen** Unternehmen aus der Umfrage des Jahres 2013
  - Nur Unternehmen mit 100 bis 5000 Mitarbeitern werden Beruecksichtigt
  - N=300

Management quality and firm size

(a) Management score



(b) Firm size (number of employees)



Note: *Source: Management quality is an average score of 18 variables. Firm size is number of employees.* `wms-management-survey` *data. Mexican sample, n=300.*

Management quality and firm size

- *Descriptive statistics*
  - `sum management emp_firm, detail`
- Management Score:
  - Der *mean* beträgt 2,94, der *median* liegt bei 2.94, die *standard deviation* beträgt 0,6
  - Keine *skewness* (*mean* $\approx$ *median*)
- Unternehmensgröße:
  - Die *range* der Beschäftigung reicht von 100 bis 5000
  - Der *mean* beträgt 761, der *median* liegt bei 353, die *standard deviation* beträgt 977
  - Es besteht *skewness* mit einem *long right tail* ($\frac{761-353}{977} = 0.42$)
    - `sum emp_firm, d`
    - `display (r(mean)-r(p50))/r(sd)`
  - Es gibt einige große Unternehmen, aber keine *outlier* (innerhalb des ausgewählten Wertebereichs).

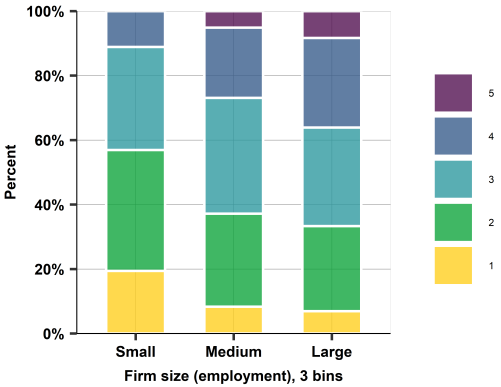
Management quality and firm size

- *Conditional probabilities*
  - Wir erzeugen drei *bins* nach Unternehmensgroesse:
    - klein (100-199, N=72), mittelgroß (200-999, N=156), groß (1000-5000, N=72)
  - Wir betrachten folgende *score*
    - *Lean management score*, mit den Werten 1,2,3,4,5.
  - **Für eine *score* Variable, haben wir 15 conditional probabilities**
    - die Wahrscheinlichkeit für jeden der 5 Werte von y (*score*) gegeben jeden der drei Werte von x (*bins*)— z.B. $P(y = 1|x = small)$.

Management quality and firm size

- Lean management score 1–5
- Drei *firm size bins*
- *Conditional probability*:
  - *share* (Anteil) score=1 *conditional on* (gegeben dass) *firm size* = *small* ist etwa 20%.
  - *share* (Anteil) score=5 *conditional on* (gegeben dass) *firm size* = *large* ist etwa 10%.

Q: Werden größere Firmen besser gemanaged?

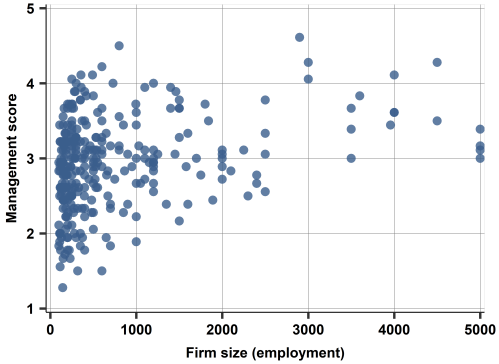


Note: *Source: Management quality is an average score of 18 variables. Firm size is number of emoployees.* `wms-management-survey` *data. Mexican sample, n=300.*

Management quality and firm size

- *Conditional statistic*: ***conditional mean***
  - Wir können den ***mean* in Abhängigkeit** von der Unternehmensgröße berechnen.
    - Drei Gruppen nach Mitarbeiteranzahl
    - klein (100–199, N=72), mittelgroß (200–999, N=156), groß (1000–5000, N=72).
  - Die *mean* Management-Score beträgt
    - 2,68 für kleine Unternehmen
    - 2,94 für mittelgroße Unternehmen
    - 3,18 für große Unternehmen.
- Bestätigt visuellen Ersteindruck:
  - **Größere Unternehmen haben bessere Managementpraktiken**

Management quality and firm size



- *Scatterplot*
  - x und y Variablen sind *quantitative*
  - Jeder Punkt (*dot*) ist eine Beobachtung.
  - Alle in den Daten zur Assoziation enthaltenen Informationen werden in dem Graph dargestellt.
- **Positiven Zusammenhang** "mit bloßem Auge" erkennen
  - `scatter management emp_firm`

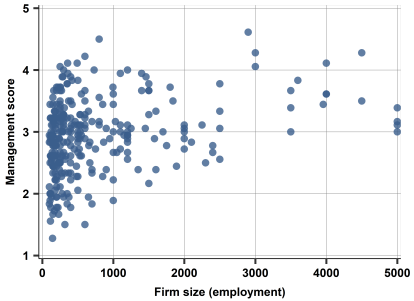
Note: *Source: Management quality is an average score of 18 variables. Firm size is number of employees.* `wms-management-survey` *data. Mexican sample, n=300.*

Management quality and firm size

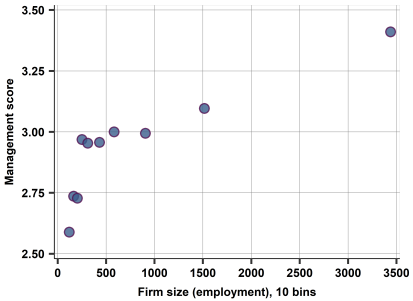
- Für den *bin scatter*
  - **berechnen wir den Durchschnitt von** y **für Werte mit ähnlichen** x
  - tragen wir das durchschnittliche y im *bin* gegen den Mittelpunkt des *bins* (z.B. 110 für en Bin 100–120) in den *scatterplot* ein
- Wir wählen 10 *bins*, jeder mit einer gleichen Anzahl von Unternehmen (*deciles*)
  - Punkte sind NICHT gleichmäßig verteilt—*deciles* in *right tail* haben eine größere *range*
    - `binscatter management emp_firm, nq(10)`
  - Wir könnten die bins aber auch so wählen dass alle die gleiche *range* haben, z.B. 500:
    - `gen FSbin = round(emp_firm, 500)`
    - `egen MAbin = mean(management), by(FSbin))`
    - `scatter MAbin FSbin`

Management quality and firm size

(a) Scatterplot



(b) 10 Bin-scatter



Note: *Source: Management quality is an average score of 18 variables. Firm size is number of employees.* `wms-management-survey` *data. Mexican sample, n=300.*

Management quality and firm size

- *Scatterplot* deutet positiven Zusammenhang an
  - Aber viel Variation in y für Werte mit ähnlichen x
  - Der x-y Zusammenhang ist dadurch weniger deutlich zu erkennen
- *Bin scatter*
  - Enthält weniger Information, aber leichter zu lesen.
  - Positiver Zusammenhang, vor allem für klein vs. mittelgross.
- *Smoothing*:
  - **Weniger *bins* $\rightarrow$ geringere Unterschiede in y, die aber leichter zu erkennen sind**

Dependence & independence (Abhängigkeit & Unabhängigkeit)

- Wir wollen die stärke des Zusammenhangs erfassen
  - In einer quantitativen *statistic* zusammenfassen
- *Dependence* (Abhängigkeit) von zwei Variablen y und x
  - **Die *conditional distributions* von y für verschiedene gegebene x sind nicht gleich** (x ist die *conditioning variable*).
- *Independence* (Unabhängigkeit) von y und x bedeutet das Gegenteil:
  - Die Verteilung von y ist unabhängig vom Wert von x immer gleich.
- Die *Dependence* von y und x kann viele Formen annehmen...

Mean dependence

- *Mean-dependence*
  - ***conditional expectation*** $E[y|x]$ **verändert sich mit dem Wert, den** x **annimmt**.
  - das Ausmaß, in dem sich *conditional expectation* (*means*) unterscheiden.
- Zwei Variablen sind positiv *mean dependent* (mittelwertsabhängig)
  - wenn der *mean* einer Variablen tendenziell größer ist,
  - wenn der Wert der anderen Variablen ebenfalls größer ist.
- Typische Maße
  - *Covariance* (Kovarianz)
  - *Correlation coefficient* (Korrelationskoeffizient)

Covariance (Kovarianz)

- *Covariance* zwischen zwei Variablen x und y bei n *observations*:

$$Cov[x, y] = \frac{\sum_i (x_i - \overline{x})(y_i - \overline{y})}{n} \tag{1}$$

  - $i = 1 \ldots n$ indiziert Beobachtungen in unserer *data table*
- Intuitiv:
  - Wir **multiplizieren Abweichungen von Durchschnittswerten**
    - von x vom eigenen Durchschnitt $(x_i - \bar{x})$
    - von y vom eigenen Durchschnitt $(y_i - \bar{y})$
  - Die *covariance* ist der **Durchschnitt dieser Produkte** über alle Beobachtungen hinweg.
- **Wenn die Abweichungen von den Durchschnittswerten im Mittel in die gleiche Richtung zeigen, ist die *covariance* positiv**

Correlation coefficient (Korrelationskoeffizient)

$$Corr[x, y] = \frac{Cov[x, y]}{Std[x]Std[y]} \tag{2}$$

$$-1 \leq Corr[x, y] \leq 1 \tag{3}$$

- **Der *correlation coefficient* ist die standardisierte Version der *covariance***
  - Die *covariance* ist abhängig von den Dimensionen von y und x
  - Der *correlation coefficient* **immer zwischen -1 und 1**
- **Intuitiver zu interpretieren** also die *covariance*

Dependence, correlation

- ***Covariance* oder *correlation coefficient* gut für *quantitative variables* geeignet**
  - Differenzen $y_i - \bar{y}$ und $x_i - \bar{x}$ ergeben mehr Sinn, wenn y und x quantitativ sind.
- Können grundsätzlich auch für andere Arten von Variablen berechnet werden
  - z. B. *binary variables*, aber andere Maße sind dann geeigneter

Management quality and firm size

- Die *covariance* zwischen Firmengröße und der Management-Score beträgt 177.
  - `corr management emp_firm, cov`
- Die *standard deviations* betragen
  - Firmengröße: 977
  - Management-Score: $0,6$.
  - `sum management emp_firm`
- Der *correlation coefficient* beträgt $177/(977 \cdot 0,6) = 0,30$.
  - **Positive und mäßig starke ausgeprägte** *mean dependency*
  - `corr management emp_firm`

Gehe zu `https://pingo.coactum.de`, *access number* 435578

Management quality and firm size

Table: Measures of management quality and their correlation with size by industry

Industry	**Management–employment correlation**	**Observations**
Auto	0.50	26
Chemicals	0.05	69
Electronics	0.33	24
Food, drinks, tobacco	0.05	34
Materials, metals	0.32	50
Textile, apparel	0.29	43
Wood, furniture, paper	0.28	29
Other	0.44	25
All	0.30	300

Note: *Employee retention rates: The probability of staying with the firm, in the two experimental groups. Source:* `working-from-home` ***dataset***

Erfassung eines latenten Phänomens mit vielen beobachteten Variablen

- *Latent variables* (Latente Variablen)
  - Wir messen ein Phänomen **nicht direkt**, sondern indirekt über verschiedene Variablen
  - Kommt häufig vor, z.b. IQ
- Zur Messung von Managementqualität haben wir
  - 18 *scores* gemessen
  - Diese zusammengefasst, in dem wir den Durschnitt über alle *scores* gebildet haben.
  - Das war unproblematisch, weil **alle *scores* auf einer Skala von 1-5** gemessen wurden
- Doch was tun wenn Variablen **in unterschiedlichen Einheiten** gemessen werden?

Z-Score

- *Standardizing* (Standardisieren)
  - Überführung von Variablen **in die gleichen Einheiten**
  - Notwendig wenn wir Variablen in unterschiedlichen Einheiten Aggregieren wollen
  - Die standardisierten Variablen können wir dann zusammenfassen
    - z.B. in dem wir den Mittelwert bilden
- *Z-Score*
  1. *mean* abziehen
  2. Division durch *standard deviation*
  - Ergibt eine Variable mit *mean* von Null und *standard deviation* von Eins
    - `sum emp_firm`
    - `gen Z_emp_firm = emp_firm-r(mean)`
    - `replace Z_emp_firm = Z_emp_firm/r(sd)`
    - `sum emp_firm`

Causality (Kausalität)

- Oftmals sind wir an einem kausalen Effekt von x auf y interessiert
  - Wie wird sich y ändern, wenn wir x ändern?
- ***Mean dependency* läßt per se keine kausalen Schlussfolgerungen zu**
  - Positive Korrelation zwischen Unternehmensgröße und Managementqualität bedeutet nicht automatisch, dass Managementqualität zunimmmt, wenn wir mehr Leute einstellen
- Was ist die *source of variation* (Quelle der Variation) in der *conditioning variable*?
  - Hängt davon ab wie die Daten erhoben wurden
    - Option 1: *experimental data* (Experimentelle Daten) - unter Kontrolle der Forschenden
    - Option 2: *observational data* (Beobachtungsdaten) - außer Kontrolle der Forschenden

Vergleiche in *experimental data*

- In Experimenten gibt es *controlled variation*
  - **Wir können die Variation in x gezielt herbeiführen**
    - Der Wert der *conditioning variable* unterscheidet sich zwischen den Beobachtungen, weil die Person, die das Experiment durchgeführt hat, die Unterschiede bewusst herbeigeführt hat.
    - Daher der Name: *treatment variable* ('Behandlungsvariable')
    - Typischer Weise wird das *treatment* zufällig verabreicht (*radomized*)
- **Klare Ursache-Wirkung Beziehung: *correlation = causation***
  - Klassische Anwendung: Medikamententest
  - Zufällige Vergabe von *Treatment* vs. Placebo
- In BWL/VWL/Wirtschaftspolitik schwierig.
  - Wie sollen wir die Firmengröße randomisieren?

Vergleiche in *observational data*

- *Observational data*
  - Aus Ereignissen entstanden, die nichts mit unserer Untersuchung zu tun haben
    - **Keine Variable vollständig kontrolliert**
  - Die Quelle der Variation in diesen Variablen kann mehrere Ursachen haben.
    - Entscheidungen, Interaktionen, Erwartungen der Menschen usw.
- **Keine klare Ursache-Wirkung Beziehung: *correlation* $\neq$ *causation***
  - Veränderungen in den Werten der *outcome variable* und der *conditioning variable* werden beide von dritten Faktoren herbeigeführt (*spurious correlation*)
  - Die *outcome variable* könnte die *conditioning variable* beeinflussen (*reverse causality*)
- Die meisten Daten in BWL, VWL und Politikanalyse sind *observational data*
  - Wir brauchen Methoden der *causal inference*
    - *Empirical Economics: Causal Impact Analysis* Vorlesung oder ***Applied Econometrics***

Zusammenfassung

- Für *qualitative variables*
  - kann die *correlation* durch die Zusammenfassung der *conditional probabilities* (frequencies) gezeigt werden.
- Für *quantitative variables*
  - bieten *scatter plots* einen visuellen Eindruck des empirischen Zusammenhangs.
- Der *correlation coefficient*
  - ist eine einfache Maßzahl für *mean dependency*.
- Vorsicht mit kausalen Interpretationen
  - In *observational data* gilt generell ***correlation*** $\neq$ ***causation***