05 Verallgemeinerung aus Daten

Gabriel M Ahlfeldt

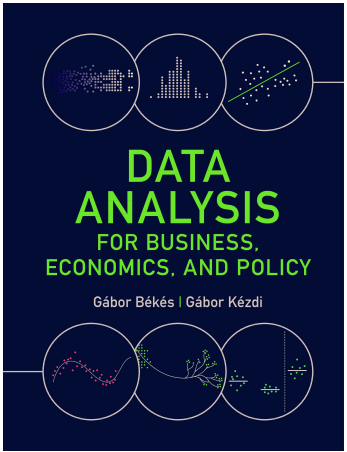
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 05**

Motivation

- ***Wie wahrscheinlich ist es, dass wir Verluste in unserem Anlageportfolio erleben werden?***
  - *Um diese Frage zu beantworten, haben wir historische Renditedaten gesammelt und analysiert.*
  - *Um die Häufigkeit von Verlusten einer bestimmter Größenordnung für das kommende Kalenderjahr vorherzusagen, müssen wir darüber nachdenken in wie weit die beobachteten Daten ein allgemeines Muster (**general pattern**) repräsentieren und inwieweit dieses general pattern auf die Zukunft übertragbar ist.*

Gehe zu `https://pingo.coactum.de`, *access number* 613586

Generalization (Verallgemeinerung)

- Unter Umständen sind wir nur an dem **vorliegenden Datensatz** interessiert
  - Wir haben eine gewisse Auswahl an Hotels in Wien vorliegen
  - Aus dieser Auswahl wollen wir das mit dem niedrigsten Preis finden
- Häufig reicht uns dies nicht
  - Wir wollen den durchschnittlichen Hotelpreis (in Wien) herausfinden
  - Würden wir das Ergebnis mit anderen Daten (samples) auch erhalten?
- ***Generalisation*** **(Verallgemeinerung)**
  - Die Verallgemeinerung der Muster in einem Datensatz auf andere Situationen wird als ***inference*** (Inferenz) bezeichnet
  - Wir schließen aus unseren Daten auf ein allgemeineres Phänomen, weil wir dieses Wissen auch jenseits des vorliegenden Datensatzes anwenden wollen.

Generalization (Verallgemeinerung)

- ***Statistical Inference* (statistische Infernez)**
  - Oftmals analysieren wir einen Datensatz, um *allgemeine Muster* zu finden
    - Dieses *allgemeine Muster* is grundsätzlich kontextspezifisch, z.B. Wien
  - Fallen Hotelpreise generell in Wien, wenn wir uns vom Stadtzentrum entfernen?
    - Wir sind nicht nur an den Hotels im Datensatz interessiert, sondern an Hotels in Wien
    - Wie wahrscheinlich ist, dass das Muster in unseren Daten allgemein in Wien gilt?
- ***External validity* (externe Validität)**
  - Ist ein *general pattern* auch auf andere Kontexte übertragbar?
    - Gilt das Preis-Distanzmuster, dass wir in Wien finden, auch in anderen Städten?

General patterns 1: Population and representative sample

- Unsere Daten vs. *general pattern*
  - **Wir gehen davon aus, dass unsere Daten ein *general pattern* repräsentieren**
- Das *general pattern* ist erstmal ein abstraktes Konstrukt
  - Kann existieren oder nur hilfreich sein, um Tools der *statistical inference* anzuwenden
- Beispiel: **Ein *sample*, dass aus einer *population* gezogen wurde**
  - Das *general pattern* bezieht sich auf alle Hotels in Wien
  - Das *sample* sind die Hotels in Wien, die wir beobachten
    - Das *sample* wurde zufällig gezogen (nicht nach bestimmten Merkmalen)
    - Sonst kann es das *general pattern* nicht repräsentieren
  - Idealtypisches Szenario für *statistical inference*...

General patterns 2: No population but general pattern

- Das Konzept des *general pattern* ist nicht immer so eindeutig
  - Sehr häufig wurde keine zufällige Stichprobe gezogen
- Viele Arten wie wir uns das *general pattern* vorstellen können
  - Es gibt ein *general pattern*, jedes Jahr ist eine **zufällige Realisierung**.
  - Es gibt ein *general pattern*, jedes Produkt ist eine **zufällige Variante**
  - Wir beobachten die relevante *population*, aber
    - viele **zufällige Ereignisse** hätten zu einer anderen Realisierung des *general pattern* führen können (andere Hotelpreise für alle Hotels in Wien)
    - die beobachtete Realisierung des *general pattern* ist von **zufälliger Meßungenauigkeit** bestimmt
- **Unsere Daten sind eine Realisierung mit einer Zufallskomponente**
  - Brauchen wir, damit wir die Werkzeuge der *statistical inference* anwenden können

External validity (Externe Validität)

- ***External validity* bedeutet die Übertragbarkeit von Erkenntnissen**
  - Nur weil unsere Daten das *general pattern* in unserem Kontext repräsentieren...
  - ...muss das noch lange nicht in anderen Kontexten gelten
    - Was auch immer wir aus unseren Daten lernen, könnte sich für eine andere Anwendung als völlig irrelevant herausstellen.
- **Es gibt keine formalen Weg *external validity* sicherzustellen**
  - Wir müssen abwägen und argumentieren!
- Beispiel Hotelpreise
  - Hotelpreis-Distanz Beziehung könnte in vergleichbaren Städten ähnlich sein
    - Monozentrisch (wie Wien), ähnlich groß, vergleichbarer Tourismus, etc.
  - Schwierig auf Städte zu übertragen, die sich deutlich unterscheiden
    - Berlin hat zwei Zentren (Mitte, Kudamm)

Der Prozess der *inference*

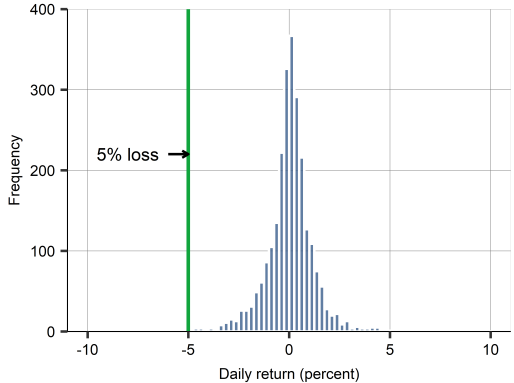
Es ist bewährte Praxis, die *inference* in zwei Teile zu unterteilen:

1. *statistical inference* verwenden, um Informationen über das ***general pattern*** zu gewinnen, **das unsere Daten repräsentieren**
   - 1.1 Betrachten einer *statistic*, die für uns relevant sein könnte, z.B. der *mean*.
   - 1.2 Berechnen des *estimated value* (geschätzten Werts) aus einem Datensatz.
   - 1.3 Ableiten des Bereichs in dem wir den wahren Wert im *general pattern* vermuten
2. Die *external validity* bewerten: Das ***general pattern*** definieren, **an dem wir interessiert sind**, und bewerten, wie es sich zu dem *general pattern* verhält, das unsere Daten repräsentieren.
   - 2.1 Transparente und öknomisch fundierte Diskussion
   - 2.2 Untersuchung der Heterogeneität im *sample* kann helfen

Stock market returns: Inference

- Aufgabe
  - Die **Wahrscheinlichkeit** einschätzen, das wir mit einem Investmentportfolio innerhalb eines Tages einen **Verlust von 5% oder mehr** erleiden
  - Können wir für die **Vorhersage** der *frequency* eines Verlusts in bestimmter Höhe für das kommende Kalenderjahr nutzen
- Daten
  - Das Anlageportfolio ist der S&P 500, ein US-Aktienmarktindex
  - *Daily returns* (Tagesrenditen) des S&P 500, definiert als prozentuale Veränderungen des Schlusskurses des Index zwischen zwei aufeinanderfolgenden Tagen
  - 11 Jahre: 25. August 2006 bis 26. August 2016. Insgesamt 2.519 Tage.

Histogram of daily returns



Note: *S&P 500 market index. Day to day (gaps ignored) changes, in percentage. From August 25 2006 to August 26 2016.*

Stock market returns: Inference

- *Encoden* "Verlust" als **dummy**
  - Eins, wenn der Tagesverlust mehr als 5% beträgt, sonst null
    - `gen loss = pct_return <= -5`
- Die relevante *statistic* in den Daten ist der Anteil der Tage mit solchen Verlusten
  - Dieser beträgt 0,5% in diesem Datensatz (*mean* des Dummies)
    - `sum loss`
  - Das S&P500-Portfolio verlor an 0,5% der Tage zwischen dem 25. August 2006 und dem 26. August 2016 mehr als 5% seines Werts.
- *Inference problem* (Inferenzproblem)
  - Wie können wir diese Erkenntnis verallgemeinern? Was können wir aus dieser 0,5-prozentigen Wahrscheinlichkeit für das **nächste Kalenderjahr** ableiten?

Repeated samples (wiederholte Stichproben)

- Die *statistic* im *general pattern* entspricht nicht genau dem in unseren Daten
  - Jeder Datensatz ist eine zufällige Realisation eines *general pattern*
  - Wir hätten auch eine andere Realisation beobachten können
- ***Repeated samples***
  - der **konzeptionelle Unterbau** der *statistical inference*.
- Wie wir uns das in der Fallstudie vorstellen könnten
  - Wir beobachten 11 Jahre von einer deutlich größeren Zahl an Jahren
  - Unser Datensatz ist eine von vielen möglichen Realisierungen des *general pattern*
    - In Paralleluniversen könnten viele zufällige Ereignisse anders ausgefallen sein
  - Wir gehen davon aus, dass das *general pattern* im nächsten Jahr unverändert bleibt

Repeated samples

- Das Ziel der *statistical inference*
  - den Wert einer *statistic* im *general pattern* zu erfahren
    - Hier der *mean* der *loss* Variable
- **Entscheidend**: Die *statistic* hat eine ***distribution* (Verteilung)**
  - Ihr Wert kann von *sample* zu *sample* variieren.
  - Die *distribution* der relevanten *statistic* ist die ***sampling distribution***
    - Der *mean* unserer *loss* Variable über viele *repeated samples* hinweg
- ***Standard error (SE)* (Standardfehler)**
  - Die ***standard deviation* der *sampling distribution***
    - Wie stark variiert der *mean* von *loss* über die *repeated samples*?
  - Die *statistic* im Sample ist eine Approximation der *statistic* im *general pattern*
    - SE sagt uns den typischen Fehler den wir im Durchschnitt erwarten können

Zur Veranschaulichung der *sampling distribution*...

- ... **können wir nicht aus der wahren *population* (*general pattern*) sampeln**
  - Alternative historische Entwicklungen von Aktienkursen (in z.B. in Paralleluniversen) sind für uns nicht beobachtbar
- Zur Veranschaulichung können wir aber folgendes annehmen
  - **Unser Datensatz ist das *general pattern***
    - der Anteil der Tage mit Verlusten von 5% oder mehr beträgt 0,5%
    - Von nun an der *true value* (wahre Wert)
  - Aus diesem (fake) *general pattern* beobachten wir N (sub) *samples*
    - Jeweils im Umfang von n Tagen täglicher Renditen aus unserem Datensatz.

Was erwarten wir für die *sampling distribution* wenn n gößer wird?
Hinsichtlich *mean*, *skewness*, *standard deviation*

Repeated samples properties (Eigenschaften wiederholter Stichproben)

- Die ***sampling distribution*** hat drei wichtige Eigenschaften:

1. *Unbiasedness* (Unverzerrtheit):
   - Der Durchschnitt der Werte in *repeated samples* entspricht seinem wahren Wert (= der Wert im *general pattern*).
2. *Asymptotic normality* (Asymptotische Normalität):
   - Je größer das *sample*, desto eher folgt die *sampling distribution* einer *normal distribution*.
3. *Root-n convergence* (Wurzel-n-Konvergenz):
   - Die *standard deviation* der *sampling distribution* ist umso kleiner, je größer die *samples* sind, mit einem Proportionalitätsfaktor, der der Quadratwurzel der Stichprobengröße entspricht.

Stock market returns: A simulation

- Wir können die *sampling distribution* wie folgt generieren
  1. Datentabellen mit Beobachtungen im Umfang von **900 Beobachtungen** *sampeln*
     - *Random sampling*: Alle Tage werden nacheinander betrachtet und unabhängig voneinander rein zufällig aus den 2519 Tagen in den Daten ausgewählt
  2. Den Anteil der Tage mit Verlusten von 5% oder mehr berechnen und speichern
- Das machen wir 10,000 Mal und plotten dann die Ergebnisse

Samplen und schätzen

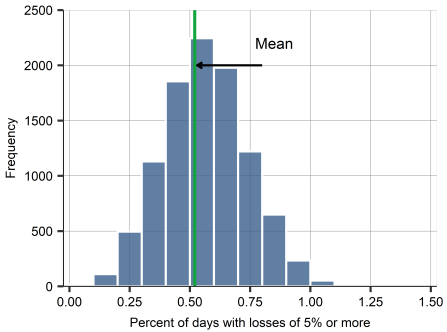
```
global iterations = 10000
forval num = 1/ $iterations {
use "$temp/sp500_pctreturns.dta",clear
gen loss = pct_return <= -5
qui sample 900, count
qui sum loss
qui scalar estimate_‘num’ = r(mean)
}
```

Ergebnisse einlesn und plotten

```
clear
set obs $iterations
gen estimate = .
qui forval num = 1/ $iterations {
replace estimate = estimate_‘num’ if _n ==‘num’ }
hist estimate
```

Stock market returns: A simulation

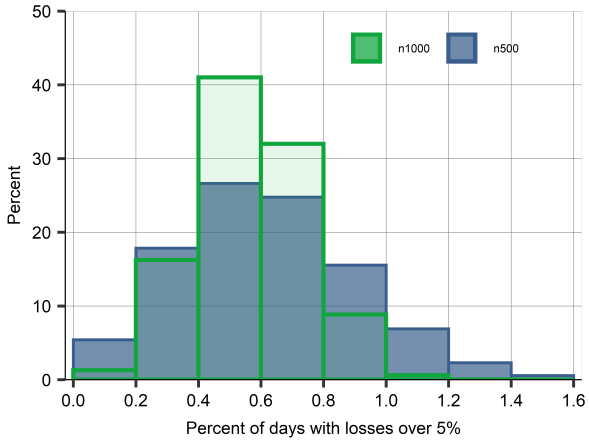
- Anteil der Tage mit Verlusten von 5% oder mehr.
- Histogramm erstellt aus den 10.000 *random samples*, jedes mit 900 Beobachtungen, gezogen aus dem gesamten Datensatz.
- *mean* = 0.5% (wie in population) $\Rightarrow$ ***Unbiasedness***
- *Spread* der *sampling distribution*: 0,1% bis über 1% beträgt.



Histogram of the proportion of days with losses of 5 percent or more, across repeated samples of size n=900. 10,000 random samples. Source: `sandp-stocks` data. S&P 500 market index.

Stock market returns: Sampling distributions

- *repeated samples* in zwei Simulationen, mit n=500 und n=1.000. (10.000 *random samples*)
- Auf die *sample size* kommt es an: Größere Stichprobe
  - Ist insgesamt öfter nah am *true value* (wahren Wert)
  - Geringere *skewness*, *long right tail*
    $\Rightarrow$ ***Asymptotic normality***
  - Geringere *standard deviation*
    $\Rightarrow$ ***Root-n convergence***



Confidence interval (Konfidenzintervall)

- Wir sind an einem wahren Parameterwert im *general pattern* interessiert
  - Beobachten können wir diesen Parameter nur über ein Sample
- ***Confidence interval*** (CI)
  - Würden wir wiederholt zufällige Stichproben ziehen und jeweils ein Intervall berechnen, dann würde ein bestimmter Anteil dieser Intervalle den wahren Parameterwert enthalten
    - Das Konfidenzniveau können wir wählen. Üblich sind 90%, 95%, 99%.
- **Nicht so ganz richtig, aber nützlich** (und oft im Lehrbuch beschrieben)
  - Der Bereich, in dem wir den wahren Wert im *general pattern* erwarten
    - Z.B. bei einem 95%-CI: „Der wahre Wert liegt vermutlich mit nur 5% Wahrscheinlichkeit außerhalb des CI“
  - Kleine CIs sind gut, weil sie auf eine präzisere Schätzung des wahren Werts hindeuten

Confidence interval bestimmen

- Das CI liegt symmetrisch um den geschätzten Wert der relevanten *statistic*.
  1. Schätzung (*estimation*) der relevanten *statistic*.
  2. Das *confidence level* (Konfidenznivaeu) definieren.
  3. Das CI mit Hilfe des ***standard errors*** (SE) berechnen.
- 95% CI
  - $\pm 1.96SE$ (gerundet $\pm 2SE$) Intervall um die geschätzte *statistic* aus den Daten.
- Das 90% CI
  - $\pm 1.65SE$ Intervall
- Das 99%-Konfidenzintervall
  - $\pm 2.58SE$ Intervall

Standard error berechnen

- Implikation der Ergebnisse aus der Übung mit *repeated samples*
  - In der Realität können wir die ***sampling distribution* nicht beobachten**.
  - Stattdessen beobachten wir einen einzelnen Datensatz.
    - Einen von vielen möglichen die sich aus dem *general pattern* realisieren könnten.
- Gute Nachrichten
  - Wir können auch aus einem einzelnen Sample eine gute **Vorstellung** davon bekommen, wie die ***sampling distribution* aussehen würde**
  - Und damit eine gute Schätzung von *standard error* und *confidence interval*.
    - Option 1: Verwenden einer Formel
    - Option 2: 'Bootstrapping' Simulation

Standard error berechnen

- Betrachten wir den *sample mean* als relevante *statistic*.
  - Die Werte von x sind unabhängig voneinander in den Beobachtungen im Datensatz.
  - $\bar{x}$ ist unser *estimate* (Schätzer) des *true value* des *mean* von x im *general pattern*.
  - Die *sampling distribution* ist ungefähr normal, mit dem *true value* als ihrem *mean*.

$$\bar{x} \sim \mathcal{N}\left(E\left[x\right], Var(\bar{x})\right)$$

  - wobei gilt, dass *variance* des *sample mean* $Var(\bar{x}) = \frac{1}{n} Var(x)$
- Daher gilt für die **Formel für den *standard error*** der geschätzten $\bar{x}$:

$$SE(\bar{x}) = SD(\bar{x}) = \sqrt{\frac{1}{n} Var(x)} = \frac{1}{\sqrt{n}} Std[x]$$

  - wobei $Std[x]$ die *standard deviation* der Variable x in den Daten ist und n die Anzahl der Beobachtungen in den Daten ist.

Die *Standard error* Formel

- Der ***standard error* ist größer**...
  - je ***größer die standard deviation der Variable in den Daten*** ist
    - Intuitiv, mehr Variation in $x \rightarrow$ mehr Variation in $\bar{x}$
  - je ***kleiner das Sample der Daten*** ist
- Zur Veranschaulichung betrachten Sie $SE(\bar{x})$ im Vergleich zu $Std[x]$.
  - Die beiden unterscheiden sich nur durch $\frac{1}{\sqrt{n}}$
- Denken Sie an die Simulation mit *repeated samples* zurück:
  - Wir haben die *sample size* der *repeated samples* erhöht...
  - an sonsten nichts verändert...
  - und bekamen weniger Variation in $\bar{x}$!
- **Der *standard error* ist kleiner als die *standard deviation* von** x

Stock market returns: The standard error formula

Betrachten wir unser Beispiel täglicher Renditedaten des S&P 500-Portfolios.

- Die berechnete *statistic*, $P(loss > 5\%) = 0.5\%$
- Der $SE\,[P(loss > 5\%)]$ wird berechnet als:
  - Die *sample size* beträgt n = 2.519, daher ist $1/\sqrt{n} = 0.02$.
  - Die *standard deviation* von $P(loss > 5\%)$ ist $SD\,[P(loss > 5\%)] = 0.07$.
  - Daher ist der $SE = \frac{1}{\sqrt{n}} SD[P(loss > 5\%)] = 0.02 \times 0.07 = 0.0014$ (0.14%).
- Jetzt können wir das 95% CI berechnen:
  - $CI = [0.5\% - 2 * SE, 0.5\% + 2 * SE] = [0.22\%, 0.78\%]$
- Wir können **zu 95% sicher** sein, dass im *general pattern*, das durch die 11-jährige Historie der Renditen in unseren Daten repräsentiert wird, tägliche Verluste von mehr als 5% mit einer Wahrscheinlichkeit von **0,2% bis 0,8%** auftreten.

Pause and reflect

Das CI ist ein absolut zentrales Konzept. Verstehen Sie die Idee?

Statistical inference: Zusammenfassung zum praktischen Vorgehen

- *Statistical inference*
  - Wir wollen aus den beobachteten Daten auf das *general pattern* verallgemeinern
- 1) Betrachten wir eine *statistic* wie den *sample mean* $\bar{x}$
  - Leicht aus den Daten zu berechnen
- 2) Als nächstes berechnen wir den *standard error*
  - Dafür brauchen wir nur die *standard deviation* und Größe des Samples n
- 3) Als nächstes berechnen wir das *confidence interval*
  - Wir entscheiden uns zunächst für ein *confidence level*, z.B. 95%
  - Daraus ergibt sich ein *critical value*, z.B. 1.96
  - Damit berechnen wir $CI = \bar{x} + /-1.96SE$ (analog für andere *statistics*)
- Jetzt wissen wir in welchem Bereich wir den *true value* erwarten können

Bootstrapping

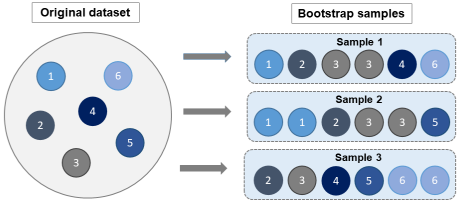
- Bootstraping
  - wir erzeugen **viele synthetische Samples** aus einem Datensatz
    - Diese unterschieden sich zufällig in den Beobachtungen die einfließen
  - In diesen synthetischen Samples berechnen wir unsere *statistic*
    - So erhalten wir die ***sampling distribution***
    - Deren ***standard deviation* ist unser *standard error***
- **Eine flexible Alterative zur Berechnung von *standard errors* (und CIs)**
  - Wenn wir keine Formeln fuer *standard errors* herleiten können (oder wollen)
- Für viele anspruchsvolle empirische Anwendungen unerlässlich.
  - Quantifizierung quanitativer ökonomischer Modelle
    - Structural economomists aufgepasst!
  - Machine learning
    - Data scientists aufgepasst!

Bootstrapping

- Das Bootstrap-Verfahren erzeugt ***repeated samples with replacement***
  - Wir ziehen viele *repeated samples* aus dem Originaldatensatz
    - Wie in der *case study simulation*
  - Alle Samples haben die **selbe Größe wie der Originaldatensatz**
    - Anders als in der *case study simulation*
  - Dafür werden die Stichproben mit *replacement* (Zurücklegen) gezogen.
    - Die Beobachtungen werden zufällig nacheinander aus dem Originaldatensatz gezogen
    - sobald eine Beobachtung gezogen wird, wird sie "zurückgelegt" (*replaced*), um wieder gezogen werden zu können, mit der gleichen Wahrscheinlichkeit wie jede andere Beobachtung.
  - Das Ziehen endet, wenn die Größe des Originaldatensatzes erreicht ist.
- Wir können das Erstellen eines Bootstrap-Samples an die Software delegieren
    - `bsample _N`

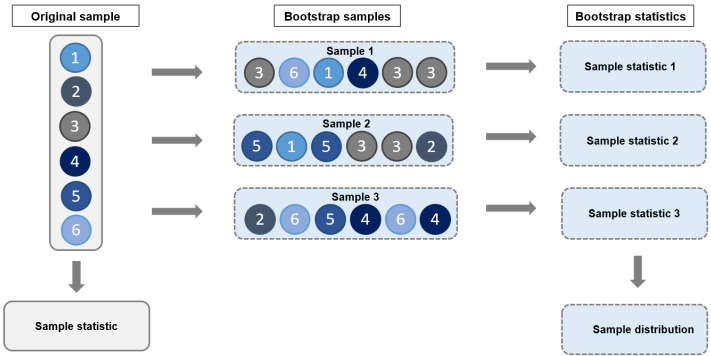
Bootstrapping

- Eine Bootstrap Sample hat immer die gleiche Größe wie der Originaldatensatz.
- Es enthält einige der Originalbeobachtungen mehrfach und andere gar nicht.
- In der Regel erstellen wir 500 bis 10.000 Stichproben.
- Rechnerisch aufwendig, aber machbar und relativ schnell (wenn nicht zu viele Beobachtungen).



Bootstrapping & *standard errrors*

- Wir haben einen Datensatz (*original sample*) und können eine *statistic* berechnen (z. B. den *mean*).
- Wir erstellen viele Bootstrap Samples und erhalten jeweils einen *mean*.
- **Das *bootstrap estimate* des SE = *standard deviation* der *mean* Werte aus den Bootstrap Samples**.

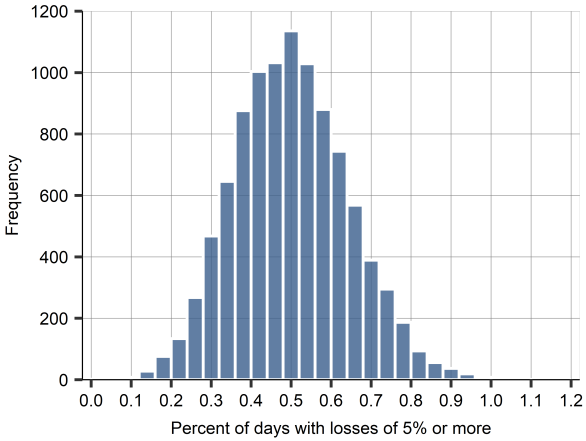


Stock market returns: The Bootstrap standard error

- Betrachten wir unser Beispiel mit 11 Jahren täglicher Renditedaten des S&P 500-Portfolios.
- Wir gehen wie folgt vor:
  1. Erstellen eines Bootstrap Sample aus dem Orginaldatensatz.
  2. Berechnen des Anteils der Tage mit Verlusten von 5%+ in diesem Sample
  3. Speichern des Wertes.
  4. Zurück auf 1.
- So lange, bis wir genug gesampelt haben (z.B. 10.000)
- Ergebnis ist ein neuer Datensatz:
  - eine Beobachtung pro Bootstrap Sample.
  - Die einzige Variable ist der geschätzte Anteil mit hohen Tagesverlusten ($loss \geq 5\%$).
- **Der bootstrap SE ist einfach die *standard deviation* dieser geschätzten Werte in diesem neuen Datensatz.**

Stock market returns: The Bootstrap standard error

- 10.000 Bootstrap Samples mit 2.519 Beobachtungen.
- Der Anteil der Tage mit einem Verlust von 5 Prozent oder mehr.
  - Variiert von 0,1% bis 1,2%
  - *mean* = *median* = 0,5 Prozent.
  - *Standard deviation* über die Bootstrap Samples = 0,14.
- *Confidence Interval*
  - Das 95% CI ist [0,22, 0,78] $(0,5 \pm 1.96 \times 0,14)$.



Stock market returns: The Bootstrap standard error

- Wir sind uns zu 95% sicher, dass tägliche Verluste von mehr als 5% mit einer Wahrscheinlichkeit von 0,22 bis 0,78 Prozent auftreten werden.
  - Im *general pattern*, das durch die 11-jährige Historie der Renditen in unseren Daten dargestellt wird
- Die SE-Formel und Bootstrap haben **genau** dieselbe Antwort geliefert.
  - War zu erwarten:
    - Ausreichend große Stichprobengröße
    - Unabhängige Beobachtungen

Würden Sie mit dieser Wahrscheinlichkeit auch im nächsten Jahr rechnen?

External validity

- *Statistical inference*
  - Wir berücksichtigtigen die Unsicherheit (*uncertainty*) die dadurch ensteht, dass wir nur **eine von vielen Realisierungen** des *general pattern* beobachten.
  - Dieses *general pattern* bezieht sich zunächst einmal auf unseren **Kontext**
- Womöglich sind wir an einem **anderen Kontext** interessiert
  - Gilt in dem Kontext das gleiche *general pattern*?
  - Wenn dem so ist, liegt *external validity* (Externe Validität) vor.
    - Wir können unsere Ergebnisse auf den anderen Kontext übertragen
- ***External validity* ist genauso wichtig wie die *statistical inference***
  - Es handelt sich jedoch mehr um ein philosophisches als ein statistisches Konzept.

External validity

- Typische Beispiele für **Übertragungen zwischen Kontexten**
  - Zeit
    - Wir haben Daten aus der Vergangenheit untersucht
    - Haben die Ergebnisse in der Zukunft bestand?
  - Raum
    - Unsere Daten stammen aus einem Land
    - Gelten die Ergebnisse auch anderswo auf der Welt?
  - Gruppen
    - Unsere Daten beziehen sich auf 25-30 Jahre alte Menschen
    - Würde ein Muster auch bei jüngeren/älteren Menschen bestehen?
- **Natürlich ist *external validity* häufig fragwürdig**
  - Spezielle Kontexte (z.B. Experimente) sind gut geeignet, um *causality* zu etablieren
    - Wir haben ***internal validity***, bedeutet aber noch lange nicht *external validity*

External validity

- In unserem Fallbeispiel
  - Angenommen, dass das kommende Jahr ähnlich sein wird
    - Dann können auf das Anlagerisiko im nächsten Jahr Rueckschlüsse ziehen.
  - Unser Datensatz von 2006-2016
    - enthält die Finanzkrise und die Große Rezession von 2008-2009
    - enthält aber nicht den Dotcom-Blase und den Crash von 2000-2001
    - Wir wissen nicht welche Krise repräsentativ für zukünftige Krisen ist
  - All das ist in der *statistical inference* nicht berücksichtigt
- **Daher ist das tatsächliche CI wahrscheinlich wesentlich breiter**.
  - *External validity* ist bei Übertragung auf einen anderen Index noch fragwürdiger

External validity in Big Data

- Big Data bedeutet meistens **sehr große Stichproben (*N*)**
  - *Statistical inference* ist in der Praxis wenig relevant
    - **Das CI wird sehr eng, da *N* gross und SE klein**
    - Es sei denn wir wenden Methoden der *causal inference* an (und nutzen de facto nur einen kleinen Teil der Beobachtungen für die Identifikation)
  - ***External validity* ist aber noch lange nicht garantiert**
    1. Großes Sample bedeutet NICHT zwangsläufig eine repräsentatives Sample. Big Data ist oft das Ergebnis von **Handlungen von speziellen Gruppen**, z.B. Social Media Nutzern (die nicht repräsentativ sind)
    2. Das *general pattern* kann sich ändern, wenn Menschen ihr Verhalten ändern und sich äußere Bedingungen ändern

Zusammenfassung

- Verallgemeinerung (*generalization*) ist eine wichtige Aufgabe:
  - Erkenntnisse zu gewinnen, die über den vorhandenen Datenset hinausgehen.
- *Statistical inference*
  - wir schliessen von unserem Datenset auf das *general pattern* in unserem Kontext
  - Dafür haben wir etablierte statistische Werkzeuge
- *External validity*
  - Unterstellt, dass unsere Daten dem gleichen *general pattern* folgen wie in dem Kontext der uns interessiert
  - Dies muss kritisch hinterfragt werden, auch wenn wir dafür keine einfachen statistischen Werkzeuge haben (wir müssen argumentieren und abwägen)