06 Hypothesen testen

Gabriel M Ahlfeldt

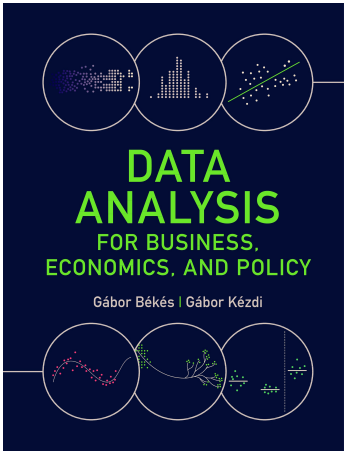
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 06**

Motivation

- *Das Internet ermöglichte das Aufkommen spezialisierter Online-Händler, während größere Geschäfte auch Waren in den Hauptgeschäftsstraßen verkaufen. Wir fragen uns, ob es* ***nennenswerte Preisunterschiede zwischen Online- und Offline-Preisen*** *gibt?*
  - *Um diese Frage zu beantworten, können wir Online- und Offline-Preise derselben Produkte sammeln und* ***prüfen, ob die Durchschnittspreise gleich sind***
  - *Wir müssen uns dabei auch mit der Frage ausseinandersetzen wie wahrscheinlich es ist, dass Unterschiede in unseren Daten* ***auf das general pattern generalisieren***



Gehe zu `https://pingo.coactum.de`, *access number* 948211

Hypothesis testing (Hypothesentests)

- Eine **Hypothese (*hypothesis*)**:
  - Eine Aussage über ein *general pattern*, von der wir nicht sicher sind, ob sie wahr ist
- **Hypothesis testing**
  - Analyse der Daten, mit dem Ziel die Hypothese zu testen.
- Die Hypothese wird **abgelehnt (rejected) wenn die Evidenz ausreichend ist**
  - Sonst wird sie nicht abgelehnt
    - Wird auch nicht abgelehnt wenn sie wahr ist, aber die Evidenz schwach
    - **Nichtablehnung bedeutet nicht, dass die Hypothese wahr ist**
  - Ähnlich wie bei der Unschuldsvermutung
    - Wir werden die Hypothese, dass Online- und Offlinepreise gleich sind nur ablehnen, wenn wir uns sehr sicher sind...
    - Wenn wir es nicht schaffen die Hypothese abzulehnen heisst das nicht, dass die Preise gleich sind. Wir können nur **keine gesicherte Aussage** treffen...

Hypothesis testing: Das setup

- Zunächst definieren wir die ***statistic***, s, an der wir interessiert sind
  - Z. B. der *mean* einer Variable
- Wir sind am *true value* (wahren Wert) von s interessiert: s_{true}
  - s_{true} ist im Beispiel dann der *mean* von s im *general pattern*
- Unseren *estimated value* (geschätzten Wert) von s bezeichnen wir mit $\hat{s}$
  - Im Beispiel ist dies der *mean* den wir in unseren Daten beobachten
  - Ganz allgemein kennzeichnen wir geschätzte Werte mit einem $\hat{}$
  - Ausgesprochen wird $\hat{s}$ als "s *hat*"
    - Beim *mean* benutzen wir manchmal auch ein $\bar{}$, hier also $\bar{s}$, ausgesprochen "s bar"

Hypothesis testing: H0 vs HA

- Formell stellen wir zwei konkurrierende Hypothesen auf
  - eine ***null*** *hypothesis* H_0 (Nullhypothese)
  - eine ***alternative*** *hypothesis* H_A (Alternativhypothese).
- Beide beziehen sich auf den unbekannten ***true value*** der Statistik $\hat{s}$.
  - Die *null hypothesis* gibt einen bestimmten Wert oder Bereich an
  - die Alternativhypothese bezieht sich dann auf *alle anderen* möglichen Werte
  - Daher kann nur eine der Hypothesen wahr sein
- Oft formulieren wir **das was wir zeigen wollen als** H_A
  - Das liegt daran, dass wir Hypothesen nicht direkt annehmen können
  - H_A **wird mit grosser Wahrscheinlichkeit richtig sein wenn wir** H_0 **ablehnen**
    - Wenn wir zeigen wollen, dass sich Online und Offlinepreise unterscheiden...
    - ... ist unsere H_0 dass die Preise gleich sind

Hypothesis testing: two vs. one-sided test

- ***Two-sided*** (zweiseitiger) Test:
  - Wir testen, ob $H_A : s_{true} \neq 0$. Erlaubt s_{true} entweder größer als null oder kleiner als null zu sein. Uns ist egal, ob die Differenz positiv oder negativ ist.

$$H_0 : s_{true} = 0$$

$$H_A : s_{true} \neq 0$$

- ***One-sided*** (einseitiger) Test:
  - Uns interessiert ob eine *statistic* einen positiven oder negativen Wert annimmt, z.B.:

$$H_0 : s_{true} \leq 0$$

$$H_A : s_{true} > 0$$

Comparing online and offline prices: Testing hypotheses

- Forschungsfrage
  - **Unterscheiden sich die Online- und Offline-Preise derselben Produkte?**
- Daten
  - Preise für 10 bis 50 Produkte pro Einzelhandelsgeschäft, das an der Umfrage teilgenommen hat
    - die größten Einzelhändler in den USA, die ihre Produkte sowohl online als auch offline verkaufen
    - Die Produkte wurden von den Datensammlern in den Geschäften ausgewählt und mit denselben Produkten abgeglichen, die dieselben Geschäfte online verkauften.
- Unsere relevante *statistic*

Differenz der Durchschnittspreise oder
Durchschnitt der Preisdifferenzen?

Comparing online and offline prices: Testing hypotheses

- Jedes Produkt i hat sowohl einen Online-Preis ($p_{i,\text{online}}$) als auch einen Offline-Preis ($p_{i,\text{offline}}$) in den Daten.
- Die Differenz lautet:

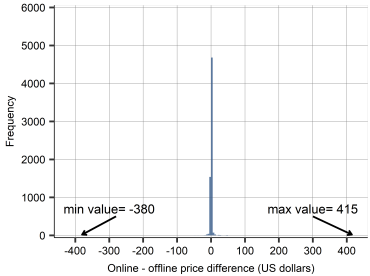
$$\text{Differenz}_i = p_{i,\text{online}} - p_{i,\text{offline}}$$

- Bei n Beobachtungen ist die *statistic* an der wir interessiert sind:

$$\hat{s} = \overline{\text{Differenz}} = \overline{p_{\text{online}}} - \overline{p_{\text{offline}}} = \frac{1}{n}\sum_{i=1}^{n}(p_{i,\text{online}} - p_{i,\text{offline}})$$

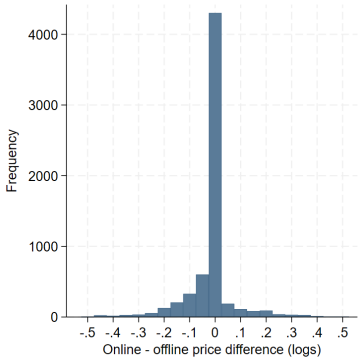
Comparing online and offline prices: Testing hypotheses

- *Descriptive statistics* (Deskriptive Statistiken)
  - Der *mean* beträgt -0,05 $:
    - Online-Preise sind in diesem Datensatz im Durchschnitt 5 Cent niedriger.
  - *Standard deviation* beträgt 10 $.
  - *Range*: -380 $ bis +415 $.
    - Es liegen *Extreme values* vor
  - Von den 6.439 Produkten haben 64 % den gleichen Online- und Offline-Preis
  - bei 87 % liegt der Unterschied innerhalb von ± 1 $ Dollar.



Comparing online and offline prices: Testing hypotheses

- Wir können auch relative Differenzen (relative differences) betrachten
  - Wir berechnen den Unterschied in *logs*
  - `gen lpd = log(price_online)-log(price)`
  - Beachte:
    $\ln(p_{online}) - \ln(p_{offline}) = \ln\left(\frac{p_{online}}{p_{offline}}\right)$
  - Der *mean* beträgt -0.01
  - Entspricht etwa -1%



Comparing online and offline prices: Formalizing the question

- Verallgemeinern
  - Aus den Daten wissen wir, dass $|\hat{S}|$ klein ist
  - Was sagt uns das über s_{true} im *general pattern*?
    - Preisdifferenzen für Produkte die wir nicht beobachten
- Dafür formulieren wir unsere Hypothesen

$$H_0 : s_{true} = \bar{p}_{online\,true} - \bar{p}_{offline\,true} = 0$$

$$H_A : s_{true} = \bar{p}_{online\,true} - \bar{p}_{offline\,true} \neq 0$$

- Wenn wir H_0 ablehnen können, unterscheiden sich die Preise im *general pattern*
  - Jetzt brauchen wir nur noch eine Methode um den Hypothesentest duchzuführen...

Hypothesis testing

- Um H_0 abzulehnen (oder nicht) müssen wir $\hat{s}$ **mit** s_{true} **unter** H_0 **vergleichen**
  - $\hat{s}$ (unsere beste Schätzung von s); hier die Durchschnittliche Preisdifferenz
  - **Nullhypothese** $H_0 : s_{true} = 0$
  - **Wenn die differenz zwischen** $\hat{s}$ **und** H_0 **gross ist**, lehnen wir ab
  - Nur, **was ist eigentlich "groß"?**
- **t-test** (T-Test)
  - Testverfahren, das auf der *t-statistik* (T-Statistik) basiert
  - Die *t-statistik* stammt aus einer *sampling distribution*, die einer *standardized 'Student's-t' distribution* folgt.
  - Aus dieser Verteilung können wir ableiten, **welche Abweichungen von** s_{true} **bei einen gegebenen *standard error* häufig oder selten sein sollten**

T-test

- Die *t-Statistic*
  - ist eine Statistik, die den **standardisierten Abstand des geschätzten Wertes von dem wahren Wert misst, wenn H_0 wahr wäre**.
  - verwendet das *sample estimate* (Schätzwert aus der Stichprobe) $\hat{s}$ und den *standard error* (Standardfehler) der Schätzung, $SE(\hat{s})$.
  - Für:
$$H_0 : s_{true} = 0,$$
$$H_A : s_{true} \neq 0$$
  - ist die *t-statistic* der Hypothesen:
$$t = \frac{\hat{s}}{SE(\hat{s})}$$
- **Je grösser t, desto eher lehnen wir H_0 ab**
  - weil $\hat{s}$ weit weg von $s_{true} = 0$ erscheint

Die wichtigsten t-Tests

Wenn H_0 besagt, dass der *mean* gleich null ist, ist die *t-statistic* einfach

$$t = \frac{\bar{x}}{SE(\bar{x})} \tag{1}$$

Wenn H_0 besagt, dass der *mean* gleich einer bestimmten Zahl ist, ist die t-Statistik

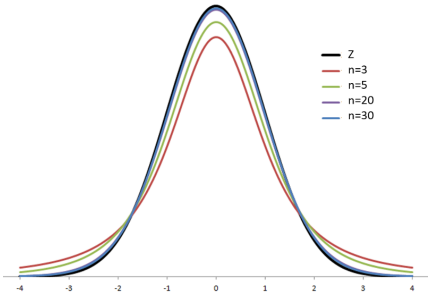
$$t = \frac{\bar{x} - \text{Zahl}}{SE(\bar{x})} \tag{2}$$

Wenn H_0 zwei *mean* Werte vergleicht: $\bar{x}_A - \bar{x}_B = 0$, ist die t-Statistik

$$t = \frac{\bar{x}_A - \bar{x}_B}{SE(\bar{x}_A - \bar{x}_B)}, \text{ wobei } SE(\bar{x}_A - \bar{x}_B) = \sqrt{\frac{Var_A}{n_A} + \frac{Var_B}{n_B}} \tag{3}$$

t-statistics unter der Nullhypothese

- "*Under the null*" (unter der Nullhypothese) oder wenn die H_0 wahr ist, stammt die relevante *t-statistic* aus einer *sampling distribution*, die als *'Student's-t' distribution* bezeichnet wird.
  - Die Student's-t Verteilung ist der *standard normal distribtion* ähnlich.
  - Sie hat einen *mean* von Null und eine *standard deviation* von 1.
  - Sie hat einen dritten Parameter, *degree of freedom* ('Freiheitsgrad'), der in unserem Fall mit der Anzahl der Beobachtungen zusammenhängt. **Ab 30 Beobachtungen ist der Unterschied marginal**



Hypothesis testing: Eine Entscheidung treffen

- **Wann ist die *t-statistic* groß genug, um die *null hypothesis* abzulehnen?**
  - Je grösser t desto weiter weg ist $\hat{s}$ von $s_{true} = 0$
- Dazu legen wir im Vorhinein einen ***critical value*** (kritischen Wert) fest
  - Die *null hypothesis* wird abgelehnt, wenn die *t-statistic* größer ist als der *critical value*
  - Sonst wird sie nicht abgelehnt
- Je grösser der *critical value*, desto strenger sind wir in unserer Entscheidung
  - Das hat natürlich Vor- und Nachteile

Richtig oder falsch liegen

Wenn wir die Entscheidung treffen, können wir auf zwei Arten richtig oder falsch liegen.

	H_0 ***true*** **(wahr)** (online \$ = offline \$)	H_0 ***false*** **(falsch)** (online \$ ≠ offline \$)
Null ***not rejected*** (Die Nullhypothese nicht abgelehnt) online \$ ≦ offline \$	True negative	False negative, Type II Error
Null ***rejected*** (Nullhypothese abgelehnt) online \$ ≠ offline \$	**False positive, Type I Error**	**True positive**

Typische Fehler

- **False positive** = *Type-I-Error* (Typ-I-Fehler)
  - Wir lehnen die Nullhypothese ab, obwohl sie wahr ist
    - "Positiv", weil wir die aktive Entscheidung treffen, die *null* abzulehnen.
  - H_0 (wahr): Autobahn hat keine wesentlichen wirtschaftlichen Effekte
    - Wir lehnen fälschlich ab $\rightarrow$ **schließen auf Effekte die es nicht gibt**
    - Bauen die Autbahn und verschwenden Milliarden Steuergelder

Typische Fehler

- **False positive** = *Type-I-Error* (Typ-I-Fehler)
  - Wir lehnen die Nullhypothese ab, obwohl sie wahr ist
    - "Positiv", weil wir die aktive Entscheidung treffen, die *null* abzulehnen.
  - H_0 (wahr): Autobahn hat keine wesentlichen wirtschaftlichen Effekte
    - Wir lehnen fälschlich ab $\rightarrow$ **schließen auf Effekte die es nicht gibt**
    - Bauen die Autbahn und verschwenden Milliarden Steuergelder
- **False negative** = *Type-II-Error* (Typ-II-Fehler)
  - Wir lehnen die *null* nicht ab, obwohl sie falsch ist
    - "Negativ", weil wir keine aktive Entscheidung treffen.
  - H_0 (nicht wahr): Autobahn hat keine wesentlichen wirtschaftlichen Effekte
    - Wir lehnen nicht ab $\rightarrow$ **können keine belastbare Aussage treffen**
    - Wir bauen nicht; chance vertan; aber keine Steuergelder verschwendet

Vorsicht bei *Type-I error*

- ***False positives* im allgemeinen schlimmer als *false negatives***
  - Das Design des Tests ist so angelegt, dass es *null* schützt:
    - Diese wird nur dann abgelehnt, wenn die Evidenz sehr stark ist.
  - Die grundlegende Annahme:
    - Das irrtümliche Ablehnen der *null* (*false positive*) ist ein schwerwiegenderer Fehler als das irrtümliche Akzeptieren (*false negative*)
- ***Critical value*** muss so gewählt werden, dass ***false positives* selten** sind

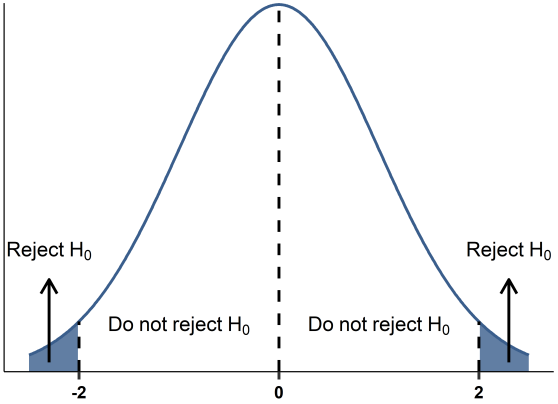
Wie gross sollte der *critical value* sein, der wir mit der *t-statistic* vegleichen?

Daumenregel (*Rule of thumb*)

- Ein häufig angewandtes ***significance level* für eine *t-statistic* ist** ± 1.96:
  - H_0 wird abgelehnt, wenn die *t-statistic* kleiner als -1.96 oder größer als $+1.96$ ist.
    - Wenn $-1.96 < t < 1.96$ lehnen wir nicht ab
  - Die Wahrscheinlichkeit, dass $|t| \geq 1.96$ ist beträgt 5%
    - Angenommen die *sampling distribution* folgt der *Student t-distribution*
    - Prob(*t-statistic*< -1.96) oder Prob(*t-statistic*> 1.96) sind beide etwa $2,5\%$
  - Unser geschätzter Wert liegt außerhalb des **95% *confidence interval***
- Wir sprechen von einem **5% *significance level*** (Signifikanzniveau)
  - Die Wahrscheinlichkeit für *false positive* Ergebnisse (Fehlalarme) ist 5%.
- Bei kleinen *samples* (n<30) sind die *critical values* größer!

Sampling distribution der *t-statistic* unter der *null*

- Die Verteilung der *t-statistic* würde bei mittlerer *sample size* nahe der *standard normal distribution* $\mathcal{N}(0,1)$ liegen.
- Prob(*t-statistic* < -2) sowie Prob(*t-statistic* > 2) beträgt je $2,5\%$.
- Die Wahrscheinlichkeit, dass einer der Fälle eintritt (*false positives*), beträgt 5%, wenn die *null* wahr ist (*two-sided test*).



Critical values

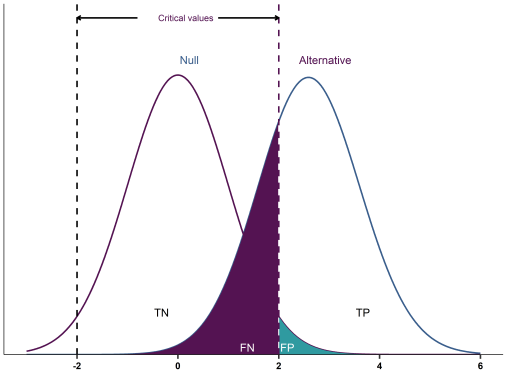
- Weitere übliche *critical values*
  - Haben wir schon in der *generalization* (Verallgemeinerung) verwendet
- *Critical value*: $\pm 2.6 \rightarrow 1\%$ *significance level*
  - Für das 99% *confidence interval* verwendet
  - Die Wahrscheinlichkeit eines *false positive* ist 1%
    - Gilt als **besonders anspruchsvoll**
- *Critical value*: $\pm 1.6 \rightarrow 10\%$ *significance level*
  - Für das 90% *confidence interval* verwendet
  - Die Wahrscheinlichkeit eines *false positive* ist 10%
    - Gilt als **gerade so akzeptabel**
- Noch größere Unsicherheiten sind nicht üblich

Significance level vs *power*

- ***Significance level*** **(Signifikanzniveau)**
  - Die maximale Wahrscheinlichkeit für *false positives*, die wir tolerieren.
    - Wenn wir das *significance level* auf 5% festlegen und die *null* ablehnen, ist die von uns getestete Statistik signifikant auf (*significant at)* dem 5%-Niveau.
- ***Power*** **des tests (Teststärke)**
  - 1-p(*false negative*): Die Wahrscheinlichkeit **keine** *false negatives* zu generieren
  - Hohe Power ist wahrscheinlicher, wenn
    - Die Stichprobe groß ist und die Streuung gering ist.
    - Der wahre Wert weiter von dem in der Nullhypothese liegt.
  - ***Precisely estimated zero*** (präzise geschätzte Null)
    - Nicht-abgelehnte Nullhypothese wird öknomisch relevant wenn *standard error* klein
    - Wir können davon ausgehen, dass der wahre Wert nahe Null ist

False negative

- Je größer der *critical value*
  - desto geringer die Wahrscheinlichkeit für *false positives* (FP)
    - Wir bauen fälschlich die Autobahn
  - desto größer die Wahrscheinlichkeit für *false negatives* (FN)
    - Wir bauen fälschlich die Autobahn nicht
- Problem verringert sich bei mehr Power
  - *True value* weit von H_0 entfernt ist
    - Rechte Verteilung weiter rechts
  - Streuung gering



Der *p-value*

- ***p-value*** (p-Wert)
  - gibt uns direkt das *significance level* an
    - Das kleinste Signifikanzniveau, bei dem wir H_0 ablehnen können
    - Wir (bzw. die Statistiksoftware) vergleichen die geschätzte *t-statistic* mit *Student's t-distribution* und berechnen die Wahrscheinlichkeit für *false positives* (Integral jenseits von t)
  - Hängt von von den gleichen Faktoren wie die *t-statistic* ab:
    - der relevanten *statistic* und
    - der *sampling distribution* der *statistic*
- **Wir lehnen H_0 ab wenn der *p-value* hinreichend klein ist**
  - 10% muss erfüllt sein; 5% üblicher Anspruch; 1% hohe Sinifikanz

Comparing online and offline prices: Testing hypotheses

- Wir legen das *significance level* auf 5% fest
  - Damit tolerieren wir eine 5%ige Wahrscheinlichkeit für ein *false positive*
  - Unsere *null* ist, dass es keinen Preisunterschied gibt ($H_0 : s_{true} = 0$)
  - 5% *significance level* $\rightarrow$ Wir müssen einen *critical value* von ± 2 erreichen
- Geschätzt haben wir:
  - Wert der relevanten *statistic* (*mean*) im Datensatz beträgt $\hat{s}$ =-0,054
  - Der *standard fehler* betraegt 0,124
    - Zur Erinnerung: $SE = \frac{\sigma}{\sqrt{N}} = \frac{9.99}{\sqrt{6439}}$
- Die *t-statistic* beträgt also $\frac{-.054}{0.124} = -0,44$.
  - Dies liegt weit innerhalb von ± 2.

Comparing online and offline prices: Testing hypotheses

- **Wir lehnen die *null*, dass es keinen Preisunterschied gibt, nicht ab!**
  - Online- und Offline-Preisedifferenz **nicht signifikant von null** verschieden
    - Im *general pattern*, das von den Daten repräsentiert wird
  - Wir sagen **nicht**, dass wir bewiesen haben, dass Preise gleich sind!!!
    - Wir haben gezeigt, dass wir die Preisdifferenz nicht von null unterscheiden können
- Großer Datensatz, kleiner *standard error* $\rightarrow$ **gute *power***
  - Abgelehnter *t-test* ist nicht auf fehlende *power* zurückzuführen.
  - Wenn sich die Preise unterscheiden, wird der Unterschied gering sein
    - Und ökonomisch kaum eine Rolle spielen

Comparing online and offline prices: Testing hypotheses

- Der direkte Weg über den *p-value*
  - `ttest pd = 0`
  - `display r(p)`
- *p-value* des Tests beträgt 0,66
  - Das kleinste *significance level*, auf dem wir die *null* ablehnen können, beträgt 66%
  - Die Wahrscheinlichkeit fälschlich die *null* abzulehnen, beträgt 66%.
- Das ist eindeutig zu viel: Daher **lehnen wir die *null* nicht ab**
  - Was nicht bedeutet, dass wir eine Preisdifferenz ausschliessen

Comparing online and offline prices: Testing hypotheses

- Weil wir hohe *power* haben:
  - Es lohnt sich zu prüfen inwieweit wir die Preisdifferenz eingrenzen können
- Wir können auf dem 5% level ablehnen dass die Differenz größer als 0.3 $ ist
  - $H_0 : s_{true} > 0.3$
    - `ttest pd = 0.3`
    - `r(p_l)`
- Wir können auf dem 1% level ablehnen dass die Differenz kleiner als 0.3 $ ist
  - $H_0 : s_{true} < -0.3$
    - `ttest pd = -0.3`
    - `r(p_r)`
- Wir sind zuversichtlich, dass die Differenz zwischen -0.3 und 0.3 $ liegt
  - Diese Preisunterschiede sind ökonomisch wenig relevant (Lehrbuch)

Comparing online and offline prices: Testing hypotheses

- Wir können auch **relative Differenzen** (relative differences) betrachten
  - Wir berechnen den Unterschied in *logs*
  - `gen lpd = log(price_online)-log(price)`
  - `ttest lpd = 0`
  - `display r(p)`
- *p-value* des Tests beträgt 0.00001 (*t-stat* = -4.4)
  - Das kleinste *significance level*, auf dem wir die *null* ablehnen können, beträgt 0.001%
  - Das 95% CI liegt zwischen -1.5% und -0.6%
- Wir **lehnen die *null* ab**
  - **Relativ gesehen**, sind Onlinepreise niedriger!
  - Absolute Preisdifferenzen machen bei sehr unterschiedlichen Gütern wenig Sinn

Multiple testing

- Beispiel
  - Medizinischer Datensatz mit 400 Patienten, enthält
    - Eine bestimmte Herzkrankheit, *binary variable*
    - 100 Merkmale des Lebensstils
      (Sport, Ernährung, Gesundheitsgeschichte, sozioökonomische Faktoren)
- Wir suchen explorativ nach Determinanten der Herzkrankheit
  - Ist die Herzkrankheit bei Armen und Reichen gleichermaßen wahrscheinlich?
  - Nehmen die Betroffenen Vitamine oder nicht, usw.?
- Daher testen wir viele Hypothesen nacheinander: ***multiple testing***
  - Für etwa ein halbes Dutzend Faktoren gibt es einen significanten Unterschied!
- **Vorsicht!**

Multiple testing

- Theoretisches Scenario
  - Wir stellen 100 *null hypotheses* auf
    - Besagen jeweils, dass es keine Unterschiede zwischen Gruppen gibt
  - Wir nehmen an, dass alle diese 100 *null hypotheses* wahr sind
- Das Signifikanzniveau setzten wir auf 5% fest
  - Wir akzeptieren eine 5%ige Chance, falsch zu liegen, wenn wir die *null* ablehnen.
- Bei 100 tests können wir erwarten, dass wir 5 *null hypotheses* abzulehnen
  - Das ist jedoch falsch: Denn alle 100 Nullhypothesen sind annahmegemäss wahr.
- **Allein durch Zufall werden wir einige Nullhypothesen ablehnen**
  - Das muss bei der Interpretation natürlich berücksichtigt werden

Multiple testing

- Strenger Ansatz: Bonferroni Korrektur
  - **Teile das angestrebte *significance level* durch die Anzahl der Hypothesen**
  - Wenn wir 20 Hypothesen haben und einen p-Wert von 5% anstreben:
    - Die *null* wird nur abgelehnt, wenn wir einen *p-value* von $0.05/20 \leq 0{,}25\%$ erhalten
    - Kann dazu führen dass gar keine signifikanten Ergebnisse erziehlt werden
- Im Endeffekt kommt es auf die Interpretation an
  - **Nicht überbewerten**, wenn **eine von 100 Hypothesen** abgelehnt wird
    - z.B. 'Häufige Bewegung' ist auf dem 5%-*level* signifikant
    - Andere Arten von Bewegung wie Laufen, Schwimmen, Ballsport, etc. sind es nicht
  - Wenn **viele von 100 Hypothesen zu einem ähnlichen Phänomen** auf dem 5% *level* abgelehnt werden, hat dies schon eine **Aussagekraft**
    - z.B. verschiedene Arten von Bewegung sind alle auf dem 5%-*level* signifikant
    - Deutet darauf hin, dass Bewegung eine signifikante Determinante ist

p-hacking

- *P-Hacking*
  - **Vielzahl von Versuchen** während des *data wrangling*
    - Umgang mit fehlenden Werten
    - Umgang mit Extremwerten
    - *Conditioning* auf unterschiedliche x-Werte
    - Löschen von Beobachtungen
  - Ergebnis mit gewünschtem *significance level* wird ausgewält
    - Meistens niedrige *p-values*, um *significance* zu ereichen
- Wie ***multiple testing***, nur dass es den Leserinnen **verschwiegen** wird
  - **Dieses Vorgehen untergräbt die Integrität der Wissenschaft!**

Tests bei sehr großen Datensätzen

- Bei sehr großen Datensätzen ist *statistical inference* weniger relevant
  - *Standard errors* werden kleine, wenn *N* gross ist
- Das gilt auch für Hypothesentests
  - *t-statistic* hängt vom *standard error* ab
    - Bei Millionen von Beobachtungen wird der *standard error* winzig, die *t-statistic* fast immer grösser als die üblichen *critical* values
- **Ökonomische Relevanz** steht im Vordergrund
  - Hypothesentests kann man sich eigentlich sparen
    - Es sei denn, es geht um sehr, sehr kleine Unterschiede
  - Jedenfalls sollte in die statistische Signifikanz nicht viel hineininterpretiert werden...