07. Einfache Regressionen

Gabriel M Ahlfeldt

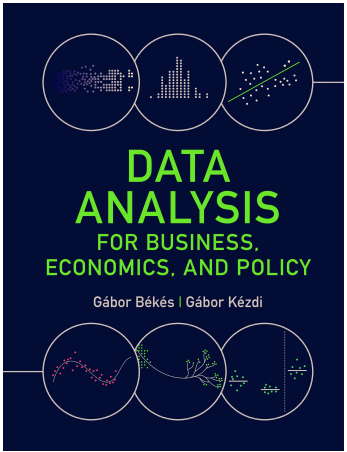
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 07**

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Motivation

- Wir suche ein gutes Angebot für eine Unterkunft in Wien
  - Natürlich ist uns ein niedriger Preis lieber
  - Die Lage (näher am Zentrum) ist aber auch wichtig
- **Wir analysieren einen Datensatz, um geeignete Hotels zu finden**



Einführung

- *Regression*
  - Die häufigste Methode, um Vergleiche innerhalb von Datensätzen anzustellen.
- **Simple regression analysis** (einfache Regressionsanalyse)
  - Zeigt die ***mean dependence* zweier Variablen** auf
    - *mean* Werte einer *dependent variable* (abhängige Variable) (y), werden für Beobachtungen vergleichen, die sich in *explanatory variable* (erklärenden Variable) (x), unterscheiden.
    - Vergleiche *conditional (on x) means* von y (Vergleich der bedingten Mittelwerte)
- Dadurch wird **die Beziehung (*association*) zwischen y und x** aufgedeckt
  - Was für y und x verwendet wird, ist wichtig und nicht austauschbar!
- Die multiple Regressionsanalyse umfasst mehrere x Variablen $\rightarrow$ Thema 10

Regression—Anwendungen

- ***Descriptive analysis*** (deskriptive Analyse):
  - Den Zusammenhang zwischen zwei Variablen zu **veranschaulichen** ist oft ein guter Ausgangspunkt, auch für komplizierte Fragestellungen
- ***Causal analysis*** (Kausalanalyse):
  - Welchen ***effect*** **(Effekt)** hat eine Variable (Entfernung zum Stadtzentrum) auf eine andere (Hotelpreise)
  - Ziel ist die *estimation* (Schätzung) eines Parameters $\left(\frac{\partial y}{\partial x}\right)$
- ***Predicitive Analaysis*** (Prognoseanalyse):
  - Was von einer y-Variablen (Hotelpreise) für verschiedene Werte einer anderen x-Variablen (Entfernung zum Stadtzentrum) zu erwarten ist.
  - Ziel ist die ***prediction*** **(Prognose)** von y für ein gegebenes x, $(\mathbb{E}(y|x))$.

Regression—Notationen

- Die **regression analysis** ist eine Methode, die den *mean* einer Variablen y für verschiedene Werte einer anderen Variablen x schätzt.

$$E[y|x] = f(x) \tag{1}$$

Wir verwenden eine einfachere Kurznotation

$$y^E = f(x) \tag{2}$$

- **dependent** oder **left-hand-side variable**, oder einfach die y Variable,
- **explanatory variable**, **right-hand-side variable**, oder einfach x Variable,
- Häufig verwendet: "*regress* y on x" (y auf x regressieren)

Regression—Arten von Zusammenhängen

- *Linear pattern* (lineare Zusammenhänge):
  - Die *association* (Assoziation) ist ***monotonic*** (monoton) mit konstanter Steigung
    - Der *mean* von y wird immer grösser wenn x grösser wird
    - oder der *mean* von y wird immer kleiner wenn x grösser wird
- *Non-linear pattern* (nicht-lineare Zusammenhaenge) mit variabler Steigung
  - Die *association* kann **non-monotonic** (nicht-monoton) sein
    - y tendiert dazu, bei höheren Werten von x in einem bestimmten Bereich der x-Variablen höher zu sein
    - und in einem anderen Bereich der x-Variablen tendiert y dazu bei höheren Werten von x niedriger zu sein.
- Keine *association* oder *relationship* (Beziehung)
  - y ändert sich nicht systematisch wenn x größer wird

Non-parametric vs. parametric regression

- **Non-parametric regressions** (nichtparametrische Regressionen)
  - Wir beschreiben $y^E = f(x)$, **ohne eine *functional form* (funktionale Form) festzulegen**
  - Wir lassen die Daten sprechen, weil wir die *functional form* nicht kennen
- **Parametrische Regressionen legen eine *functional form* für f fest**
  - Klassische (*monotonic*) Beispiele sind:
    - *linear functions* (lineare Funktionen): $f(x) = a + bx$;
    - *exponential functions* (exponentielle Funktionen): $f(x) = ax^b$;
  - Es geht auch flexibler (*non-monotonic*)
    - *Quadratic functions* (Quadratische Funktionen): $f(x) = a + bx + cx^2$,
    - Oder jede Funktion, die Parameter wie a, b, c, usw. hat, darunter *higher-order polynomial functions, spline functions, interaction terms*
  - Restriktiver, aber marginale Effekte sind direkt quantifizierbar

Non-parametric regression

- Wir berechnen den ***mean* von** y **für jeden einzelnen Wert von** x
  - Wir erhalten eine einfache und intuitive *non-parametric regression* für $y^E = f(x)$
- Hier wird keine funktionale Form auf f auferlegt.
  - Das einfachste Beispiel ist, wenn wir *ordered Variables* haben.
    - Durchschnittspreis der Hotels mit der gleichen Anzahl von Sternen vergleichen
  - Funktioniert generell gut wenn wir **viele Beobachtungen** haben
    - Relativ zu der Anzahl der Werteausprägungen für x
  - `egen Ey = mean(y), by(x)`

Non-parametric regression: bins

- Bei **vielen unterschiedlichen Werteausprägungen für** x
  - Wir können die x werte in *bins* (Beahälter) gruppieren
    - Bins sind disjunkte Kategorien (keine Überlappung), die den gesamten Bereich von x abdecken (keine Lücken).
  - Im Endeffekt wird für jeden *bin* ein *mean* berechnet
- Es gibt viele Möglichkeiten, *bin* zu erstellen
  - gleiche Größe
    - `gen xbin = round(x,b)`, wobei `b` angibt auf Welche Werte gerundet werden soll z.B. 5
    - `egen Ey = mean(y), by(xbin)`; berechnet z.B. y^E für *bin* von -2.5-2.5,2.5-7.5, etc.
  - gleiche Anzahl von Beobachtungen pro Bin
    - `binscatter y x, n(b) savedata`, wobei `b` die Anzahl der *bins* definiert
  - oder beliebige *bins*, die von der Analystin definiert werden.

Non-parametric regression: lowess (loess)

- **Smooth conditional means plots** (geglättete bedingte Mittelwertsplots)
  - Zeigen *conditional means*, **geglättet für ein besseres Bild**
  - *Continuous* (kontinuierlich), d.h. ohne *kink* (Knick) an irgendeiner Stelle
- ***Lowess***
  - *locally weighted scatterplot smoothing* manchmal als "Loess" abgekürzt.
    - *Conditional means* für bins, die sich überlappen
    - Innerhalb der bins bekommen Werte, die näher an einem x sind ein höheres Gewicht
  - `lowess y x`
- Intuitiv:
  - Eine glatte Kurvenanpassung um die y^E für die Bins

Non-parametric regression: lowess (loess)

- Awendung von *lowess*
  - Eine großartige Möglichkeit, **unbekannte Beziehungsmuster zu erkunden**
    - Was ist *functional form*? Ist sie *non-monotnic*?
    - Welche Abschnitte sind, steiler, flacher usw.
  - **Geeignet für *within-sample prediction*** (Prognose innerhalb des Samples)
    - Wir bekommen einen Wert y^E für jeden speziellen x-Wert, der in den Daten vorkommt, sowie für alle dazwischenliegenden x-Werte
    - Vorsicht, sehr abhängig davon wie stark wir glätten—Fingerspitzengefühl
  - **Nicht für *out-of-sample prediction*** (Prognose ausserhalb des Samples) geeignet
  - **Nicht für Schätzung der *slope*** (Steigung) $\frac{\partial y}{\partial x}$ geeignet
- Wir interpretieren meist Grafiken auf qualitative, nicht quantitative Weise.

Case Study: Finding a good deal among hotels

- *Wie unterscheiden Sich Hotelpreise abhängig von der Enfernung vom Stadtzentrum?*

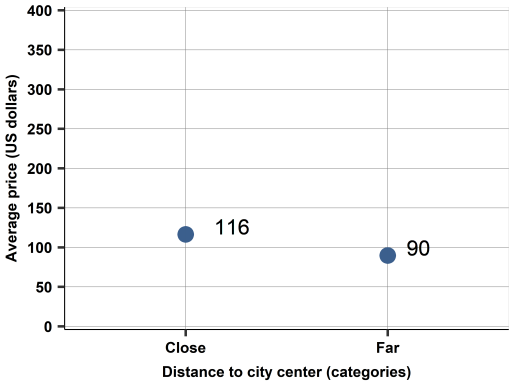
Gehe zu `https://pingo.coactum.de`, *access number* 929634



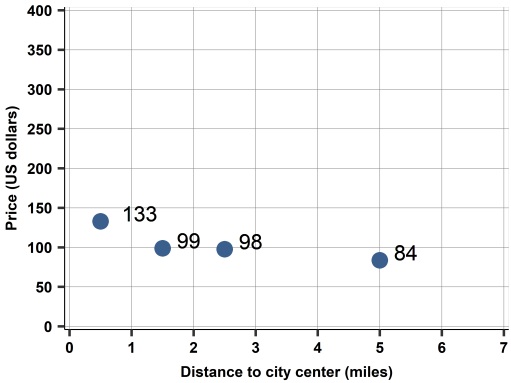
Case Study: Finding a good deal among hotels

- Wir betrachten Wiener Hotels für einen Wochentag im November 2017
  - Für diesen Wochentag in Wien gibt es 428 Hotelpreise
- Im Rahmen des *data wrangling* trimmen wir das Sample auf Hotels
  - die (i) tatsächlich in Wien sind, (ii) nicht zu weit vom Zentrum entfernt sind, (iii) als Hotels klassifiziert sind, (iv) 3-4 Sterne haben und (v) keinen extrem hohen Preis aufweisen
  - Unser *trimmed sample* (bereinigtes Sample) hat $N = 207$ Beobachtungen.

Case Study: Finding a good deal among hotels



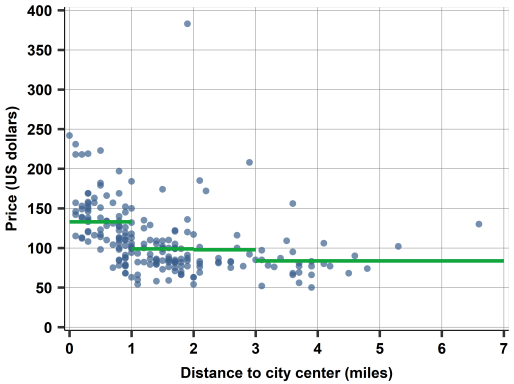
Bin scatter non-parametric regression, 2 bins



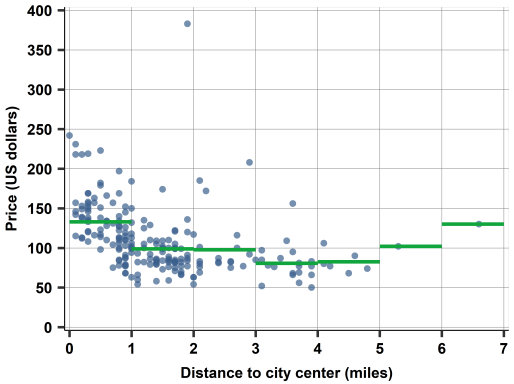
Bin scatter non-parametric regression, 4 bins

Q: Zusammenhang *linear* oder *non-linear*?

Case Study: Finding a good deal among hotels



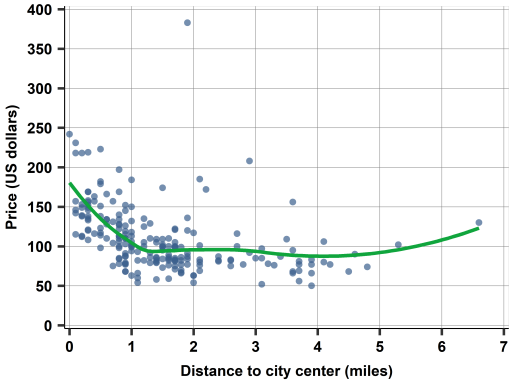
Scatter and bin scatter non-parametric regression, 4 bins



Scatter and bin scatter non-parametric regression, 7 bins

Case Study: Finding a good deal among hotels

- **Lowess** *non-parametric regression*, zusammen mit dem *scatter plot*.
- Die von der Software ausgewählte Bandbreite beträgt 0,8 Meilen.
  - Innerhalb derer wir smoothen
- Die lowess Appriximation folgt dem Muster im *scatter plot* wie erwartet
  - Vereinfacht Ablesen der *conditional means*.
- Zeigt, dass sich die Steigung über die Distanz verändert



Linear regression

- ***Linear regression*** ist die am häufigsten verwendete Methode in der Datenanalyse
  - unterstellt Linearität der Funktion f in $y^E = f(x)$.

$$y_i = \alpha + \beta x_i + e_i \rightarrow y^E = \alpha + \beta x$$

    - wobei i eine Beobachtung indiziert und e_i der Fehler in der Approximation ist
  - zwei Parameter, auch *coefficients* (Koeffizienten) genannt
    - *intercept* (Achsenabschnitt) α, *slope* (Steigung) β
  - Ergibt die *best-fitting line* (die am besten passende Linie) durch den *scatterplot*
    - Die Gerade, die allen Punkten im scatterplot am nächsten ist
  - `reg y x`

Linear regression coefficients

Die *coefficients* haben eine klare **Interpretation**—ein Vergleich von *conditional means*

$$E[y|x] = \alpha + \beta x$$

Zwei *coefficients*:

- **intercept**: α = *mean* von y, wenn x null ist:
- $E[y|x = 0] = \alpha + \beta \times 0 = \alpha$.

- **Slope**: β = erwartete Differenz in y für eine Differenz in x von eins.
  - $E[y|x = x_0 + 1] - E[y|x_0] = (\alpha + \beta \times (x_0 + 1)) - (\alpha + \beta \times x_0) = \beta$
  - $\frac{\Delta E[y|x]}{\Delta x} = \beta \rightarrow \Delta E[y|x] = \beta$ wenn $\Delta x = 1$

Linear regression coefficients

- Verbale interpretation der **slope**
  - *y is higher, on average, by β for observations with a one-unit higher value of x.*
  - wenn x eine Einheit grösser ist, ist y im Schnitt β Einheiten grösser
  - Wenn wir zwei Beobachtungen vergleichen, die sich in x um eine Einheit unterscheiden, erwarten wir, dass y für die Beobachtung mit einer Einheit grösserem x um β grösser ist.
  - Manchmal: *An increase in x by one unit is associated with an increase in y by β*

- **Vermeiden Sie "abnehmen/zunehmen" (*increase/decrease*)**
  - es sei denn, es handelt sich um Zeitreihen
    - Wir haben beobachtet, dass x/y abgenommen/zugenommen haben
  - oder eine kausale Beziehung
    - Wir gehen davon aus, dass sich y erhöhen würde, wenn sich x erhöhen würde

Linearität—Annahme vs. Approximation

- *Linearität als Annahme*:
  - Die *regression function* (Regressionsfunktion) **ist** linear in ihren *coefficients*
  - Gehen davon aus, dass die *coefficients* in der *range* über alle x konstant sind
- *Linearität als Approximation*.
  - Unabhängig von der Form der Beziehung $y^E = f(x)$ passt die Regression $y^E = \alpha + \beta x$ eine Gerade an sie an
    - Auch wenn der Zusammenhang ein anderer ist
    - Dies kann eine gute Approximation sein oder auch nicht
  - Wir approximieren die **durchschnittliche *slope*** der $y^E = f(x)$-Kurve
    - Kann nützlich sein wenn uns dieser Durchschnitt interessiert
    - Müssen im Hinterkopf behalten, der wahre Zusammenhang nichtlinear ist

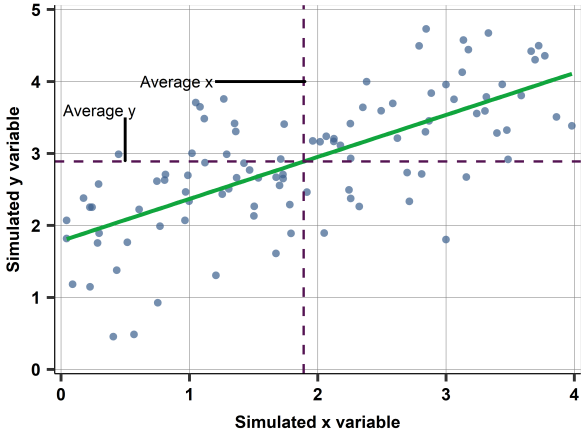
Regression: binary explanatory variable

- x ist entweder null oder eins, oft ***dummy variable*** genannt
  - α ist der *mean* von y, wenn x null ist ($E[y|x = 0] = \alpha$).
  - β ist die Differenz in y^E zwischen Beobachtungen mit $x = 1$ und $x = 0$
    - $E[y|x = 1] - E[y|x = 0] = \alpha + \beta \times 1 - \alpha + \beta \times 0 = \beta$.
    - Der *mean* von y bei $x = 1$ ist $E[y|x = 1] = \alpha + \beta$
  - Bequemer Test auf **signifikante Differenz in *mean* zwischen zwei Gruppen**
    - `gen stars4 = stars == 4`
    - `reg price stars4`
- Grafisch verläuft die Regressionsgerade der linearen Regression durch zwei Punkte:
  - Durchschnittswert von y, wenn x null ist (α)
  - Durchschnittswert von y, wenn x eins ist ($\alpha + \beta$)

Ordinary Least Squares (OLS)

- Wir brauchen Schätzverfahren, um die *regression coefficients* zu bestimmen
- OLS (Methode der kleinsten Quadrate) liefert die am besten passende Gerade.
- Die Regressionslinie verläuft durch den Punkt des Durchschnitts von x und Durchschnitt von y

Q: Kleinste quadrate?



More on OLS

- **OLS**
  - findet die **Werte der *intercept*- und *slope*-Parameter**, die den **besten *fit*** der *regression line* im *scatterplot* sicherstellen
  - **Minimiert die *sum of squares*** (summe der Quadrate) der Differenz zwischen
    - den tatsächlichen y-Werten und
    - den durch die Regression vorhergesagten Werten, $\hat{y} = \hat{\alpha} + \hat{\beta}x$

$$\min_{\alpha,\beta} \sum_{i=1}^{n} (y_i - \alpha - \beta x_i)^2$$

    - Beachte: *squares* sind immer positiv und bestrafen grosse Abweichungen stärker
  - Die Lösung im Detail findet sich im Lehrbuch
    - Das Minimum finden wir in dem wir die 1) Ableitungen nach $\hat{\alpha}$ und $\hat{\beta}$ bilden, 2) diese gleich null setzen. 3) nach α und β auflösen

Regression coefficient Formel

- Aus der Lösung des Minimierungsproblems ergibt sich:
  - Die berechneten *estimates* (Schätzwerte) $\hat{\alpha}$ and $\hat{\beta}$ (mit 'hat') der Parameter α, β
- Die **slope**

$$\hat{\beta} = \frac{Cov[x, y]}{Var[x]} = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

- **misst die *covariance* in Einheiten der *variance* von** x
  - Diese Standardisierung sorgt dafür, dass die interpretation intutiv ist
    - Um wie viel verändert sich y^E wenn sich x verändert

Regression coefficient Formel

- Die Regressionslinie liegt immer auf den **Durchschnittswerten von** x **und** y
  - Um die *sum of squares* zu minimieren, muss gelten, dass $E(y|\bar{x}) = \bar{y}$
- Es gilt:

$$\bar{y} = \hat{\alpha} + \hat{\beta}\bar{x}$$

- Gegeben $\hat{\beta}$, ist es daher leicht den **intercept** $\hat{\alpha}$ zu erhalten:

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x}$$

Predicted values

- Der **predicted value** der *dependent* Variable y wird als $\hat{y}$ bezeichnet.

$$\hat{y} = \hat{\alpha} + \hat{\beta}x$$

- Der **predicted value** (vorhergesagte Wert) der *dependent variable* ist das beste *estimate* für einen gebeben Wert der *explanatory* Variable.
  - Der **predicted value** kann aus der Regression für jedes x berechnet werden.
    - **Auch für x-Werte, die ausserhalb der *range* in den Daten liegen**
  - Die **predicted values** der *dependent* Variablen liegen alle auf der Regressionslinie.

Residuals

- ***Residual*** (Residuum):
  - **Der Fehler in der Approximation** durch die Regressionsgerade
    - Differenz zwischen beobachtetem Wert der *dependent variable* und *predicted value*:

$$e_i = y_i - \hat{y}_i, \qquad \text{wobei} \qquad \hat{y}_i = \hat{\alpha} + \hat{\beta} x_i$$

  - Existiert **nur für tatsächliche Beobachtungen**
    - Hier mit i indiziert
  - Vertikaler Abstand zwischen dem Punkt im *scatter plot* und der *regression line*.
    - Für Punkte oberhalb der *regression line* ist das *residual* positiv.
    - Für Punkte unterhalb der *regression line* ist das *residual* negativ.

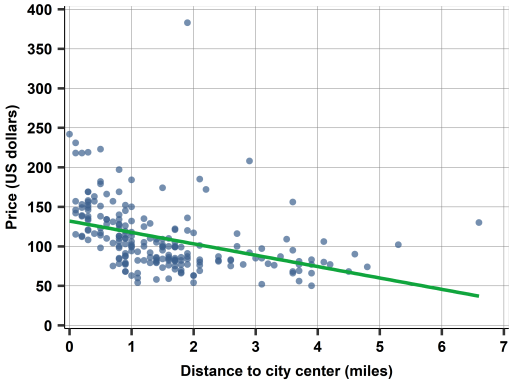
Q: Wie hilft uns das unser Hotel zu finden?

Residuals

- Wir interessieren uns (aus ökonomischer) Sicht für das *resdiual*
  - Wenn wir uns für Unterschiede in y interessieren, die **um** x **bereinigt** sind
    - Wie hoch ist die Note einer Studentin in der Einführung in die Öknometrie einzuschätzen, wenn wir berücksichten in welchem Studiengang sie eingeschrieben ist?
- **Das *residual* ist eine bereinigte Variante von** y
- Beachte: Die *residuals* einer OLS *regression* summieren sich zu null.
  - Dies ist eine Eigenschaft von OLS: $E[e_i] = 0$
    - Schliesslich haben Wir die *summe* der quadrierten Fehler minimiert...
  - Um die Grössenordnung vergleichbar zu halten, müssen wir $\hat{\alpha}$ hinzufügen
    - `reg y x`
    - `predict resid, res`
    - `gen y_adjusted = resid + _b[_cons]`

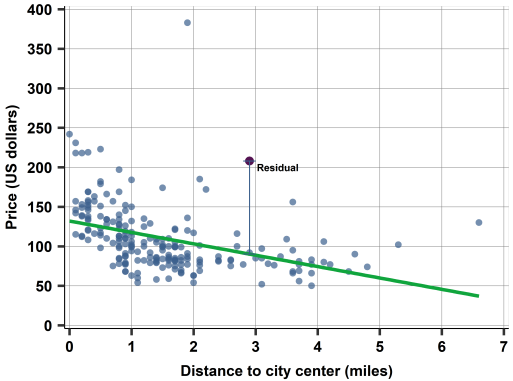
Case Study: Finding a good deal among hotels

- Die Regression von *hotel prices* (in $) auf *distance* (Entfernung) (in Meilen) ergibt einen *intercept* von 133 und eine *slope* von -14.
- *Intercept* impliziert, einen *mean price* im Zentrum von 133 $.
- Hotels, die 1 Meile weiter vom Stadtzentrum entfernt sind, sind in unseren Daten durchschnittlich 14 $ günstiger.
  - *mean hotel price* = 110 $ $\Rightarrow$ Preis fällt im Schnitt um $\frac{-14\$/mile}{110\$} \times \frac{1.61 miles}{1 km} = 12.7\%/km$.



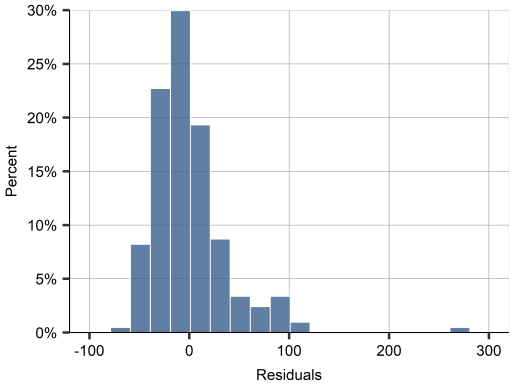
Case Study: Finding a good deal among hotels

- Das *residual* ist der vertikale Abstand eines jeden Punktes im *scatterplot* zur *regression line*
- Ein positives *residual* bedeutet hier, dass der Preis über dem liegt, was von der *regression line* vorhergesagt wurde
- **Das Hotel is auffällig teuer**



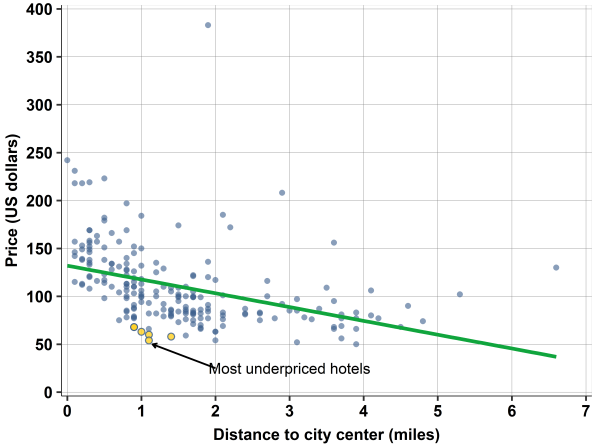
Case Study: Finding a good deal among hotels

- Betrachten wir die *residuals* aus der *linear regression*.
- Wie erwartet, sehen wir eine *distribution*
  - mit positiven und negativen Werte
  - die um Null zentriert ist



Case Study: Finding a good deal among hotels

- Sofern wir mit der linearen Approximation zufrieden sind, können wir über- und unter-bewertete Hotels anhand der *residuals* identifizieren
  - Unterbewertete (*underpriced*) Hotels liegen unterhalb der *regression line* und haben zu ihr den grössten Abstand
  - **Die sollten wir uns näher ansehen**



Case Study: Finding a good deal among hotels

- Eine Liste der fünf Hotels mit den niedrigsten *residuals*

No.	Hotel_id	Distance	Price	Predicted price	Residual
1	22080	1.1	54	116.17	-62.17
2	21912	1.1	60	116.17	-56.17
3	22152	1	63	117.61	-54.61
4	22408	1.4	58	111.85	-53.85
5	22090	0.9	68	119.05	-51.05

- Wir können—und werden—die Analyse natürlich verbessern. Ein besseres Modell für Preisprognosen könnte folgenden Aspekte berücksichtigen.
  - *Non-linearity*, bzw. *functional form*
  - Andere Merkmale jenseits der Entfernung

Model fit—R^2 (Modellgüte)

- ***R-squared*** (R^2) (Bestimmtheitsmass)
  - **Anteil der Variation** in y, der **von der Regression erklärt** wird.

$$R^2 = \frac{Var[\hat{y}]}{Var[y]} = 1 - \frac{Var[e]}{Var[y]}$$

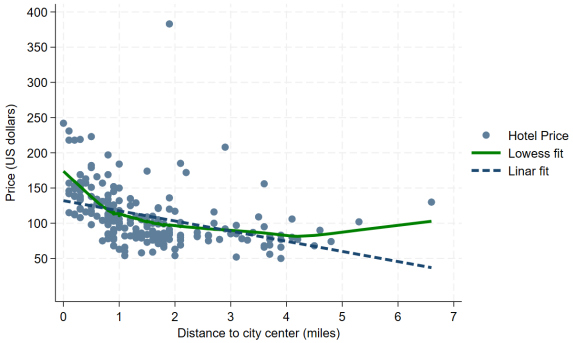
    - wobei, $Var[\hat{y}] = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2$, and $Var[e] = \frac{1}{n}\sum_{i=1}^{n}(e_i)^2$
- Wir können die **Variation in** y **zerlegen** in:
  - **Erklärte Variation** (durch die Regression) in den *predicted values*
  - **Nicht erklärte Variation** in den *residuals*:

$$Var[y] = Var[\hat{y}] + Var[e]$$

Model fit—R^2

- R^2 kann für *parametric* als auch *non-parametric regressions* bestimmt werden
  - Wir benötigen nur die *predicted values* und deren *variance*
  - Jede Art von Regression erzeugt *predicted values*
- Der Wert von R^2 liegt **immer zwischen null und eins**
  - $R^2 = 0$ bedeutet, dass $\hat{y}_i = \bar{y}, \forall\ i$
    - Wir sagen immmer den *mean* von y voraus $\rightarrow$ Dafür brauchen wir keine Regression
- **Vorhersagen sind *wahrscheinlich* besser bei hohem** R^2
  - Das R^2 kann bei der Auswahl zwischen verschiedenen Modellspzifikationen helfen
- Für *causal inference* (kausaler Effekt von x auf y) ist das R^2 weniger wichtig
  - Hier kommt es darauf an, dass x_i und e_i unkorreliert sind

R^2




```
* code by Gabriel Ahlfeldt
twoway ///
       (scatter price distance , ms(O) msize(small) mlw(thick) mcolor(navy*0.7) ) ///
       (lowess price distance , bwidth(0.8) lw(thick) lc(green) ) ///
       (lfit price distance , lw(thick) lc(navy) lpattern(dash))       ///
       ,  xlab(0(1)7, grid) yscale(range(0 300)) ylab(50(50)400, grid) ///
        xtitle("Distance to city center (miles)") ///
        ytitle("Price (US dollars)") title("") note("") ///
        graphregion(fcolor(white) ifcolor(none))  ///
        plotregion(fcolor(white) ifcolor(white)) ///
        legend(order(1 "Hotel Price" 2 "Lowess fit" 3 "Linar fit"))
graph export "$output/ch07-figure-3-lowess-linear-Stata.png", as(png) replace

* now check R2
    qui reg price distance
    local R2 = round(e(r2), 0.01)
    display "R2 of linear fit is `R2'"
    lowess price distance , bwidth(0.8) gen(lowess_y_hat)
    qui reg price lowess_y_hat
    local R2 = round(e(r2), 0.01)
    display "R2 of lowess fit is `R2'"
```

Q: **OLS vs. lowess: Welches R^2 ist höher?**

Correlation & linear regression

- *Covariance*, *correlation coefficient* und *slope of linear regression*
  - **Messen die Assoziation zwischen den beiden Variablen**

$$Corr[x, y] = \frac{Cov[x, y]}{Std[x]Std[y]} \rightarrow Cov[x, y] = Corr[x, y]Std[x]Std[y]$$

- *Covariance* und *correlation coefficient* können genutzt werden, um $\hat{\beta}$ zu erhalten:

$$\hat{\beta} = \frac{Cov[y, x]}{Var[x]} = \frac{Corr[x, y]Std[x] \times Std[y]}{Var[x]} = Corr[x, y]\frac{Std[y]}{Std[x]}$$

- Anders als bei *correlation coeffficent*
  - Mögliche Werte **nicht auf [-1,+1] beschräkt und ökonomisch interpretierbar**
  - y und x sind **nicht austauschbar**.

Correlation & R^2 in linear regression

- Das R^2 der einfachen *linear regression* ist das Quadrat des *correlation coefficient*

$$R^2 = \frac{Var[\hat{y}]}{Var[y]} = \frac{Var[\hat{\alpha} + \hat{\beta}x]}{Var[y]} = \frac{\hat{\beta}^2 Var[x]}{Var[y]} = \left(\hat{\beta}\frac{Std[x]}{Std[y]}\right)^2 = (Corr[y, x])^2$$

- **Das R^2 misst die Stärke der Assoziation, aber nicht die Richtung**
  - Die Richtung und die quantitative Interpretation ergibt sich aus $\hat{\beta}$ der Regression
- **Der *correlation coefficient* misst Stärke und Richtung der Assoziation**
  - Quantitativ aber nicht so gut interpretierbar wie $\hat{\beta}$

Reverse regression (umgekehrte Regression)

- *Reverse regression*: $x^E = \gamma + \delta y$
  - Der OLS-*estimator* ist $\hat{\delta} = \frac{Cov[y,x]}{Var[y]} \Rightarrow Cov[x,y] = \hat{\delta} Var[y]$

$$\Rightarrow \hat{\beta} = \frac{Cov[x,y]}{Var[x]} = \hat{\delta}\frac{Var[y]}{Var[x]}$$

  - $\hat{\beta}, \hat{\delta}$ muessen unterschiedlich sein, es sei denn $Var[x] = Var[y]$,
    - Haben aber immer das gleiche Vorzeichen (da $Var > 0$).
    - Beide sind größer, je größer die *covariance* ist.
- **Wenn man x und y vertauscht, ändert sich die slope!**
  - R^2 für die einfache lineare Regression und die umgekehrte Regression ist gleich

Causation

!!! Jenseits von Experimenten, sind *linear regression coefficients* in der Regel nicht als kausal zu interpretieren !!!

- **Achten Sie auf Ihre Ausdrucksweise**
  - Sprechen Sie nicht vorschnell über Kausalität (*causality*)
- Denken Sie an die *sources of variation* in x
  - Kontrollieren Sie die Variation in x (Experiment)? Oder beobachten Sie sie nur?
- Regression ist eine Methode des Vergleichs
  - Unterschiede in x werden mit Unterschieden in y verglichen.
  - Unabhängig davon ob
    - x auf y wirkt
    - y (auch) auf x wirkt
    - Eine andere Variable z auf x und y wirkt

Zusammenfassung der wichtigsten Erkenntnisse

- Regression
  - vergleicht durchschnittlichen y-Werts für Beobachtungen mit unterschiedlichen Werten von x
- Nicht-parametrische Regressionen (Binscatter, Lowess)
  - visualisieren komplexe Muster der Beziehung zwischen y und x
  - liefern jedoch keine interpretierbaren Zahlen.
- Lineare Regression
  - lineare Approximation des durchschnittlichen Beziehungsmusters zwischen y und x.
  - In $y^E = \alpha + \beta x$ zeigt β, wie viel größer y im Durchschnitt für Beobachtungen mit einem um eine Einheit größeren x ist.
  - Wenn β nicht null ist, liegt eine Korrelation vor, aber nicht unbedingt Kausalität!
- Ernsthaftes Interesse an Ökonometrie und fortgeschrittener Statistik?
  - Abschnitte im Lehrbuch mit detaillierten Herleitungen empfohlen