08. Komplexe Muster und unübersichtliche Daten

Gabriel M. Ahlfeldt

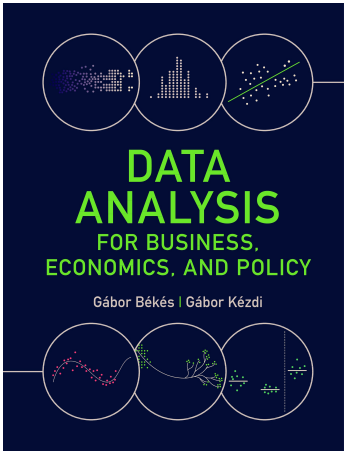
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 08**

Motivation

- Wir sind immer noch daran interessiert, ein **Hotel in Wien zu finden, das ein gutes Preis-Leistungs-Verhältnis bietet**.
  - Wir haben bereits eine erste Analyse mithilfe einer *simple linear regression* durchgeführt.
  - Wir sind jedoch besorgt, dass das Modell die nichtlineare Wirkung der Entfernung nicht berücksichtigt und daher unsere *residuals* die Hotels, die den besten Preis in Bezug auf ihre Entfernung zum Zentrum bieten, nicht zuverlässig identifizieren.
- **Wir möchten eine bessere Annäherung an die Funktion $y^E = f(x)$ finden**.

Linear approximation (lineare Approximation)

- *Linear regression*
  - Oft einfach eine **lineare Approximation** eines Zusammenhangs unbekannter Form:

$$y^E = f(x) \approx \alpha + \beta x$$

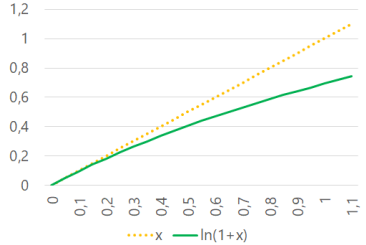
- Gründe die *functional Form* zu **hinterfragen**:
  - Wir sind an **aussagekräftigen *predicted values* und *residuals*** interessiert
  - Wir möchten einer **theoretisch erwarteten Nichtlinearität** Rechnung tragen
  - Die lineare Approximation **repräsentiert den Zusammenhang schlecht**
- Wir können es bei der *simple linear regression* **belassen** wenn
  - wir uns wirklich **nur für die durchschnittliche *slope* interessieren**
  - die lineare Regression eine **gute Approximation liefert**

Ln transformation

- Vorteile des ***natural logarithm of x*** (natürlicher Logarithmus von x)
  - In *logs* **verschwinden Dimensionen** weil wir relative Unterschiede betrachten
    - $\Delta x = x_2 - x_1$, aber, $\Delta \ln x = \ln x_2 - \ln x_1 = \ln \frac{x_2}{x_1}$
  - Impliziert **Nichtlinearität**: Gleiche Veränderung von x bedeutet
    - bei grösseren Werten von x eine grössere Veränderung von y
  - Logarithmische Unterschiede entsprechen **prozentualen Unterschieden**
    - Bei kleinen Zahlen!
- Beachte
  - x muss eine positive Zahl sein
  - *ln*(0) oder *ln*(*negativeZahl*) existiert nicht
  - Manchmal wird *log*(x) verwendet, aber das könnte auch der log zur Basis 10 sein
  - `gen lx = ln(x)` oder `gen lx = log(x)` ergeben in Stata das gleiche

Logarithmus-Approximation: Was gilt als klein?

- ***Log-differences***
  - Veränderungen in (*natural*) logs
  - $\Delta ln(x) = ln(x_2) - ln(x_1)$
- Formel für Umrechnung auf **Prozent-Effekt**:
  - Prozent-Effekt $= [\exp(\Delta ln(x)) - 1] \times 100$
- **Faustregel**
  - **Bis** $\pm 0,2$ gilt $\Delta ln(x) \approx$ Prozent-Effekt
  - Bei grösseren Werten, Formel nutzen!
    - $\Delta ln(x) = +1 \rightarrow +170\%$
    - $\Delta ln(x) = -1 \rightarrow -63\%$



Herleitung

Wann sollte man Logarithmen verwenden?

- wenn man an **relativen Unterschieden** interessiert ist
  - Prozentuale Unterschiede
- Die Variable muss **ausschließlich positive Werte** annehmen
  - Fall der Datensatz Nullen enthählt, wird häufig $\ln(1 + x)$ verwndet.
  - Relativ unproblematisch wenn x generell große Werte annimmt.
- Typische Beispiele:
  - Preise
  - Umsatz, BIP
  - Bevölkerung, Beschäftigung
  - Kapitalbestand, Lagerbestände
- Man kann den **Logarithmus für y, x oder beide** nehmen!
  - Diese führen zu **unterschiedlichen Interpretationen** des *slope* Parameters!

Parameterinterpretation (**bei kleinen Werten**)

- $ln(y)^E = \alpha + \beta x_i$ - 'log-level' Regression
  - log y, level x
  - α ist der durchschnittliche Ln(y)-Wert, wenn x null ist (nicht besonders intuitiv)
  - β: y ist im Durchschnitt um $\beta * 100$ Prozent größer wenn x eine Einheit größer ist

Parameterinterpretation (**bei kleinen Werten**)

- $ln(y)^E = \alpha + \beta x_i$ - 'log-level' Regression
  - log y, level x
  - α ist der durchschnittliche Ln(y)-Wert, wenn x null ist (nicht besonders intuitiv)
  - β: y ist im Durchschnitt um $\beta * 100$ Prozent größer wenn x eine Einheit größer ist
- $y^E = \alpha + \beta ln(x_i)$ - 'level-log' Regression
  - level y, log x
  - α ist: durchschnittlicher y-Wert, wenn ln(x) null ist (und damit x eins ist).
  - β: y ist im Durchschnitt um $\beta/100$ Einheiten größer wenn x ein Prozent größer ist

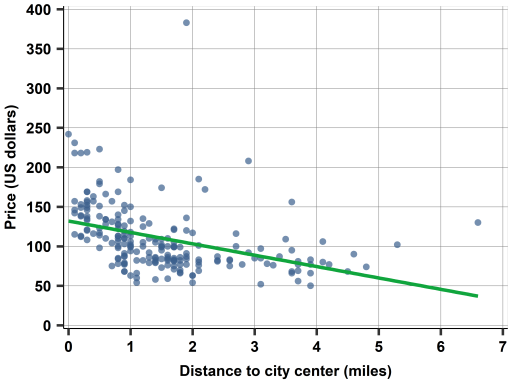
Parameterinterpretation (**bei kleinen Werten**)

- $ln(y)^E = \alpha + \beta x_i$ - 'log-level' Regression
  - log y, level x
  - α ist der durchschnittliche Ln(y)-Wert, wenn x null ist (nicht besonders intuitiv)
  - β: y ist im Durchschnitt um $\beta * 100$ Prozent größer wenn x eine Einheit größer ist
- $y^E = \alpha + \beta ln(x_i)$ - 'level-log' Regression
  - level y, log x
  - α ist: durchschnittlicher y-Wert, wenn ln(x) null ist (und damit x eins ist).
  - β: y ist im Durchschnitt um $\beta/100$ Einheiten größer wenn x ein Prozent größer ist
- $ln(y)^E = \alpha + \beta ln(x_i)$ - 'log-log' regression
  - log y, log x
  - α: ist der durchschnittliche $ln(y)$-Wert, wenn $ln(x)$ null ist (nicht besonders intuitiv)
  - β: y ist im Durchschnitt um β Prozent höher wenn x ein Prozent größer ist.
    - Häufig verwendet, um eine *elasticity* (Elastizität) zu schätzen.

Hotel price-distance regression and functional form

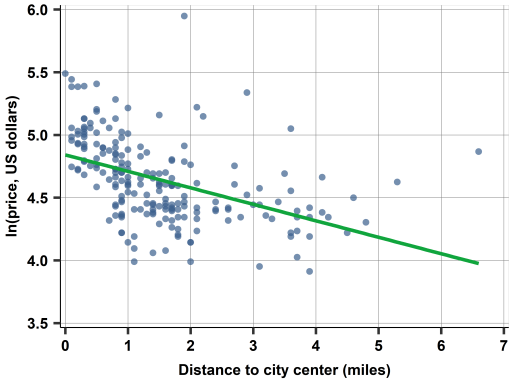
- $price_i = 132.02 - 14.41 * distance_i$
  - `reg price distance`

Q: Haben wir hier ein Problem, dass wir mit der log Transformation lösen können?



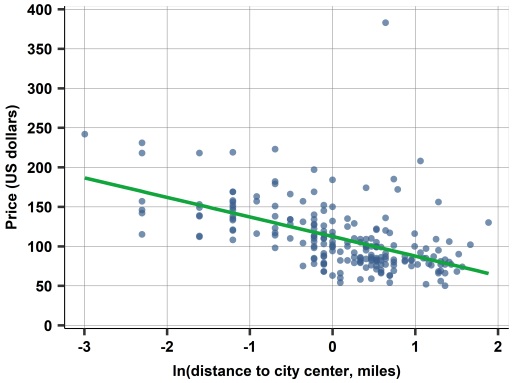
Hotel price-distance regression and functional form—log-level

- $\ln(price_i) = 4.84 - 0.13 * distance_i$
  - `gen lprice = ln(price)`
  - `reg lprice distance`
- **Bessere Approximation** der *slope*
  - Die Verteilung des Log-Preises ist näher an der *normal distribution* als die Verteilung des Preises selbst
  - *Scatter plot* ist **symmetrischer** um die *regression line* verteilt.



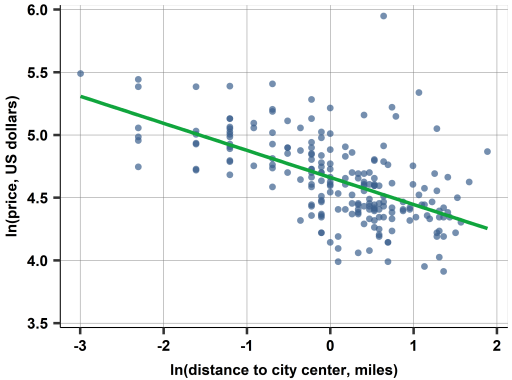
Hotel price-distance regression and functional form—level-log

- $price_i = 116.29 - 28.30 * \ln(distance_i)$
  - `gen ldistance = ln(distance)`
  - `reg price ldistance`
- Jetzt vergleichen wir
  - absolute Unterschiede in Preisen mit
  - prozentualen Unterschieden in der Entfernung.
- Diese Transformation betont die Rolle **kleiner** x **Werte**
  - Kleinere Werte haben noch kleinere Log-Werte, während große Werte näher am Durchschnittswert liegen.



Hotel price-distance regression and functional form—log-log

- $\ln(price_i) = 4.70 - 0.25 * \ln(distance_i)$
  - `gen lprice = ln(price)`
  - `gen ldistance = ln(distance)`
  - `reg price ldistance`
- Jetzt vergleichen wir
  - prozentuale Unterschiede in Preisen
  - prozentuale Unterschiede in Entfernungen
- ***Distance elasticity of price*** oder *elasticity of price with respect to distance* ist 0.25



Hotel price-distance regression and functional form

Figure: Log-level

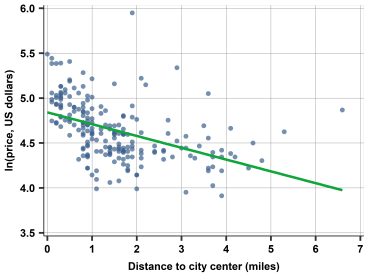


Figure: Level-log

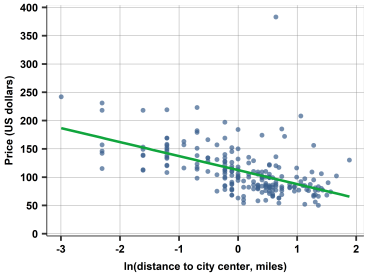
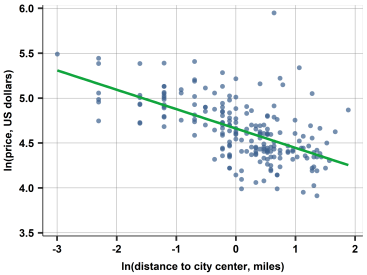


Figure: Log-log



Q: Welche *functional form* funktioniert am besten?

Comparing different models

Table: Hotel price and distance regressions

Variables	(1) price	(2) ln(price)	(3) price	(4) ln(price)
Distance to city center, miles	-14.41	-0.13		
ln(distance to city center)			-24.77	-0.22
Constant	132.02	4.84	112.42	4.66
Observations	207	207	207	207
R-squared	0.157	0.205	0.280	0.334

Source: `hotels-vienna` dataset. Prices in US dollars, distance in miles.

Hotel price-distance regression interpretations

- **Level-level**: Hotels, die 1 Meile weiter vom Stadtzentrum entfernt sind, sind im Durchschnitt 14 US-Dollar günstiger.
- **Log-level**: Hotels, die 1 Meile weiter vom Stadtzentrum entfernt sind, sind im Durchschnitt 13 Prozent günstiger.
- **Level-log**: Hotels, die 10 Prozent weiter vom Stadtzentrum entfernt sind, sind im Durchschnitt 2,48 US-Dollar günstiger.
- **Log-log**: Hotels, die 10 Prozent weiter vom Stadtzentrum entfernt sind, sind im Durchschnitt 2,2 Prozent günstiger.

Logarithmieren oder nicht—wichtige Gründe

- **Theoretische Erwägungen**:
  - Verwenden Sie Logarithmen, wenn es wahrscheinlich ist, dass eine Variable auf multiplikative Weise beeinflusst wird
    - *Microfoundations* ergeben oft (gewollt) **multiplikative Zusammenhänge**
    - Oft wollen wir **Elastizitäten schätzen**
  - Verwenden Sie *levels*, wenn eine Variable wahrscheinlich auf additive Weise beeinflusst wird
- **Statistische Erwägungen**:
  - Lineare Regressionen liefert einen besseren *fit*, wenn die Verteilung der *dependent variable* näher an der *normal distribution* ist.
  - Verwenden Sie Logarithmen, wenn die **Verteilung *skewed*** ist und einen ***long right tail*** aufweist
- Oft sind theoretische und statistischen Erwägungen im Einklang

Comparing different models—model choice

Table: Hotel price and distance regressions

Variables	(1) price	(2) ln(price)	(3) price	(4) ln(price)
Distance to city center, miles	-14.41	-0.13		
ln(distance to city center)			-24.77	-0.22
Constant	132.02	4.84	112.42	4.66
Observations	207	207	207	207
R-squared	0.157	0.205	0.280	0.334

Source: `hotels-vienna` dataset. Prices in US dollars, distance in miles.

Q: Statistische vs. ökonomische Erwägungen?

Model choice—theoretische Erwägungen

- Da wir kein theoretisches Modell haben, kommt es auf die **Intuition** an!
  - Geeignete Modelle gibts es aber durchaus → *Quantitative Spatial Economics*
- Preise
  - **Unmittelbar relevant** ist im *hier und jetzt* der **absolute Preisunterschied**
    - Für **längerfristige** Aussagen sind **prozentuale Preisunterschiede** interessanter wenn Inflation und saisonale Schwankungen die Preise proportional beeinflussen
  - Möglicher Weise interessieren uns sowieso nur relative Unterschiede
    - Der absolute Betrag ist sekundär, wir **benötigen nur das beste Angebot**
- Entfernung
  - **Intuitiv** macht die Entfernung in **Meilen (oder km)** mehr Sinn als in *logs*.
  - Aber wir sind **nicht an einer ökonomischen Interpretation** interessiert
    - Wir wollen ja nur ein *vergleichsweise* günstiges Hotel zu finden.

Model choice—statistische Erwägungen

- Visuelle Inspektion ⇒ **Log Preis**
  - Log-Preismodelle bieten einen besseren *fit*
- Vergleich der R^2 ⇒ **Log Entfernung**
  - Level-Level- vs. Level-Log-Regression: R^2 der Level-Log-Regression ist höher
  - Log-Level- vs. Log-Log-Regression: R^2 der Log-Log-Regression ist höher
    - **Merke**: Das R^2 von zwei Regressionen mit **unterschiedlich transformierten *dependent Variables*** sollte man auf Grund der verschiedenen Einheiten **nicht vergleichen**!
- Urteil:
  - **Log-Log** wahrscheinlich die **beste Wahl**:
    - Selbst wenn die Interpretation weniger intuitiv ist als bei log-lin
    - Bessere *predicted values* und *residuals* und das ist woran wir interessiert sind!

Piecewise Linear Splines

- Eine Regression mit *piecewise linear splines* der *dependent variable*
  - **Verbundene lineare Segmente** von *predicted values* der *dependent variable*.
  - Jedes Segment entspricht einem bestimmten Intervall der *explanatory variable*
- Die **Verbindungspunkte** werden als *knots* (Knoten) bezeichnet
  - An den *knots* kann sich die ***slope* ändern**
  - Ein *piecewise linear spline* mit m Segementen hat $m - 1$ *knots*
- Die Positionen (Werte der x Variable) der *knots* können **festgelegt** werden
  - Software-Pakete verfügen über integrierte Routinen, die den Rest berechnen
- Eleganter ist die *knots* von **Alogirthmen** bestimmen zu lassen
  - Viele *knots* ausprobieren und Wert Wählen, der R^2 maximiert (*grid search*)
  - Oder mit nichtlinearen Verfahren die Werte der *knots* schätzen

Piecewise Linear Splines—Formel

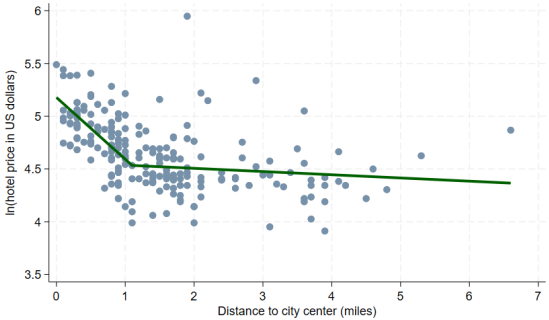
- Bei m Segmenten und $m-1$ *knots* lautet die Formel wie folgt:

$$
\begin{aligned}
y^E = & \underbrace{\alpha}_{\text{E(y|x=0)}} + \underbrace{\beta_1 x \mathbb{1}_{x<k_1}}_{\text{Verlauf bis zu knot 1}} \\
& + \underbrace{\beta_1 k_1 \mathbb{1}_{x\geq k_1}}_{\text{Korrekturterm}} + \underbrace{\beta_2 (x-k_1)\mathbb{1}_{k_1\leq x<k_2}}_{\text{Verlauf von knot 1 zu knot 2}} \\
& + \underbrace{\beta_2 (k_2-k_1)\mathbb{1}_{x>k_2}}_{\text{Korrekturterm}} + \underbrace{\beta_3 (x-k_2)\mathbb{1}_{k_2\leq x<k_3}}_{\text{Verlauf von knot 2 zu knot 3}} + \dots \\
& + \underbrace{\beta_m (k_m-k_{m-1})\mathbb{1}_{x\geq k_{m-1}}}_{\text{Korrekturterm}} + \underbrace{\beta_m (x-k_{m-1})\mathbb{1}_{x\geq k_{m-1}}}_{\text{Verlauf ab knot m-1}}
\end{aligned}
$$

- Korrekturterme stellen sicher, dass die Segmente an den *knots* verbunden sind

Überblick über *piecewise linear splines*

- Stata code (nicht Klausurrelevant): *knot* wird mitgeschätzt
  - `nl (lnprice = {a}+{b0}*distance+({b1}-{b0})*max(distance-{k1},0)),initial(k1 1)`
    - nl steht für non-linear least squares "{}" sind parameter. Vgl. "help nl"
  - Nerd-Task: Die Idee hinter dem Code verstehen...



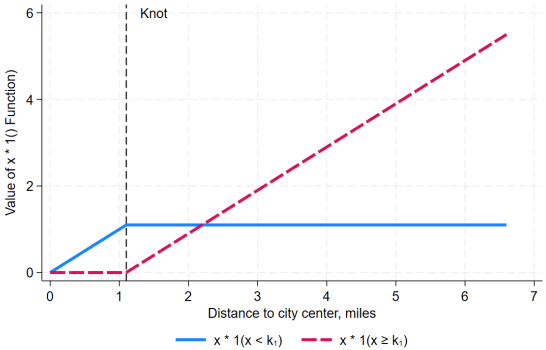
Source	SS	df	MS		
Model	8.4489066	3	2.81630222	Number of obs =	207
Residual	14.911747	203	.073456882	R-squared =	0.3617
				Adj R-squared =	0.3522
Total	23.360654	206	.113401231	Root MSE =	.2710293
				Res. dev. =	42.91267

lnprice	Coefficient	Std. err.	t	P>|t|	[95% conf.	interval]
/a	5.178058	.0621358	83.33	0.000	5.055543	5.300572
/b0	-.5857929	.0880186	-6.66	0.000	-.7593409	-.4122449
/b1	-.0304916	.0245707	-1.24	0.216	-.078938	.0179549
/k1	1.1	.1140877	9.64	0.000	.8750511	1.324949

Note: Parameter **a** is used as a constant term during estimation.

Piecewise Linear Splines - Formel

- In Standardardimplementierungen (z.B. `mkspline` in Stata) werden Korrekturterme nicht geschätzt
  - Implementiert werden diese indem $x \times \mathbb{1}$ Terme auf dem Maximum verweilen. Software erstellt die Variablen entsprechend.
  - $\{\alpha, \beta_1, \beta_2\}$ können somit mittels einer *simple OLS Regression* geschätzt werden
  - $\hat{\beta}_1$ ist der *coefficient* des ersten Terms (dist_1, blau).
  - $\hat{\beta}_2$ ist der *coefficient* des zweiten Terms (dist_2, rot, gestichelt).
  - $\hat{\alpha}$ ist die uebliche Konstante




```
gen lprice ln(price)
mkspline lprice dist_1 1.1 dist_2 = distance
reg lprice dist_1 dist_2
predict lprice_hat
```

Überblick über *piecewise linear splines*

- Bewältigt Nichtlinearität **sehr flexibel**
  - Einschließlich nicht-monotoner Zusammenhänge jeder Art
- **Erfordert** jedoch **Entscheidungen** der Analysten
  - Wie viele Knotenpunkte?
  - Wo sollen sie platziert werden?
  - Entscheidungen basieren auf *scatterplots*, Theorie, oder Geschäftswissen
  - Oft mehrere Versuche
- Algorithmen können bei der Bestimmung der *knots* helfen
  - *Grid search*
  - NLS

Second-order polynomial—Poynome zweiter Ordnung

- Um Nichtlinearität abzubilden, können wir einen quadrierten x-Term hinzufügen
  - Erlauben eine sanfte Änderung der Steigung in x
  - **Weniger flexibel** als ein *piecewise linear spline*, aber **leichter zu implementieren**!

$$y^E = \alpha + \beta_1 x + \beta_2 x^2$$

- Wir approximieren jetzt eine **Parabel**, keine Gerade
  - β_1 hat keine eigene Interpretation,
  - β_2 zeigt, ob die Parabel
    - U-förmig (konvex) ist (wenn $\beta_2 > 0$)
    - umgekehrt U-förmig (oder konkav) ist (wenn $\beta_2 < 0$).

Second-order polynomial—Poynome zweiter Ordnung

- Die ***slope* hängt von** x **ab**!

$$\frac{\partial y^E}{\partial x} = \beta_1 + 2\beta_2 x$$

  - Wenn x um eine Einheit größer ist, ist y im Durchschnitt um $\beta_1 + 2\beta_2 x$ größer.
  - Für das durchschnittliche $x = \overline{x}$ ist die *slope*: $\gamma = \beta_1 + 2\beta_2 \bar{x}$.

- Mit ***higher-order polynomials*** wird die *functional form* **sehr flexibel**

$$y^E = \alpha + \beta_1 x + \beta_2 x^2 + \cdots + \beta_n x^n = \alpha + \sum_{n=1}^{N} \beta_n x^n \Rightarrow \frac{\partial y^E}{\partial x} = \sum_{n=1}^{N} n\beta_n x^{n-1}$$

  - Aber Vorsicht, reagieren empfindlich auf *outlier*...

Welche funktionale Form wählen?—Praxis

1. Folgen die Hauptvariablen (y und x) einer ***normal distribution***?
2. *Scatter plot* mit *predicted values* aus einer ***nonparametric regression***
   - Lowess oder Bin Scatter
3. Angemessene **Transformation wählen**!
   - Wählen Sie eine oder mehrere Möglichkeiten, um **dem sichtbaren Muster gerecht zu werden** (log Transformationen, *piecewise linear spline*, *polynomials* usw.).
     - Berücksichtigen, dass Logarithmus-Transformation evt. nicht möglich ist (negative Werte)
   - **Forschungsfrage** berücksichtigen
     - Geht es nur um *prediction* oder kommt es auf die Interpretation der *slope* an?
4. Vergleichen Sie die Ergebnisse verschiedener Regressionsansätze
   - *robustness checks* (Robustheitsprüfung)

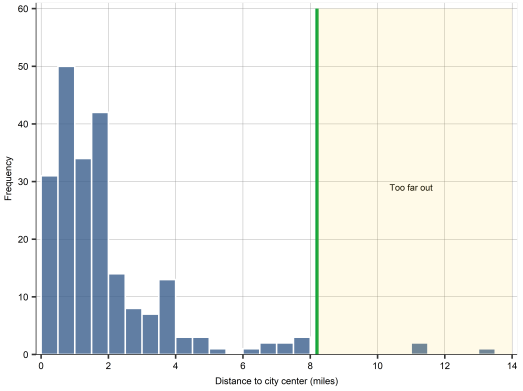
Daten sind unordentlich (*messy*)

- Unproblematische Daten existieren nur in Träumen und in einigen Lehrbüchern...
  - **Daten können auf viele Arten unordentlich sein**!
  - Struktur und Speichertyp unterscheiden sich von dem, was wir möchten.
  - Einige Beobachtungen haben *extreme values*.
  - Wir haben erhebliche **Meßfehler** in unseren Daten

Q: Was ist schlimmer, Meßfehler in der *dependent* oder *independent variable*?

Outlier vs *influential observations*

- *Outlier* (Ausreisser):
  - Beobachtungen mit extremen Werten für eine bestimmte Variable
- ***Influential observations*** (Einflussreiche Beobachtungen)
  - Ihre Einbeziehung oder Auslassung beeinflusst die Regressionsgerade
  - *influential observations* sind *outlier*
  - Aber nicht alle *outlier* sind *influential observations*!
  - Extreme Werte für x **und** *residuals*!
    - Grosse *residuals* in der Nähe von $\bar{x}$ haben weniger Einfluss



Influential observations: Was tun?

- Wenn sie wahrscheinlich aus **Messfehlern** resultieren
  - Dann wollen wir sie eher **löschen**
- Wenn sie **von Natur aus extrem** sind
  - Wollen wir sie eher **nicht löschen**
- Grauzone
  - Sie bilden nicht das *general pattern* ab an dem wir interessiert sind.
- Löschen von Beobachtungen basierend auf dem Wert der y-**Variable vermeiden**
  - Für die gleichen x ändern sich die *predicted values*
- Das Löschen von *extreme values* in x-**Variablen** ist **weniger strittig**
  - Werte können für die analysierte Frage untypisch sein...
  - Können aber auch extreme Variation liefern, aus der wir am meisten lernen können

Classical Measurement Error (klassischer Messfehler)

- Viele Variablen sind schwierig zu messen:
  - Qualität der Hotels, Inflation, andere latente Variablen mit Proxy-Messungen
- Oft entstehen diese Messfehler durch
  - *recording errros* (Aufzeichnungsfehlern beim Eingeben von Daten)
  - *reporting errors* (Falschangaben) in Umfragen oder administrativen Daten
- **'Classical measurement error'**:
  - **Im Durchschnitt null** (beeinflusst nicht den Durchschnitt der gemessenen Variable)
  - ***Mean independent* von allen Variablen** (also keine *correlation*)
- Eines der häufigsten und 'weniger schlimmen' Probleme— aber ein Problem...

Classical Measurement Error: auf x und y kommt es an

- *Classical Measurement Error* in der ***dependent variable***
  - Sollte die **Regressionskoeffizienten nicht beeinflussen**
    - Intuitiv, da für alle x, der *expected value* $E(y|x)$ unverändert bleibt
  - Die geschätzten parameter werden **weniger signifikant**
    - R^2 ist niedriger, weniger Variation in y durch das Modell erklärt
- *Classical Measurement Error* in der ***explanatory variable***
  - Wird die **Regressionskoeffizienten beeinflussen**
    - Es gibt mehr Variation in x, aber die gleiche Variation in y.
    - Gleiches Δx muss im Schnitt eine kleinere Veränderung in y, also $\hat{\beta}$, bedeuten.
  - ***Attenuation bias*** *towards zero* (Schätzer in Richtung Null verzerrt)

Intuitive Darstellung

- Zwei Experimente: Wir addieren $e \sim \mathcal{N}(0,1)$ Fehler zu y und x
  - `gen lnprice_noisy = ln(price) + rnormal(0,1)`
  - `gen lndistance_noisy = ln(distance) + rnormal(0,1)`

Figure: Messfehler in y

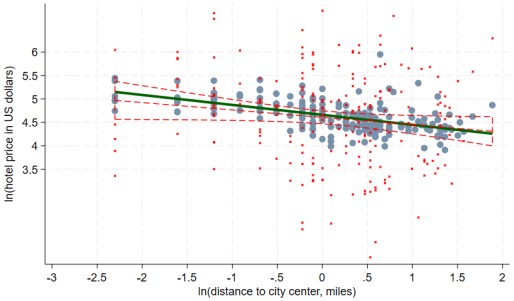
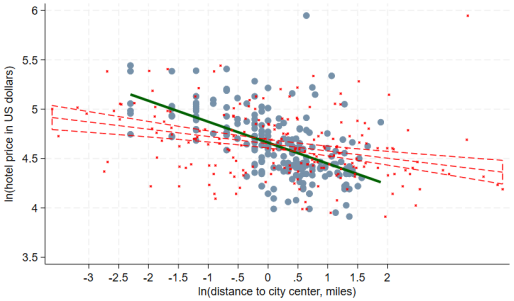


Figure: Messfehler in x



Formale Herleitung—**bitte durchgehen**

Konsequenz

- Oft kann man gegen den Fehler nicht viel tun!
  - Das Problem liegt bei der Datensammlung/wie die Daten generiert werden.
- Wichtig, dass man sich des **Problems und der Wirkungen bewusst** ist
  - **Wo** haben wir in Anbetracht der vermuteten Datenqualität den Fehler?
    - **Falsche *coefficients estimates*** bei Fehler in x
    - **Falsche *standard errors*** bei Fehler in y?
- Gibt es eine Proxy Variable für unser x?
  - Ist diese mit weniger Fehlern gemessen?
  - Dann können wir sie als "**Instrument**" für x benutzen
  - Siehe ***Applied Econometrics***
- *'Non-classical' measurement errors*, verursachen grössere Probleme
  - $cov(e, x) \neq 0 \Rightarrow$ Komplexe Verzerrungen (*bias*)

Summary take-away

- Einfache lineare Regression erfordert of 'Nachbesserung'
  - Um bessere Ergebnisse zu erzielen
- Es kann sich lohnen sich flexibelere *functional forms* in Betracht zu ziehen
  - Helfen uns komplexe Muster zu Erfassen
- Häufig müssen wir mit Datenproblemem umgehen
  - *Influential observations* beeinflussen die *coefficient estimates*
  - *Classic measurement error* beeinflusst *coefficient estimates* oder *standard errors*

Herleitung

- From calculus we know:

$$\lim_{x \to x_0} \frac{ln(x) - ln(x_0)}{x - x_0} = \frac{1}{x_0}$$

- By definition it means a small change in x or $\Delta x = x - x_0$. Manipulating the equation, we get:

$$\lim_{\Delta x \to 0} ln(x_0 + \Delta x) - ln(x_0) = \lim_{\Delta x \to 0} \frac{\Delta x}{x_0}$$

- If Δx is not converging to 0, this is an approximation of percentage changes.

$$ln(x_0 + \Delta x) - ln(x_0) \approx \frac{\Delta x}{x_0}$$

Zurück

Klassischer Messfehler in der abhängigen Variable (y)—I.

- Das bedeutet: $y = y^* + e$
  - Dabei gilt $E[e] = 0$ und e ist *mean independent* von x und y ($E[e \mid x, y] = 0$).
  - Wenn e *mean independent* von x und y ist, dann gilt $Cov[e, x] = 0, Cov[e, y] = 0$)
- **Vergleichen wir die *slope*** des Modells mit
  - einer fehlerfreien abhängigen Variable (y^*)
  - der Steigung derselben Regression, bei der y mit einem Fehler gemessen wird (y).

$$y^* = \alpha^* + \beta^* x + u^*$$
$$y = \alpha + \beta x + u$$

  - Die *slope coefficients* in den beiden Regressionsmodellen sind:

$$\beta^* = \frac{Cov[y^*, x]}{Var[x]}, \qquad \beta = \frac{Cov[y, x]}{Var[x]}$$

Klassischer Messfehler in der abhängigen Variable (y)—II.

$$\beta = \frac{Cov\left[y, x\right]}{Var\left[x\right]} = \frac{Cov\left[\left(y^* + e\right), x\right]}{Var\left[x\right]} = \frac{Cov\left[y^*, x\right] + Cov\left[e, x\right]}{Var\left[x\right]} = \frac{Cov\left[y^*, x\right]}{Var\left[x\right]} = \beta^*$$

- ***Slopes* sind gleich**
  - Entscheidend ist das—annahmegemäss— $Cov\left[e, x\right] = 0$
- *Classical measurement error* beeinflusst nicht die geschätzten Parameterwerte
  - Es senkt jedoch R^2, indem es die *residuals* $u = u^* + e$ vergrössert.

Klassischer Messfehler in der unabhängigen Variable (x)—I

- Das bedeutet: $x = x^* + e$
  - Dabei ist $E[e] = 0$ und e ist im Mittel unabhängig von y und x, sodass
  - $Cov[e, y] = 0$, $Cov[e, x] = 0$.
- **Vergleichen wir die *slopes***, wobei
  - x^* die fehlerfreie unabhängige Variable ist und
  - x mit Fehlern gemessen wird.

$$y = \alpha^* + \beta^* x^* + u^*$$
$$y = \alpha + \beta x + u$$

  - Die *slope coefficients* in den beiden Regressionsmodellen sind:

$$\beta^* = \frac{Cov[y, x^*]}{Var[x^*]}, \qquad \beta = \frac{Cov[y, x]}{Var[x]}$$

Klassischer Messfehler in der unabhängigen Variable (x)—II.

$$\begin{aligned}\beta &= \frac{Cov\left[y,x\right]}{Var\left[x\right]} = \frac{Cov\left[y,(x^*+e)\right]}{Var\left[x^*+e\right]} = \frac{Cov\left[y,x^*\right]+Cov\left[y,e\right]}{Var\left[x^*\right]+Var\left[e\right]} = \frac{Cov\left[y,x^*\right]}{Var\left[x^*\right]+Var\left[e\right]} \\ &= \frac{Cov\left[y,x^*\right]}{Var\left[x^*\right]}\frac{Var\left[x^*\right]}{Var\left[x^*\right]+Var\left[e\right]} \\ &= \beta^*\frac{Var\left[x^*\right]}{Var\left[x^*\right]+Var\left[e\right]}\end{aligned}$$

- $\beta \neq \beta^*$, daher handelt es sich um eine 'Verzerrung' (*bias*)
- Wir nennen es die '***attenuation bias***' (Abschwächungsverzerrung)
  - Da der Fehler β näher an null heranrückt ($Var[e] > 0$)

Klassischer Messfehler in der unabhängigen Variable (x) - III.

- Die Steigungsbeiwerte sind unterschiedlich in Anwesenheit eines klassischen Messfehlers in der unabhängigen Variablen.
  - Der Steigungsbeiwert in der Regression mit einer fehlerbehafteten unabhängigen (x) Variable ist im absoluten Wert kleiner als der Steigungsbeiwert in der entsprechenden Regression mit einer fehlerfreien unabhängigen Variable.

$$\beta = \beta^* \frac{Var\left[x^*\right]}{Var\left[x^*\right] + Var\left[e\right]}$$

  - Das Vorzeichen der beiden Steigungen ist gleich
  - Aber die Beträge unterscheiden sich.
- Konsequenz: **im Durchschnitt** ist β^* **näher an null, als es sein sollte**.

Effekt eines verzerrten Parameters

- Abschwächung des Verzerrungskoeffizienten in der Steigung:

$$\beta = \beta^* \frac{Var\left[x^*\right]}{Var\left[x^*\right] + Var\left[e\right]}$$

  - **Daher ist β im Betrag kleiner als β^***
- **Als Konsequenz ist auch α verzerrt**

$$\alpha = \bar{y} - \beta\bar{x}$$

- Wenn ein Parameter verzerrt ist, ist normalerweise auch der andere verzerrt
  - Der Wert des Achsenabschnitts ändert sich in die entgegengesetzte Richtung!
  - β ist näher an null, α ist weiter von α^* entfernt

Klassischer Messfehler in der unabhängigen Variable (x)

- Ohne Messfehler: $\alpha^* = \bar{y} - \beta^* \overline{x^*}$
- Mit Messfehler: $\alpha = \bar{y} - \beta \bar{x}$
- *Expected values* (*means*) unverändert, daher gilt: $\bar{x} = \overline{x^*}$
- **Beide Regressionen verlaufen durch denselben Punkt** $(\bar{x}, \bar{y})$
  - Somit ist die **Differenz zwischen den beiden Achsenabschnitten**:

$$\alpha = \bar{y} - \beta\bar{x} = \alpha^* + \beta^*\overline{x^*} - \beta\bar{x} = \alpha^* + \beta^*\bar{x} - \beta\bar{x} = \alpha^* + (\beta^* - \beta)\,\bar{x}$$
$$= \alpha^* + \left(\beta^* - \beta^* \frac{Var\,[x^*]}{Var\,[x^*] + Var\,[e]}\right)\bar{x} = \alpha^* + \beta^*\bar{x}\frac{Var\,[e]}{Var\,[x^*] + Var\,[e]}$$

Überblick zum *classical measurement error*

- *Classical measurement error* in der ***dependent variable***
  - **Keine *bias***, aber größere *standard errors* da größere *residuals*
- *classical measurement error* in der ***explanatory variable***
  - Größere Variation von x
  - ***Attenuation bias*** in β—Verzerrung nach unten
    - näher bei null / kleiner im absoluten Wert
  - Sollten **Schätzung als untere (obere) Grenze des wahren Parameters interpretieren**, wenn Ihr Vorzeichen positiv (negativ) ist
    - Wenn wir zwei Beobachtungen vergleichen, die sich in x um eine Einheit unterscheiden, ist die wahre Differenz in x^* wahrscheinlich geringer als eine Einheit. (Größere Variation in x)
    - Daher sollten wir eine geringere Differenz in y erwarten, die mit Unterschieden in x in Verbindung steht, als mit Unterschieden in der wahren Variable x^*. (Verzerrter Parameter)

Konsequenz