09 Verallgemeinerung aus Regressionsergebnissen

Gabriel M. Ahlfeldt

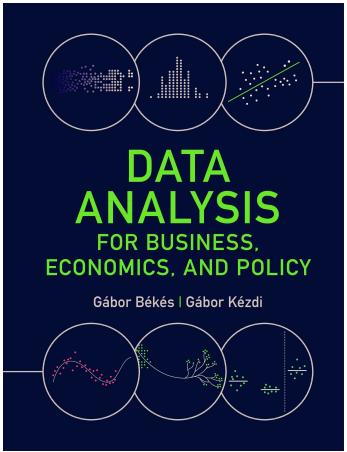
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 09**

Verallgemeinerung: Recap

- Wir haben *generalization* (Verallgemeinerung) im Kontext von *descriptive statistics* behandelt (Thema 5)
- Was ist hängen geblieben?

Q: Was ist ein *confidence interval* und wie berechnen wir es?

Verallgemeinerung: Erinnerung

- **Repräsentieren** unsere Daten das ***general pattern*** an dem wir interessiert sind?
  - Oder handelt es sich um einen Sonderfall?
- ***Statistical inference***
  - Gilt das Muster das wir finden im *general pattern*, das unsere Daten repräsentieren?
    - Fallen Hotelpreise generell in Wien, wenn wir uns vom Stadtzentrum entfernen?
- ***External validity***
  - Gilt das *general pattern*, das die Daten repräsentieren, in einem **anderen Kontext**?
    - Das Preis-Distanzmuster in Wien finden, sollte auch in anderen Städten gelten?

Generalizing Linear Regression Coefficients

- Wir haben ein einfaches lineares **Modell geschätzt**
  - *Slope* $\hat{\beta}$
    - der durchschnittliche Unterschied in y **im Datensatz** zwischen Beobachtungen, die sich um eine Einheit in Bezug auf x unterscheiden.
  - *Predicted value* $\hat{y}_i$
    - die beste Schätzung für den *expected value* (*conditional mean*) der *dependent variable* für die Beobachtung i mit dem Wert x_i **im Datensatz**.
- Jetzt wollen wir sicherstellen, dass die Ergebnisse
  - nicht nur eine zufällige Realisierung darstellen
  - sondern das *general pattern* im voliegenden Kontext **gut repräsentieren**

Statistical Inference: Confidence Interval

- Das **95% *confidence interval* des *slope parameters*** einer *linear regression*:
  - ähnelt der Schätzung eines 95% Konfidenzintervalls für jede andere Statistik.

$$CI(\hat{\beta})_{95\%} = \left[\hat{\beta} - 1.96SE(\hat{\beta}), \hat{\beta} + 1.96SE(\hat{\beta})\right]$$

  - Oft runden wir 1.96 auf 2, um uns das Leben einfacher zu machen.
- Der ***standard error*** des *slope coefficient* (Steigungskoeffizient)
  - ist konzeptionell dasselbe wie der SE jeder anderen *statistic*.
  - misst die **Streuung** der Werte der *statistic* über **hypothetische *repeated samples***, die aus einem *general pattern* gezogen werden
    - Das können wir nicht wirklich tun, da wir das *general pattern* nicht beobachten
    - Aber wir können *bootstrap samples* aus unseren Daten ziehen (siehe Thema 5).
    - Oder eine einfache Formel verwenden.

Standard Error des *slope coefficient*

Die einfache Formel für den SE lautet:

$$SE(\hat{\beta}) = \frac{Std\,[e]}{\sqrt{n} Std\,[x]}$$

- Wobei:
  - *residual*: $e = y - \hat{\alpha} - \hat{\beta}x$
  - Std[e], *standard deviation* des *residual*,
  - Std[x], *standard deviation* der *explantory variable*,
  - $\sqrt{n}$ die Quadratwurzel der Anzahl der Beobachtungen in den Daten.
    - In kleineren Samples wird auch $\sqrt{n-2}$ verwendet.

- Ein **kleinerer *standard error*** führt zu
  - schmaleren *confidence intervals*,
  - *estimates* der *slope coefficients* mit *mehr precision* (Präzision)
- **Mehr *precision*** wenn
  - *standard deviation* des *residual* kleiner, d.h. besserer *fit*.
  - *standard deviation* der *explanatory variable* groß - mehr Variation in x
  - mehr Beobachtungen in den Daten vorhanden sind.
- Diese Formel setzt *homoskedasticity* (Homoskedastizität) voraus.

Heteroskedasticity Robust (Heteroskedastizitätsrobuste) SE

- ***Homoskedasticity***:
  - ***Residuals*** sind für verschiedene Werte von x **ähnlich gross**
  - Oft trifft dies nicht zu. Betrifft nur SE und CI, nicht $\hat{\beta}$, nicht R^2
- ***Heteroskedastizität***:
  - Die Streuung der *residuals* variert mit x (z.B. wenn proportional zu x)
- ***Heteroskedasticity Robust* SE** (*White oder Huber*) sind **immer korrekt**
  - **Wichtiges Praxiswissen**: Immer schön "`reg y x , robust`" verwenden...
  - Nerdwissen
    - White-Formel berechnet quadratische *residuals* aus dem geschätzten Modell und nutzt diese als Gewichte für die Beobachtungen bei der Berechnung des $SE[\hat{\beta}]$
    - Es gibt viele robuste Schätzer, die unterschiedliche Gewichtungstechniken verwenden. Normalerweise bezeichnet als 'HC0', 'HC1', ..., 'HC4'.

Case Study: Gender gap in earnings?

- Das Einkommen wird von vielen Faktoren bestimmt.
- Gibt es ein *gender gap* (Geschlechterlücke)?
  - Systematische Lohnunterschiede zwischen männlichen und weiblichen Arbeitnehmern?

Q: Gibt es ein *gender pay gap* und, wenn ja, wie groß ist es?

Case Study: Gender gap—How data is born?

- **Current Population Survey (CPS)** der USA
  - Administrative Daten
  - Grosses Sample von Haushalten
- Monatliche Befragungen
  - Rotierende Panelstruktur: Befragung in 4 aufeinander folgenden Monaten, dann 8 Monate lang nicht befragt, anschließend wieder Befragung in 4 aufeinander folgenden Monaten
  - Wöchentliche Einkommen werden in der "outgoing rotation group" erfasst
    - Im letzten Monat jedes 4-Monats-Zeitraums
  - Mehr zu MORG: „Merged outgoing rotation group“
- *Sample restrictions* (Samplebeschränkungen)
  - Stichprobe umfasst Personen im Alter von 16-65 Jahren
  - Erwerbstätige Personen (mit Einkommen)
  - Selbstständige ausgeschlossen

Case Study: Gender gap—the data

- Heruntergeladene Daten für das Jahr 2014 (316.408 Beobachtungen)
  - Nach *Sample restrictions* $N = 149.316$
- **Wöchentliche** Einkommen in der CPS
  - Vor Steuern
  - Obere Einkommensgrenze (top-coded) für hohe Einkommen
    - bei \$2.884,6 (pro Woche)
  - Jährliche Boni und geldwerte Vorteile werden nicht erfasst.
- Wir müssen natürlich die Arbeitsstunden berücksichtigen
  - Frauen könnten mehr oder weniger arbeiten als Männer.
- Wir teilen die wöchentlichen Einkommen durch die "üblichen" wöchentlichen Arbeitsstunden (in der Befragung erfasst)

Case Study: Gender gap—conditional descriptives

Geschlecht	Durchschnitt	p25	p50	p75	p90	p95
Männlich	$ 24	13	19	30	45	55
Weiblich	$ 20	11	16	24	36	45
% Unterschied	-17%	-16%	-18%	-20%	-20%	-18%

```
collapse (mean) mean_w = w (p25) p25_w = w (p50) p50_w = w (p75) p75_w = w ///
(p90) p90_w = w (p95) p95_w = w ,by(sex)
```

- Frauen verdienen im Schnitt 17% weniger als Männer
- Für die lineare Regressionsanalyse werden wir den natürlichen Logarithmus des Lohns verwenden, um den relativen Unterschied zu schätzen.

Case Study: Gender gap in comp science occupation—Analysis

- Wir schauen uns nur einen Beruf an: Informatik (*Computer scientists*), $N = 4.740$
  - Frauen könnten in Sektoren/Berufen arbeiten, in denen weniger bezahlt wird

$$\ln(w_i) = \alpha + \beta \times \mathbf{G}_i^{female} + \varepsilon_i$$

  - G_i hat den Wert eins, wenn die Person weiblich ist, und null, wenn sie männlich ist
  - ε_i ist das *residual*
- Code
  - `gen female=sex==2`
  - `gen w = earnwke/uhours`
  - `gen lnw=ln(w)`
  - `reg lnw female, robust`

Case Study: Gender gap in comp science occupation—Analysis

- Log-level *point estimate* (Punktschätzer) ist $\hat{\beta} = -0.1475$
  - **Weibliche Mitarbeiter in der Informatik verdienen in diesem Datensatz im Durchschnitt 14,7% weniger als Männer** mit dem gleichen Beruf
    - Genau genommen $(\exp(-0.147) - 1) \times 100 = -13.7\%$
    - `local pc_effect = round( (exp(_b[female])-1)*100, 0.1)`
    - `display "‘pc_effect’%"`
- *Statistical inference* basierend auf Daten aus dem Jahr 2014.
  - SE: .0177; 95% CI: [-.182 -.112]
    - Simple vs robust SE - Hier gibt es keinen wesentlichen Unterschied.

Case Study: Gender gap in comp science occupation—Generalizing

- Im Jahr 2014 in den USA
  - Das *general pattern*, dass durch die Daten repräsentiert wird
  - Wir beobachten nicht die *population*, "nur" ein *representative sample*
- **Auf Grundlage des 95% CI gilt**:
  - Wir sind zuversichtlich, dass der **durchschnittliche Unterschied** im Stundenlohn zwischen weiblichen und männlichen Mitarbeitern im Bereich der Informatik **zwischen -18,2% und -11,2%** liegt
  - Streng genommen:
    - Bei wiederholten Stichproblem enthält das CI in 95% der Fälle den wahren Wert
- Dieses *confidence interval* enthält **nicht** die Null.
  - Daher können wir mit 95%iger *confidence* (Sicherheit) ausschließen, dass die durchschnittlichen Einkommen der Geschlechter gleich sind
  - Wir können dies auch mit 99%iger *confidence* ausschließen.

Case Study: Gender gap in market analyst occupation

- Market research analysts and marketing specialists (Marktforschungsanalytiker und Marketing-Spezialisten)
  - $N = 281$, davon 61% Frauen, durchschnittlicher Stundenlohn beträgt \$29 (sd:14.7)
- *Point estimate* (Punktschätzer) ist $\hat{\beta} = -0.113$:
  - **Frauen verdienen 11.3 Prozent wengiger als Männer** in diesem Datensatz
- *Generalization*:
  - $SE[\hat{\beta}]$: .061; 95% CI: [-.23 +0.01]
    - Mit 95%iger Zuversicht liegt das Gender Gap zwischen -23% und +1%
  - **Dieses CI enthält die Null**. Wir können **nicht** mit 95%iger Sicherheit ausschließen, dass die durchschnittlichen Einkommen gleich sind ($p - value = 0,068$)
  - Wahrscheinlicher ist jedoch, dass weibliche Marktforscherinnen weniger verdienen.
    - Wir können mit 90%iger Sicherheit ausschließen, dass das Gender Gap Null ist
    - Genau genommen mit 1-0.068=93.2%iger Sicherheit...

Testen, ob (wahrer) Beta-Wert null ist

- *Null* und *alternative hypotheses*: $H_0 : \beta_{true} = 0,\ H_A : \beta_{true} \neq 0$
  - t-stat: $t = \frac{\hat{\beta} - 0}{SE(\hat{\beta})}$
  - Wenn t-stat $>$ 1.6 / 1.96 / 2.6, dann *p-value* $<$ 10%, 5%, 1%
- Wir sagen dann
  - "***The estimated coefficient is significant at the 1% level***".
  - "***The estimated coefficient is significant at the 5% level***".
  - "***The estimated coefficient is significant at the 10% level***".
  - und markieren den geschätzten Parameterwert mit $^*/^{**}/^{***}$
- In einer **Regressionstabelle** ist
  - -0.1475^{***} **gleichbedeutend** mit
  - Der Punktschätzer ist 0.1475 und **die Null liegt ausserhalb des 99% CI**"

Vergleich zwischen den Samples

- **Informatik**- und mathematische Berufe
  - 4740 Mitarbeiter, Frauenanteil: 27,5%
  - Geschätztes Gender Gap: $\hat{\beta} =$ **-0,1475, SE = 0.0177** ; 95% CI: [-.1823 -.1128]
- **Marktforschung**sanalystinnen und Marketing-Spezialistinnen
  - 281 Mitarbeiter, Frauenanteil: 61%
  - Geschätztes Gender Gap: $\hat{\beta} =$ **-0,113, SE = 0.061**, 95% CI: [-.23 +0.01]

Q: Ist das Gender Gap in Marketing kleiner als in Informatik?

Vergleich zwischen den Samples

- *Null* und *alternative hypotheses*: $H_0 : \beta^{Inf}_{true} - \beta^{Mar}_{true} = 0, \beta^{Inf}_{true} - \beta^{Mar}_{true} \neq 0$
  - t-stat: $t = \frac{\hat{\beta}^{Inf} - \hat{\beta}^{Mar}}{SE(\hat{\beta}^{Inf} - \hat{\beta}^{Mar})} = \frac{\hat{\beta}^{Inf} - \hat{\beta}^{Mar}}{\sqrt{SE(\hat{\beta}^{Inf})^2 + SE(\hat{\beta}^{Mar})^2}} = \frac{-0{,}1475 - (-0{,}113)}{\sqrt{0.0177^2 + 0.061^2}} = -0.54$
    - Etwas anders als *t-test* auf *mean difference* zwischen zwei samples (Thema 5)
    - *Standard deviation* muss für *sample size* adjusted werden, *standard error* ist das schon
  - Deutlich unter den kritischen Werten $(|1,6|, |1,92|, |2,6|) \Rightarrow$ ***not statistically significant***
- Woran liegt es?
  - Vielleicht ist das Gender Gap **wirklich gleich?**
  - **Vielleicht haben wir auch nur nicht genug Beobachtungen**
    - SE viel groesser (0.061 vs. 0.0177) für Marketing
    - dabei viel weniger Beobachtungen (281 vs. 4740)

Zufallseffekte und Datensatzgröße

- **Mehr Beobachtungen führen generell zu kleineren *standard errors***
  - Einfache Formel: $SE(\hat{\beta}) = \frac{Std[e]}{\sqrt{n}Std[x]}$
- Das Finden zufälliger Muster ist bei mehr Beobachtungen weniger wahrscheinlich
  - Einzelne ***influencial observations*** **weniger einflussreich**
  - Die Auswirkungen von **idiosynkratischen Ereignissen können sich ausgleichen**
  - **Idiosynkratische Besonderheiten** von Personen oder Objekten können sich ausgleichen
- Hinzufügen von Beobachtungen hilft nur, wenn
  - Fehler und Besonderheiten nicht alle zusätzlichen Beobachtungen gleich betreffen
  - Zusätzliche Beobachtungen aus einer geeigneten Quelle stammen
    - Also Fehler in der zusätzlichen Quelle nicht systematisch grösser sind
- **Vorsicht bei sehr großen Datensätzen** (ökonomische Signifikanz entscheidend)

Prediction uncertainty (Prognoseunsicherheit)

- ***Prediction***
  - Wir wollen y für Werte von x **vorhersagen**, die nicht in unserem Datensatz auftauchen
  - Dafür nutzen wir die *coefficient estimates* (Schätzwerte der Koeffizienten)
- Grundlage ist die lineare Regression:

$$y_i = \hat{\alpha} + \hat{\beta} x_i + \epsilon_i, \text{ wobei } i \text{ Beobachtungen indiziert}$$

- Der ***predicted value*** $\hat{y}_j$ für eine Beobachtung j mit Wert x_j lautet:

$$\hat{y}_j = \hat{\alpha} + \hat{\beta} x_j$$

- **Achtung**:
  - ***Confidence interval* des *predicted value*** berücksichtig nur die Unsicherheit in $\hat{\alpha}, \hat{\beta}$
  - ***Prediction interval*** (Prognoseintervall) beruecksichtigt Unsicherheit in $\hat{\alpha}, \hat{\beta}$ *und* ϵ_i

Confidence interval der *regression line* I.

- **Confidence interval (CI) des *predicted value*** = das CI der *regression line*
  - Der *predicted value* $\hat{y}_j$ basiert nur auf $\hat{\alpha}$ und $\hat{\beta}$.
  - **Kombiniert die CIs für $\hat{\alpha}$ und $\hat{\beta}$**
- Misst die Unsicherheit im **expected value**, $\hat{y} = E(y|x)$
  - Wo können wir mit grosser Sicherheit erwarteten, dass $\hat{y}$ **im CI** liegen wird
    - Z.B. **durchschnittlicher Preis** aller (vieler) Hotels in einer Entfernung von 1km
  - Misst **nicht** die Unsicherheit wenn wir den tatsächlichen Wert y_j voraussagen
    - Z.B. der **tatsächliche Preis** eines (von vielen) Hotels j (mit $x_j = 1$) => *prediction interval*

Confidence interval der *regression line* II.

- Der *predicted value* von y hat folgenden *standard error (homeostaticity)*:

$$95\% CI(\hat{y}_j) = \hat{y} \pm 1.96 SE(\hat{y}_j)$$

$$SE(\hat{y}_j) = Std[e] \sqrt{\frac{1}{n} + \frac{(x_j - \bar{x})^2}{nVar[x]}}$$

  - **Das CI ist klein**, wenn:
    - **SE klein** (gilt wenn $Std[e]$ klein und $Std[x]$ gross).
    - x_j nahe am *mean* von x (zentral im *scatter plot*)
    - Die Zahl Beobachtungen n gross ist
  - Beachte: n **ist hier noch wichtiger als bei der Berechnung des CI des *coefficients*** β

- Zur Berechnung des korrekten SE des *predicted value* unter *heteroscedasticity*:
  - `reg y x, robust`
  - `predict SE_yhat, stdp`

Case Study: Earnings and age—regression table

Modell:

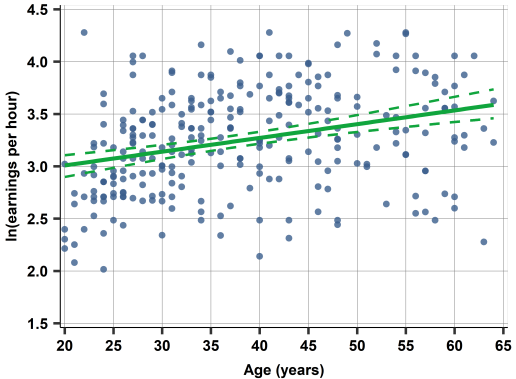
- ln *wage* $= \alpha + \beta$ *age*
  - Arbeitnehmer, die **ein Jahr älter** sind, **verdienen 1.4% mehr**
  - *Significant at the 5% level*
- Nur eine Branche: Marktanalysten, $N = 281$

VARIABLES	ln wage
age	0.014**
	(0.003)
Constant	2.732**
	(0.101)
Observations	281
R-squared	0.098

*Notes: Robust standard errors in parentheses *** p<0.01, ** p<0.05, * p<0.1.*
(Robuste Standardfehler in Klammern *** p<0.01, ** p<0.05, * p<0.1.)

Case Study: Earnings and age—CI of regression line

- Log Einkommen (earnings) und Alter (age)
  - Linearität ist natürlich nur eine Annäherung
- **Enges CI**, da SE klein ist
- "**Hourglass shape**" (Sanduhrartige Form)
  - CI ist kleiner wenn x_j näher am *mean* von x



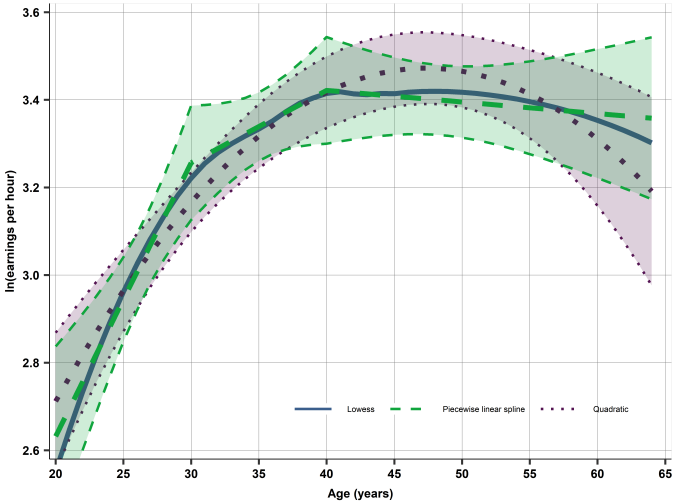
Confidence interval der *regression line*: Nichtlinearität

- CI des *predicted value* kann auch für nichtlineare Modelle berechnet werden
  - Spline, Polynom
  - Standardsoftwarepakete machen das für uns
  - Dabei gilt immer, dass das **CI enger** ist
    - Je kleiner $Std[e]$,
    - Je größer n und
    - Je größer $Std[x]$
- Das CI für den prognostizierten Wert ist immer ein **Intervall**
  - Gibt an **wo wir** $E(y|x)$ **im *general pattern* erwarten**
    - Im *general pattern*, das durch die Daten repräsentiert wird,

Case Study: Earnings and age—different functional form with CI

- Nichtlineare Approximationen:
  - Lowess
  - Piecewise linear spline
  - quadratic function
- 95% CI dashed lines

Q: Vor- und Nachteile der *functional forms*?

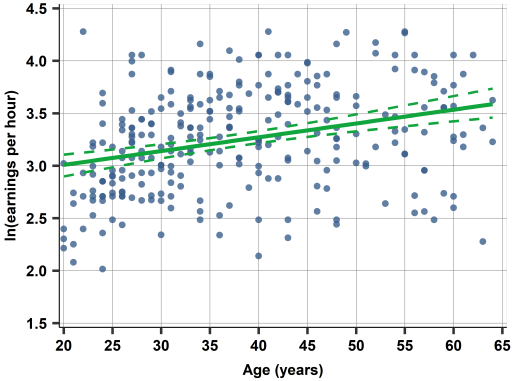


Prediction interval (Prognoseintervall)

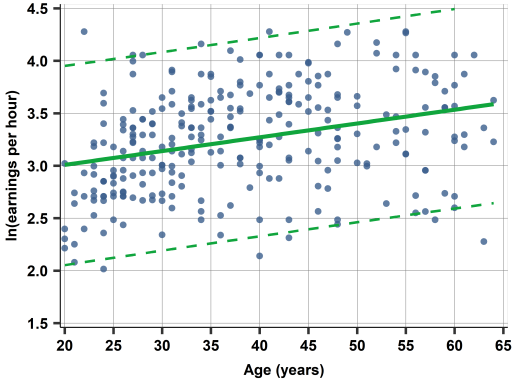
- Das *Prediction interval (PI)* gibt an:
  - **Wo wo wir den tatsächlichen Wert y_j erwarten**, wenn wir den entsprechenden Wert x_j kennen und die Schätzungen der Regressionskoeffizienten aus den Daten haben.
- Unterschied zwischen CI und PI.
  - Das CI des *predicted value* bezieht sich auf $\hat{y}_j$: wo wir den **durchschnittlichen Wert** der abhängigen Variable erwarten können, wenn wir x_j kennen.
  - Das PI des *predicted value* bezieht sich auf y_j selbst, nicht auf seinen Durchschnittswert: wo wir den **tatsächlichen Wert** von y_j erwarten können, wenn wir x_j kennen.
- Das PI **berücksichtigt zusätzliche Unsicherheit** (in $Std[\epsilon_i]$)
  - **Tatsächlicher Wert von y_j weicht von seinem Erwartungswert $E(y|x)$ ab**

Confidence interval vs Prediction interval

Confidence interval



Prediction interval



Mehr zum *prediction interval*

- Die Formel fuer das 95% PI ist

$$95\%PI(\hat{y}_j) = \hat{y} \pm 1.96SPE(\hat{y}_j)$$

$$SPE(\hat{y}_j) = Std[e]\sqrt{1 + \frac{1}{n} + \frac{(x_j - \bar{x})^2}{nVar[x]}}$$

  - SPE = *Standard Prediction Error* (Standardfehler der Prognose)
- **Beachte**:
  - $\lim_{n\to\infty} \text{SE} = 0$
  - $\lim_{n\to\infty} \text{SPE} = Std[e]$

- **SPE** erfasst gegenuber dem **SE** **zusätzliche Unsicherheit**, da der **tatsächliche Wert** y_j **um seinen Durchschnittswert** $\hat{y}$ **verteilt** sein.
  - Der Umfang wird von der *standard deviation* des *residual* bestimmt.
  - Im Limit **konvergiert** der **SE** bei unndlich vielen Beobachtungen **gegen Null**. Wir liegen beim Erwartungswert immer richtig.
  - Das gilt nicht fuer den **SPE**. Auch bei unendlich vielen Beobachtungen **streuen mögliche Ausprägungen von** y_j **um** $\hat{y}_j$.

External validity

- ***Internal validity***
  - Sind die Ergebnisse im **vorliegenden Kontext** gütlig?
  - ***Statistical inference*** bezieht sich auf *internal validity*
    - Es geht geht um das *general pattern*, das **unsere Daten repräsentieren**
- ***External validity***
  - Gelten die Ergebnisse auch in einem **anderen Kontext**?
    - andere Zeiten, Länder, Personen, Unternehmen?
  - Antwort lässt sich **nicht aus unseren Daten ableiten**
    - Müssen nachdenken, kritisch hinterfragen, argumentieren, Annahmen treffen und hoffen...
  - Analyse **anderer Datesätze** kann aber hilfreich sein...

Stability of hotel prices—idea

- Wir haben geschätzt wie Hotepreise mit der Entfernung vom Stadtzentrum abnehmen
  - Für **Wien, im November, an Wochentagen**
- Gilt die geschätzte Preis-Entfernungs-Beziehung auch **in anderen Situationen?**
  - Andere Zeitpunkte (hier)
  - Andere Städte (in der Übung)
  - Andere Arten von Unterkünften: Apartments (auch spannend)
- Wenn die geschätzten Parameter ähnlich sind, deutet das auf **external Validity** hin
  - Wir können die Parameterwerte an in anderen Kontexten nutzen
    - Wir könnten zwei beliebige Hotels (egal wann und Wo) vergleichen und fragen:
    - Rechtfertigt der Unterschied in der Entfernung den Preisunterschied?

Benchmark model

- *Piecewise linear spline* mit einem *knot* nach 2 Meilen.

$$\ln(y_i) = \alpha_1 + \beta_1(x_i \mathbb{1}_{x_i<2m}) + [\beta_1 k_1 \mathbb{1}_{x \geq k_1}] + \beta_2(x_i \mathbb{1}_{x_i \geq 2m}) + \epsilon_i$$

  - Daten: 2017, November, Wochentag, Wien, 3-4-Sterne-Hotels, innerhalb von 8 Meilen.
    - `mkspline dist_0_2 2 dist_2_7 = distance`
    - `reg lnprice dist_0_2 dist_2_7 if date=="2017-NOV-weekday", robust`

- Geschätzte Parameterwerte: $\alpha = 5.02$, $\beta_1 = -0.31$, $\beta_2 = 0.02$
  - α: Die durchschnittlichen Hotelpreise in der Innenstadt betragen 151,41 Euro (exp(5,02))
  - β_1: Innerhalb von 2 Meilen, fällt der durchschnittliche Hotelpreise um 0,31 Log-Einheiten oder 26.7% $= (exp(-0,31) - 1)$ pro Meile
  - β_2: Ausserhalb von 2 Meilen, steigt der durchschnittliche Hotelpreise um 2% pro Meile

Comparing dates

VARIABLES	(1) 2017-NOV-weekday	(2) 2017-NOV-weekend	(3) 2017-DEC-holiday	(4) 2018-JUNE-weekend
dist_0_2	-0.31**	-0.44**	-0.36**	-0.31**
	(0.038)	(0.052)	(0.041)	(0.037)
dist_2_7	0.02	-0.00	0.07	0.04
	(0.033)	(0.036)	(0.050)	(0.039)
Constant	5.02**	5.51**	5.13**	5.16**
	(0.042)	(0.067)	(0.048)	(0.050)
Observations	207	125	189	181
R-squared	0.314	0.430	0.382	0.306

Note: *Robust standard errors in parentheses* *** $p<0.01$, ** $p<0.05$, * $p<0.1$
Source: `hotels-europe` data. Vienna, reservation price for November and December 2017, June in 2018

Comparing dates–interpretation

- **Teilweise** hohe *external validity*
  - Wochentag im November und das Wochenende im Juni gleich: $\hat{\beta}_1 = 0.31$
  - Ergebnisse für Ferien im Dezember sind nah dran (-0.36 Logarithmuseinheiten)
    - CIs überlappen sich stark (statistisch können wir die *point estimates* nicht unterscheiden)
- Anders für das Wochenende im November:
  - 0.44 Log-Einheiten oder 55% ($exp(0.44) - 1$) niedrigerer Durchschnittspreis pro Meile
    - Beide *estimated coefficients* sind signifikant von null verschieden (auf dem 5% *level*)
    - Sie sind aber nicht signifikant von verschieden von einander $t = \frac{\beta_1 - \tilde{\beta}_1}{\sqrt{SE(\beta_1)^2 + SE(\tilde{\beta}_1)^2}} = 0.93$
  - **Ökonomisch** ist der Unterschied aber auf jeden Fall **relevant**!
    - **Wir sollten nicht auf Grund von Insignifikanz auf *external validity* schliessen**

Zusammenfassung

- Nach Regressionen wollen allgemein **Verallgemeinern**
  - Rückschlüsse von unseren Daten auf das *general pattern* ziehen
- Zuerst betreiben wir ***statistical inference***
  - Dazu nutzen wir die vorliegenden Daten
  - Repräsentiert das Muster in den Daten das *general pattern* in **unserem Kontext**?
- Danach setzten wir uns mit der Frage nach ***external validity*** auseinander
  - Gelten die Ergebnisse auch in einem **anderen Kontext** gelten, der uns interessiert?
  - Wir müssen die die Übertragbarkeit theoretisch erörtern und kritisch hinterfragen
  - Ähnliche Ergebnisse in anderen Daten zu dokumentieren ist hilfreich