10. Multiple Regression

Gabriel M Ahlfeldt

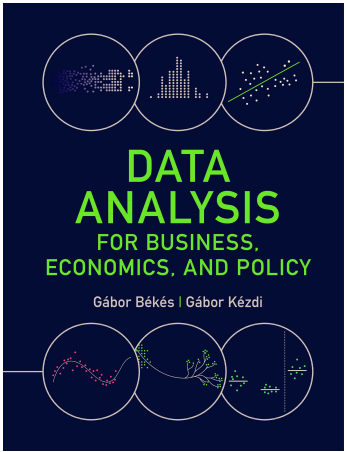
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 10**

Motivation

- Lässt sich das Gender Gap dadurch **erklären**, dass die beobachteten Frauen und Männer sich **in anderen Atributen** unterscheiden? Dafür müssen wir das Gender Gap **schätzen und gleichzeitig andere Attribute konstant halten**
- Könnten sich andere Attribute, z.b. Erfahrung, anders auf die Löhne von Frauen und Männern auswirken? Dafür müssen wir **Interaktionen berücksichtigen**.

Multiple Regression—Der Fall mit zwei Regressoren

$$y^E = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

- β_1, der *slope coefficient* von x_1:
  - Die Differenz im Durchschnitt von y wenn sich x_1 um eine Einheit unterscheidet
  - aber x_2 **konstant gehalten wird**
- β_2, der *slope coefficient* von x_2:
  - Die Differenz im Durchschnitt von y wenn sich x_2 um eine Einheit unterscheidet
  - aber x_1 **konstant gehalten wird**
- Wir machen **Beobachtungen** im Hinblick auf andere Attribute x_{-i} **vergleichbar**
  - während wir die Beziehung zwischen x_i und y schätzen
    - `reg y x1 x2, robust`

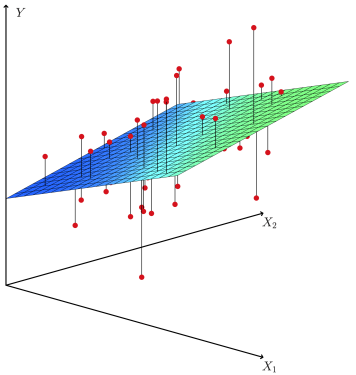
Multiple Regression—Visuelle Darstellung

Mit zwei erklärenden Variablen bedeutet dies visuell, eine lineare Ebene anzupassen:

- Wir minimieren die *objective function: Sum of squared residuals residuals*:

$$\arg \min_{\beta_0,\beta_1,\beta_2} \sum_{i=1}^{N} (y - \beta_0 - \beta_1 x_1 - \beta_2 x_2)^2$$

- Mit K Variablen passen wir eine K-dimensionale Ebene an!
  - Die multiple Regression zu visualisieren kann knifflig sein...



Multiple Regression vs. Simple Regression

- Vergleichen wir den *slope coefficient* in *simple* (β) und *multiple* (β_1) Regression:

$$\textit{simple}: \; y^E = \alpha + \beta x_1$$
$$\textit{multiple}: \; y^E = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

- Die Regression von x_2 auf x_1 ist $x_2^E = \gamma + \delta x_1$. Eingesetzt in *multiple regression*:

$$y^E = \beta_0 + \beta_1 x_1 + \beta_2(\gamma + \delta x_1) = \beta_0 + \beta_2\gamma + \underbrace{(\beta_1 + \beta_2\delta)}_{=\beta} x_1$$
$$\Rightarrow \beta - \beta_1 = \delta\beta_2$$

Q: Unter welchen Voraussetzungen unterscheiden sich die *coefficiets* von x_1 in der *simple* und der *multiple regression*?

In Worten...

- *Simple* & *multiple* regression ergeben den **gleichen** *slope coefficient* $\beta = \beta_1$ wenn
  - x_1 und x_2 *uncorrelated* ($\delta = 0$) ODER
  - der *slope coefficient* von x_2 in der multiplen Regression null ist ($\beta_2 = 0$).
- Wir **überschätzen** (*positive bias*) die Steigung in der einfachen Regression, wenn
  - x_2 und x_1 positiv korreliert ($\delta > 0$) sind und $\beta_2 > 0$
  - oder wenn x_1 und x_2 negativ korreliert sind ($\delta < 0$) und $\beta_2 < 0$
- Wir **unterschätzen** (*negative bias*) die Steigung, wenn
  - x_2 und x_1 negativ korreliert ($\delta < 0$) sind und $\beta_2 > 0$
  - oder wenn x_1 und x_2 positiv korreliert sind ($\delta > 0$) und $\beta_2 < 0$
- ***Omitted variable bias***: Die Verzerrung wenn wir x_2 nicht berücksichtigen

Multiple regression—Begrifflichkeiten

- Wenn wir ein relevantes x_2 vermuten, es aber **nicht beobachten** können:
  - Betrachten wir x_2 als möglichen **confounder** (Störvariable)
  - Wir müssen wie bei *classic measurement error* nachdenken und argumentieren.
  - Ist der "wahre" Parameter kleiner oder größer als der, den wir geschätzt haben?
- Wenn wir x_2 **beobachten** und bei der Schätzung von β_1 berücksichtigen:
  - Bezeichnen wir x_2 als ***control variable***
  - Wir schätzen β_1 "*conditional on* x_2" oder "*controlling for* x_2"
  - Ziel ist ein ***unbiased estimate*** (unverzerrter Schätzer) von β_1
- Oft fügen wir schrittweise Variablen zum Modell hinzu:
  - Bei **Parameterstabilität** können wir hoffen, dass es **keine *confounder*** gibt
  - Sonst haben wir wahrscheinlich eine ***omitted variable bias***

OLS-estimator

- Für die multiple Regression verwenden wir häufig die Matrixnotation:

$$y^E = \boldsymbol{x}'\boldsymbol{\beta}$$

  - wobei $\boldsymbol{x} = [1, x_1, x_2, \ldots, x_k]'$ und $\boldsymbol{\beta} = [\beta_0, \beta_1, \beta_2, \ldots, \beta_k]'$
  - Beides sind *column vectors* (Spaltenvektoren)
  - $\boldsymbol{x}$ wird *transposed*, so dass das y^E dem *dot product* entspricht
- OLS hat eine *closed-form solution* in Matrixform:

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{x}'\boldsymbol{x})^{-1}\boldsymbol{x}'y$$

- Um dorthin zu gelangen
  - leiten wir die *objective function* (SSR) nach $\hat{\beta}$ ab
  - und lösen dann nach $\hat{\beta}$ auf

Standard Errors der *regression coefficients*

- ***Statistical inference*** und *confidence intervals* analog zu *simple regressions*.

$$SE(\hat{\beta}_1) = \frac{Std[e]}{\sqrt{n}Std(x_1)\sqrt{1-R_1^2}}$$

  - **SE ist klein** wenn ***standard deviation* der *residuals* klein** (besserer fit); **Sample groß**, ***standard deviation* von x_1 groß**.
- **Neues Element**: der Term $\sqrt{1-R_1^2}$ im Nenner:
  - das R_1^2 bezieht sich auf eine **Regression von x_1 auf x_2** (und andere Xs).
  - Je stärker die *correlation* zwischen x_1 und x_2, desto größer der SE von $\hat{\beta}_1$ ($R^2 \uparrow, Nenner \downarrow, SE \uparrow$).
  - Beachten Sie die Symmetrie: dasselbe gilt für den SE von $\hat{\beta}_2$.
- Wie üblich verwenden wir in der Praxis ***robust* SE**! $\Rightarrow$ `reg y x1 x2, robust`

Multicollinearity (Multikollinearität) und SE of β

- **Starke**, aber unvollkommene **Korrelation** zwischen erklärenden Variablen
  - Bei *multicollinearity* können die SE sehr groß werden.
  - **Kaum Beobachtungen, die sich in x_1, aber nicht in x_2 unterscheiden**
  - Mathematisch: R_1^2 ist hoch (x_2 ist ein guter *predictor* für x_1)
    - Daher ist $\sqrt{1 - R_1^2}$ klein, was $SE(\beta_1)$ groß macht
- *Multicollinearity* sollte vermieden werden
  - In der Praxis häufig **"merkwürdige" *estimates***
    - Was bedeutet es x_2 konstant zu halten, wenn sich x_1 und x_2 simultan bewegen?
  - **Untersuchen sie *pair-wise correlations***: `pwcorr x1 x2 x3` (Korrelationsmatrix)
  - Bei *Multicollinearity* ($|\rho| > 0.7$) nur eine der hochkorrelierten Variablen verwenden
    - oder Variablen in einen Index zusammenfassen (Z-Score/Durchschnitt/PCA/FA)
- Vor allem bei kleinen Samples wichtig

F-test: joint significance

- *Testing **joint hypotheses***
  - Nullhypothesen, die Aussagen über **mehr als einen *regression coefficient*** machen
    - Z.B. haben alle räumlichen Variablen zusammen einen Effekt?
    - Distanz vom Stadtzentrum, von der nächsten U-Bahn, dem nächsten Park, usw.
- Dazu nutzen wir den **F-Test**
  - Das Prinzip ähnelt dem t-Tests, aber die *sampling distribution* ist hier eine 'F-Verteilung'
    - `reg y x1 x2, robust`
    - `test (x1=0) (x2=0)` (geht auch mit anderen Werten als 0)
  - $H_0 : \beta_1 = \beta_2 = 0$ kann abgelehnt werden, selbst wenn β_1 und β_2 insignifkant sind
- Können auch fragen, ob alle *slope coefficients* in der Regression null sind.
  - "Globaler F-Test", oft standardmäßig ausgegeben

Viele *explanatory variables*

- Wir können **mehr als zwei *explanatory variables*** in einer Regression haben:

$$y^E = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + ...$$

- Die **Interpretation** der *slope* ist **analog** zum Fall mit zwei *explanatory variables*:
  - Im Durchschnitt ist y um β_1 Einheiten größer wenn x_1 eine Einheit größer
  - aber **alle anderen** x-**Variablen** unerändert bleiben
- *Standard errror*:

$$SE(\hat{\beta}_k) = \frac{Std[e]}{\sqrt{n} Std[x_k] \sqrt{1 - R_k^2}}$$

  - Klein, wenn R_k^2 klein ist (R^2 der Regression von x_k auf alle *anderen* x-Variablen)

Understanding the gender difference in earnings

- In den USA (2014) verdienen Frauen tendenziell etwa 20% weniger als Männer.
  - Wir wollen die Ursachen verstehen
- Lohn nimmt tendentiell mit Alter und Erfahrung zu

Q: Können Altersunterschiede zwischen Frauen und Männern das Gender Gap erklären?

Gender gap in earnings—data

- Daten aus dem *census* (Volkszählung) von 2014
  - **Selbstständige ausgeschlossen** (Einkommen ist schwer zu messen)
  - Beschränkung auf
    - Alter zwischen 15 und 65 Jahren
    - Personen, die regelmässig 20 Stunden oder mehr pro Woche arbeiten
  - Arbeitnehmer mit einem **Hochschulabschluss**
- Wir verwenden
  - log des Stundenlohns ($\ln(w)$) als *dependent variable*
  - Geschlecht und Alter als erklärende Variablen

Basic models for gender gap

- Wir haben die Beziehung zwischen Einkommen und Geschlecht bereits untersucht:

$$\ln w_i = \alpha + \beta female_i + \varepsilon_i, \qquad \beta < 0$$

  - wobei *female* ein Dummy füe weibliche Arbeitnehmerinnen ist
- Jetzt **erweitern wir das Modell um Alter** als *control variable*:

$$\ln w_i = \beta_0 + \beta_1 female_i + \beta_2 age_i + \epsilon_i$$

  - `gen female=sex==2`
  - `gen w = earnwke/uhours`
  - `gen lnw=ln(w)`
  - `reg lnw female age, robust`

Gender gap regression—baseline

Variables	(1) ln wage	(2) ln wage	(3) age
female	-0.195**	-0.185**	-1.484**
	(0.008)	(0.008)	(0.159)
age		0.007**	
		(0.000)	
Constant	3.514**	3.198**	44.630**
	(0.006)	(0.018)	(0.116)
Observations	18,241	18,241	18,241
R-squared	0.028	0.046	0.005

Note: *All employees with a graduate degree. Robust standard errors in parentheses*
Source: `cps-earnings` dataset. 2014 CPS Morg.

Age ist eine confounder variable

- Zur Erinnerung: Die ***omitted variable bias*** kann man wie folgt bestimmen:

$$\beta - \beta_1 = \delta\beta_2$$

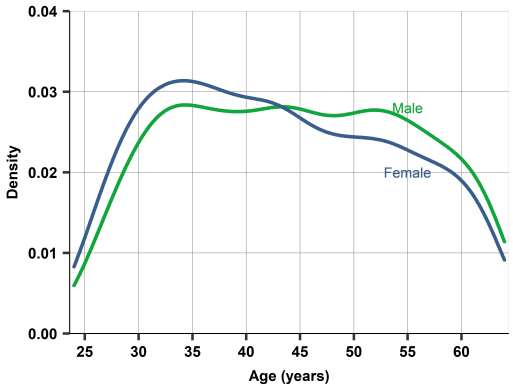
  - β der *female coefficient* aus der *simple regression* (Model 1)
  - β_1 der *female coefficient* aus der *regression* mit *age* als *control variable* (Model 2)
  - δ der *age coefficient* aus der gression von *age* auf *female* ist (Model 3)
- Mit unseren geschaetzten Parameterwerten:
  - $\beta - \beta_1 = -0.195 - (-0.185) = -0.01$
  - $\delta\beta_2 = -1.48 \times 0.007 \approx -0.01$ ✓
- Interpretation: **Alter ist ein *confounder*** (wenn auch kein besonders starker)
  - Unter Berücksichtigung von *age* wird das Gender Gap ewas kleiner
  - So wie wir das in Anbetracht der Korrelation von *age* und *female* erwarten

Interpretation

- Berufstätige **Frauen sind im Schnitt etwas jünger** als Männer
  - Etwa 1.5 Jahre
- **Jüngere Mitarbeiter verdienen** tendentiell **weniger**
  - Etwa 0.7 % pro Jahr
- Ein **Teil des Gender Gaps** ist darauf zurückzuführen, dass **Frauen jünger** sind
  - Etwa 1 Prozentpunkt der 20%igen Differenz
  - Das ist nur ein Anteil von 5% am Gender Gap
- Natürlich muss die Beziehung zwischen Alter und (log) Lohn nicht linear sein...

Conditional distribution des Alters nach Geschlecht

Age distribution of male and female employees with degrees higher than college



- Wenige Beschäftigte unter 30 Jahren
- Über 30 Jahre
  - gleichmäßig verteilt bei Männern
  - bei Frauen nimmt der Anteil ab Mitte 30 stetig ab
- Zwei mögliche Ursachen
  - weniger Frauen mit Hochschulabschluss bei den Über-45-Jährigen im Vergleich zu den Jüngeren (Kohorteneffekt)
  - Erwerbstätig nimmt ab (Alterseffekt)

Non-linearity in age, same effect on gender

Variables	(1) ln wage	(2) ln wage	(3) ln wage	(4) ln wage
female	-0.195**	-0.185**	-0.183**	-0.183**
	(0.008)	(0.008)	(0.008)	(0.008)
age		0.007**	0.063**	0.572**
		(0.000)	(0.003)	(0.116)
age^2			-0.001**	-0.017**
			(0.000)	(0.004)
age^3				0.000**
				(0.000)
age^4				-0.000**
				(0.000)
Constant	3.514**	3.198**	2.027**	-3.606**
	(0.006)	(0.018)	(0.073)	(1.178)
Observations	18,241	18,241	18,241	18,241
R-squared	0.028	0.046	0.060	0.062

Note: *** $p<0.01$, ** $p<0.05$, * $p<0.1$

- *Age effect* ist *non-linear*
- Gender gap schrumpft etwas
- Aber nur minimal

Qualitative Variablen (*Dummy variables*)

- ***Qualitative variables*** werden durch ***dummy variables*** abgebildet
  - Für jede Merkmalsausprägung wird ein Dummy erstellt
  - Eine Kategorie wird ausgelassen (***reference category***), da sonst *multicollinearity*
- Beispiel: x hat die Ausprägungen *low*, *medium*, *high*
  - $x_m = 1$, falls $x =$ medium
  - $x_h = 1$, falls $x =$ high
  - Referenzkategorie: $x =$ low
- $y^E = \beta_0 + \beta_1 x_m + \beta_2 x_h$
  - β_0: Durchschnitt von y für $x =$ low
  - β_1: Unterschied zwischen $x =$ medium und $x =$ low
  - β_2: Unterschied zwischen $x =$ high und $x =$ low
    - `encode x, gen(xnum)`
    - `reg y ib1.xnum, robust`

Qualitative variables

- Wenn uns die Schätzer für die Dummy Variablen **nicht interessieren**
  - Dann können wir ***fixed effects*** "absorbieren" lassen
    - Die Statistik Software zieht innerhalb der Kategorien den *mean* von y und allen x ab
- Wir wollen **für *occupations*** (Berufe), die wir mit o indizieren, **kontrollieren**

$$y_i = \alpha + \beta female_i + \theta_c + \varepsilon_i$$

  - `reg lnw female age, abs(occ2012) cluster(occ2012)`
    - `abs(occ2012)` berücksichtigt die *fixed efffects*
    - `cluster(occ2012)` berücksichtigt, dass die *variance* in den *residuals* sich unterscheidet

Non-linearity in age, same effect on gender

VARIABLES	(1) lnw	(2) lnw	(3) lnw	(4) lnw
female	-0.195**	-0.185**	-0.120**	-0.110**
	(0.008)	(0.008)	(0.010)	(0.010)
age		0.007**		0.008**
		(0.000)		(0.001)
Constant	3.514**	3.198**	3.475**	3.125**
	(0.006)	(0.018)	(0.005)	(0.038)
Occupation FE	-	-	Yes	Yes
Observations	18,241	18,241	18,241	18,241
R-squared	0.028	0.046	0.170	0.190

Note: *** $p<0.01$, ** $p<0.05$, * $p<0.1$

- Berufswahl spielt eine Rolle!
- Gender gap schrumpft erheblich (um 40%) wenn wir für Berufe kontrollieren
- Frauen arbeiten in **Berufen die weniger gut bezahlt sind**

Interactions (Interaktionsterme)

- Oft haben wir wichtige **Gruppen** in unseren Daten
  - Wir betrachten männliche und weibliche Arbeitnehmer
  - Ein Zusammenhang zwischen y und x kann sich zwischen den Gruppen unterscheiden
- Konzeptionell
  - Regression mit zwei erklärenden Variablen: x_1 ist quantitativ, D ist binär
  - Ist $\frac{\partial y}{\partial x_1}$ für Beobachtungen mit $D = 1$ anders als für $D = 0$?

Q: Wie kann das getested werden?

Interactions—Beispiel

- Wir fügen einen ***interaction term***, $D \times x_1$, hinzu:

$$y^E = \beta_0 + \beta_1 x_1 + \beta_2 D + \beta_3 (x_1 \times D)$$

  - `reg y c.x1##i.D, robust` oder `reg y x1 D c.x1#i.D, robust`

- In diesem Modell gilt:

$$y_0^E = \underbrace{\beta_0}_{\text{intercept}} + \underbrace{\beta_1}_{\text{slope}} x_1$$

$$y_1^E = \underbrace{\beta_0 + \beta_2}_{\text{intercept}} + \underbrace{(\beta_1 + \beta_3)}_{\text{slope}} x_1$$

  - β_2 zeigt uns den Unterschied im *intercept* an: $\beta_2 = (\beta_0 + \beta_2) - \beta_0$
  - β_3 spiegelt die Differenz in der *slope* wieder: $\beta_3 = (\beta_1 + \beta_3) - \beta_1$

Interaktionen vs. separate Regressionen

- **Zwei Möglichkeiten**
  - Separate Regressionen für beide Gruppen
  - Gepoolte Regression mit **Interaktionsterm**
- Ohne weitere *control variables*
  - Beide Ansätze liefern die gleichen *point estimates* für die gruppenspezifischen *slopes*
- Wenn uns die **Parameter der einzelnen Gruppen** interessieren
  - Separate Regressionen sind einfacher zu interpretieren
  - Die Koeffizienten aller Variablen dürfen sich zwischen den Gruppen unterscheiden
- Wenn wir wissen wollen, **ob sich die Gruppen unterscheiden**
  - Die Regression mit **Interaktion** ist vorzuziehen
    - β_3 misst den Unterschied der *slopes*
    - Ein *confidence interval* erlaubt einen direkten Signifikanztest

Interaktion mit vielen Gruppen

- Analog können wir weitere **Interaktionsterme** aufnehmen, z B. für drei Gruppen
  - Angenommen D_1, D_2 sind Dummy Variablen und x ist *continuous*:

$$y^E = \beta_0 + \beta_1 x + \beta_2 D_1 + \beta_3 D_2 + \beta_4 (D_1 \times x) + \beta_5 (D_2 \times x)$$

    - `reg y x D1 D2 i.D1#c.x i.D2#c.x, robust`
- Allgemein für K Gruppen:
  - Und $k-1$ Dummy Variablen

$$y^E = \beta_0 + \beta_1 x + \sum_{k=2}^{K} \beta_k D_{k-1} + \beta_{K+k} (D_{k-1} \times x)$$

Interactions mit zwei *continuous variables*

- Ein **Interaktionsterm** für zwei ***continuous variables***, x_1 und x_2:

$$y^E = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2$$

  - `reg y c.x1##c.x2, robust` oder `reg y x1 x2 c.x1#c.x2, robust`

- ***Slopes* hängen von der jeweils anderen *explanatory variable* ab**!

$$\frac{\partial y^E}{x_1} = \beta_1 + \beta_3 x_2, \quad \frac{\partial y^E}{x_2} = \beta_2 + \beta_3 x_1$$

- Beispiel Hotels
  - y ist der Preis, x_1 ist die Distanz, x_2 misst die Qualität
  - Die Interaktion kann erfassen, dass der Preis für bessere Hotels schneller mit der Entfernung fällt

Interaktion zwischen Geschlecht und Alter

- Bislang gingen wir davon aus, dass das **Alter** unabhängig vom Geschlecht den **gleichen *slope parameter*** hat.
- Ist das eine plausible Annahme?

Q: Unterscheidet sich der Koeffizient von Alter/Erfahrung zwischen Männern und Frauen?

Interaction between gender and age

- **Einkommen von Männern steigt schneller**
  - **50% schneller** mit jedem Jahr!
- Unterschied im *age* Effekt in (1) und (2) entspricht Interaktionseffekt in (3)
  - β_3 ist signifikant: Unterschied im *slope parameter* statistisch signifikant.
- Der Effekt des *female*-Dummy ist nahe null und statistisch insignifikant
  - Kein Gender Gap bei Geburt,
  - aber mit 25 gibt es bereits einen signifikanten Unterschied: $-0.036 - 0.003 \times 25 = 0.111$

Variables	(1) Women ln wage	(2) Men ln wage	(3) All ln wage
female			-0.036
			(0.035)
age	0.006**	0.009**	0.009**
	(0.001)	(0.001)	(0.001)
female × age			-0.003**
			(0.001)
Constant	3.081**	3.117**	3.117**
	(0.023)	(0.026)	(0.026)
Observations	9,685	8,556	18,241
R-squared	0.011	0.028	0.047

*** $p<0.01$, ** $p<0.05$, * $p<0.1$

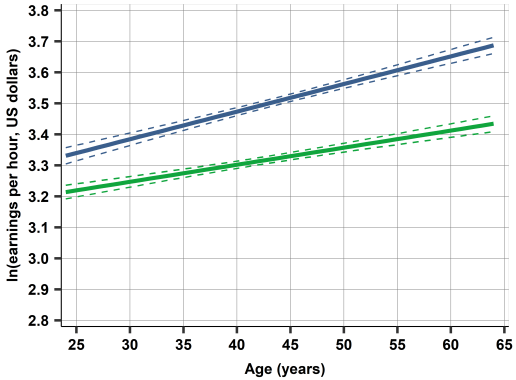
Nonlinearities & interactions

- Wir können auch Interaktionen auch mit **nichtlinearen Termen** schätzen:
  - z.B. *fourth-order polynomial*

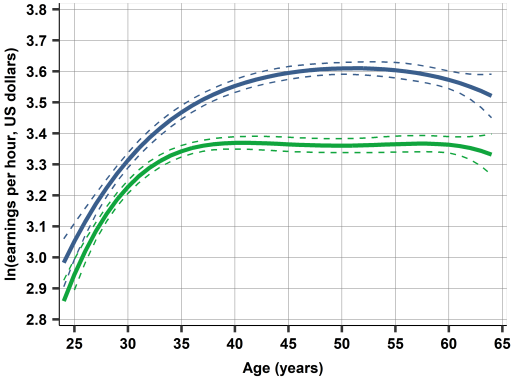
$$\begin{aligned} lnw^E = \beta_0 &+ \beta_1 age + \beta_2 age^2 + \beta_3 age^3 + \beta_4 age^4 \\ &+ \beta_5 female + \beta_6 female \times age + \beta_7 female \times age^2 \\ &+ \beta_8 female \times age^3 + \beta_9 female \times age^4 \end{aligned}$$

  - `foreach num of numlist 1/4 {` (Interaktionsterme erstellen)
  - `gen age_‘num’ = age^‘num’`
  - `gen age_femXage‘num’ = female*age^‘num’`
  - `}`
  - `reg lnw female age_* , robust` (Regression laufen lassen)
  - `predict lnwhat_m if female==0` (*predicted values* und *standard errors* erstellen)
  - `predict lnwhatse_m if female==0, stdp`
  - `predict lnwhat_f if female==1`
  - `predict lnwhatse_f if female==1 , stdp`

Nonlinearities and interactions



Log earnings per hour and age by gender: predicted values and confidence intervals from a linear regression interacted with gender.



Log earnings per hour and age by gender: predicted values and confidence intervals from a regression with 4th-order polynomial interacted with gender.

Interpretation

- Das Gender Gap
  - liegt bei etwa **10%** zwischen den Altersgruppen **25 und 30**
  - steigt auf etwa 15% bis zum Alter von 40 Jahren
  - erreicht **22%** bis zum Alter von **50** Jahren
  - nimmt ab 50 wieder etwas ab
- Die **Konfidenzintervalle** um die *predicted values* herum sind eher **schmal**
  - außer an den beiden Enden
- Implikation
  - **Beruf und Kinder** für Frauen besonders schwer zu vereinbaren?
  - Gender Gap vergrössert sich auffällig ab 30...

Causal analysis—ceteris paribus

- Multiplen Regressionen wollen wir häufig einer **kausalen Interpretation** näherkommen
  - *Causal analysis* (kausale Analyse) oder *causal inference* (Kausalitätsinferenz)
  - In dem wir für andere beobachtbare Variablen kontrollieren, **vergleichen wir ähnliche Objekte— "Äpfel mit Äpfel"**—selbst in Beobachtungsdaten
- Müssen auf **jede** potenzielle ***confounder variable*** eingehen
  - Alle Variablen, die sowohl y als auch die x_1 gleichzeitig beeinflussen
  - Ceteris paribus = Wir halten **alle** anderen Variablen konstant
- **Das ist natürlich nicht möglich!**
  - Wirkliche *causal inference* erfordert eine *identification strategy*
  - Gegenstand in *Applied Econometrics*

Mechanisms (Mechanismen)

- Oft wollen wir nicht nur die Stärke einer statistischen Beziehung messen
  - Grösse des *regression coefficient* und *statistical significance*
- Wir sind auch an den **zu Grunde liegenden Mechanismen** interessiert
  - Wir wollen auch verstehen, wo der Effekt herkommt
- Wir wollen eine **statistische Beziehung ökonomisch erklären**
  - Wir stellen Hypothesen hinsichtlich der ökonomischen Kräfte die am Werk sind auf
  - Wir sammeln Variablen, die diese Kräfte abbilden
  - **Wir fügen diese Variablen unserem Regressionsmodell zu**
- **Verschwindet die statistische Beziehung, haben wir das Phänomen "erklärt"**
  - Wir haben Mechanismen aufgedeckt

Gender Gap—mechanisms

- **Mögliche *mechanisms***, die dem Gender Gap zu Grunde liegen
  - Persönliche Merkmale wie Ausbildung und Alter
  - Rolle in der Famile und evt. damit einhergehend
  - Wahl des Berufs / Arbeitsstelle
- Denkbar ist aber auch Diskriminierung
  - Frauen verdienen weniger, selbst wenn sie die gleiche *marginale Produktivität* haben
  - Schwieriger zu messen...

Causal analysis—results

- *Female coefficient* **fällt von 22% auf 14%** wenn wir unsere Variablen hinzufügen
  - Deutliche Veränderung
  - aber Frauen verdienen immer noch durchschnittlich 14% weniger
- Beachte
  - *Restricted Sample*
  - Hier haben *occupation fixed effect eine kleinere Wirkung*

Variables	(1) ln wage	(2) ln wage	(3) ln wage	(4) ln wage
female	-0.224**	-0.212**	-0.151**	-0.141**
	(0.012)	(0.012)	(0.012)	(0.012)
Age and education		YES	YES	YES
Family circumstances			YES	YES
Demographic background			YES	YES
Job characteristics			YES	YES
Union member			YES	YES
Age in polynomial				YES
Hours in polynomial				YES
Observations	9,816	9,816	9,816	9,816
R-squared	0.036	0.043	0.182	0.195

Restricted sample: employees of age 40 to 60 with a graduate degree that work 20 hours per week or more

Discussion

- Beobachtbare **Variablen reduzieren das Gender Gap nur bedingt**
  - Alter und Ausbildung können das Gender Gap kaum erklären (nur ein Prozentpunkt)
  - Familienstand, Jobmerkmale und demographischer Hintergrund können zusammen auch nur einen relativ kleinen Teil des Gender Gaps erklären
- Werden Frauen also **im ökonomischen Sinne diskriminiert**?
  - Möglich, aber:
    - Kein statistischer Beweis
    - Unmöglich alle Mechanismen perfekt abzubilden
    - Die Veränderung des Gender Gap *coefficients* könnte auch als Indiz für *omitted variable bias* ausgelegt werden
- Klar ist, dass etwas gravierendes ab dem Alter von ca. 30 passiert
  - Familiengründung könnte eine wichtige Rolle spielen!

Prediction mit *multiple regression*

- Ein Grund, um eine multiple Regression durchzuführen, ist die ***Prognose***
  - Schätzung für die abhängige Variable y_j für eine bestimmte *Zielbeobachtung* j.

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1 x_{1j} + \hat{\beta}_2 x_{2j} + ...$$

- Die Regression soll sich **so gut wie möglich an die Daten anpassen**
  - im Sinne des *general pattern*, das für die Zielbeobachtung j repräsentativ ist
- Mehr Variablen können helfen, aber Vorsicht vor ***overfitting***
  - Mit sehr vielen Variablen (und Interaktionen) kann man Muster in den Daten finden, die im ***general pattern*** **nicht wahr sind**, sondern nur im vorliegenden Sample
  - Mehr dazu (und Machine Learning als alternative zu OLS) in *Applied Econometrics*

Zusammenfassung

- **Multiple Regression**
  - Lineare Modelle mit mehreren unabhängigen Variablen
- **Einsatzmöglichkeiten**
  - Für mögliche *confounder* kontrollieren
  - Interaktionen zwischen Variablen abbilden
  - Mechanismen aufdecken
  - Bessere Vorhersagen ermöglichen
  - Ohne Identifikationsstrategie bringt sie uns kausalen Interpretationen bestenfalls näher