Thema 11. Modellierung von Wahrscheinlichkeiten

Gabriel M Ahlfeldt

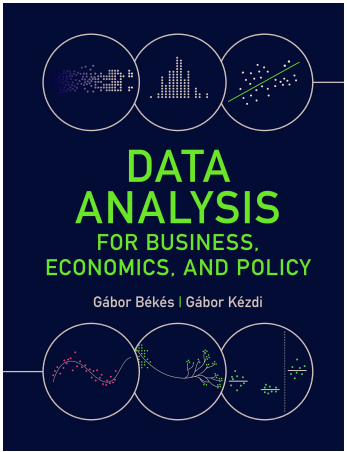
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 11**

Lehrevaluation



Motivation

- **Ist Rauchen schlecht für die Gesundheit?**
- Um diese Frage zu beantworten, untersuchen wir, ob Unterschiede in den Rauchgewohnheiten mit Unterschieden im Gesundheitszustand korrelieren.

Gehe zu https://pingo.coactum.de, *access number* 887564



Binary events (Binäre Ereignisse)

- **Binary variable** (binäre Variable)
  - Das outcome nimmt entweder den wert 0 oder 1 an
  - Gut geeignet, um zu erfassen ob bestimmte Ereignisse eintreten oder nicht
- ***Predicted values*** $\hat{y}$ liegen zwischen 0 und 1
  - Macht streng genommen keinen Sinn!
  - Es sei denn man interpretiert sie als ***probabilities*** (Wahrscheinlichkeiten)!

$$E[y] = P[y = 1]$$

- Der *mean* einer binären 0-1 y Variable ist die *probability*, dass $y = 1$.
  - Z.B. Häufigkeit (25% der Fälle) — Wahrscheinlichkeit (25% Chance)
  - ***Expected value*** ist die **durchschnittliche Wahrscheinlichkeit** des Eintretens

Linear probability model—LPM

- ***Linear probability model*** (LMP, lineares Wahrscheinlichkeitsmodell)
  - Eine *linear regression* mit *binary dependent variable*
- Notation für die Wahrscheinlichkeit des Eintritts des Events y:

$$y^P = P[y = 1|x_1, x_2, \dots]$$

- Die Regression des LPM lautet

$$y^P = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

  - **Wir modellieren ökonometrisch den *conditional mean***
    - Wie *multivariate regression*, **geschätzt mit OLS**
    - `reg y x1 x2, robust`

Linear probability model—Interpretation

$$y^P = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

- y^P: ***probability*, dass die *dependent variable* eins ist**, *conditional on* x_1, x_2.
- β_0: *probability*, dass $y = 1$, **wenn alle** x **null sind**.
- β_1: **Unterschied in der *probability***, dass $y = 1$
  - für Beobachtungen, die sich in x_1 um eins unterscheiden,
  - in Bezug auf x_2 gleich sind.
    - β_2 analog...
- **Weitere Parallelen** mit standard *multivariate regression*
  - **Transformationen** (logs in x, polynomials, splines, dummies, interactions)
  - **Statistical inference** (SE, CI, p-values, etc.)

Predicted values im LPM

- ***Predicted values***, $\hat{y}^P$, werden wie gehabt berechnet:

$$\hat{y}^P = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2$$

  - **Sollen zwischen 0 and 1 liegen**, da es sich um Wahrscheinlichkeiten handelt

- In einer OLS Schätzung gibt es dafür aber **keine Garantie**
  - Ausser wenn nur *binary explanatory variables* verwendet werden ('saturated models')
  - Offensichtliches **Problem** wenn unser Ziel ***prediction*** ist!
  - **Weniger problematisch bei *inference*** $\rightarrow$ Schätzung von x-y Beziehungen.
    - Theoretisch kann es zu verzerrten Schätzern kommen...
    - Wenn ein erheblicher Teil der $\hat{y}^P$ ausserhalb von $[0, 1]$ liegt, ist das Grund zur Sorge...

Does smoking pose a health risk?

- **Führt Rauchen zu einer Verschlechterung der Gesundheit?**
  - Unsere Forschungsfrage
- Eingrenzung der Probanden
  - Personen im Alter von 50 bis 60 Jahren, die sich selbst als gesund betrachten
  - Diese werden **vier Jahre später erneut befragt**
- Mit diesen Daten können wir abschätzen, **ob Raucher weniger wahrscheinlich gesund bleiben** als Nichtraucher und wenn ja, um wie viel

Data

- $y = 1$, **wenn eine Person gesund geblieben ist** (*stays healthy*)
  - Sich "ausgezeichnet" (*feeling excellent*) oder "sehr gut" (*very good*) fühlen
- $y = 0$, wenn sich die Gesundheit verschlechtert hat
- Die Daten stammen von SHARE
  (Survey for Health, Aging and Retirement in Europe)
  - 14 europäische Länder
  - Demografische Informationen zu allen Personen
  - Teilnehmer aus den Jahren 2011 und 2015 werden verwendet
  - $N = 3,109$

LPM

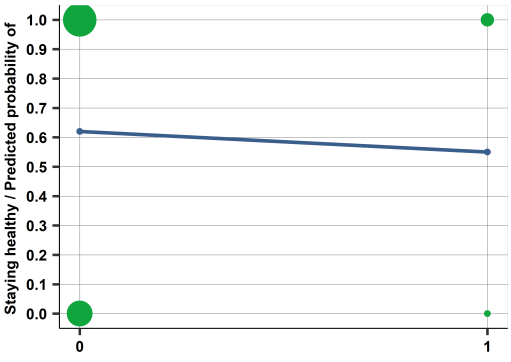
- Wir beginnen mit einem *simple bivariate model*
  - Einfaches bivariates Modell (nur zwei Variablen)
- *Explanatory variable* ist *being a smoker* (Rauchen).

$$\textit{stays healthy}^P = \alpha + \beta \textit{smoker}$$

- *Estimated* β ist -0.072
  - ***Dependent variable* und *independent variable* sind *binary variables***
  - Wie stellt sich das im *scatterplot* dar?

Scatterplot and regression line

Figure: Staying healthy



Anmerkung: Lineares Wahrscheinlichkeitsmodell.
Quelle: `share-health`-Datensatz.

Warum nur vier Punkte?

- Beide Variablen sind binär (0/1).
- Deshalb gibt es nur vier mögliche Kombinationen.
- Viele Beobachtungen liegen auf denselben Koordinaten.
- Die Punktgröße ist proportional zur Anzahl der Beobachtungen.

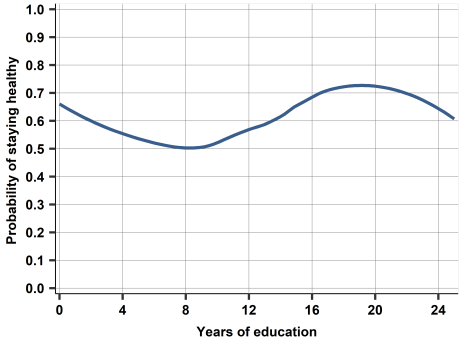
LPM Interpretation

- Der *regression coefficient* der Variable "*smoker*", β
  - zeigt den Unterschied in der Wahrscheinlichkeit, gesund zu bleiben
- **7 *Prozentpunkte* geringere Wahrscheinlichkeit gesund zu bleiben!**
  - Wenn wir aktuelle Rauchende mit Nichtrauchenden vergleichen
- Natürlich könnte es aber ***selection*** (Selektion) geben
  - Rauchende und Nichtrauchende können sich in anderen **Merkmalen unterscheiden**
  - Wer auf seine Gesundheit achtet, raucht nicht, macht Sport, isst gesund...
  - Ohne **Radomisierung** kaum komplett zu vermeiden—und die wäre unethisch!
- Das beste was wir tun können, ist wichtige ***confounder* zu berücksichtigen**

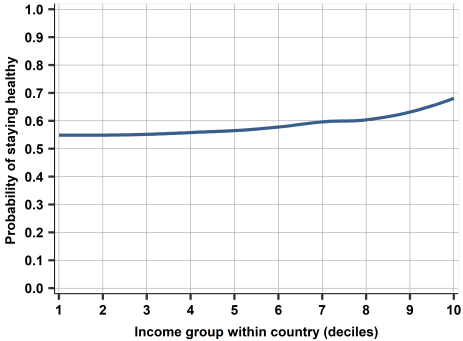
LPM with many regressors II.

- Auswahl der **control variables**:
  - Geschlechtsdummy, Alter, Bildungsjahre,
  - Einkommen (gemessen in 10 Einkommensgruppen innerhalb den Landes),
  - Body-Mass-Index (ein Maß für das Gewicht im Verhältnis zur Größe),
  - ob die Person regelmäßig Sport treibt
  - das Land, in dem die Person lebt.
    - Länder *fixed effects*: eine Ansammlung von Binärindikatoren (eine für jedes Land).
- Überlegung zur ***functional form***:
  - *continuous variables* könnten eine nichtlineare Beziehung zur Gesundheit aufweisen.
  - Sollten wir mit nichtparametrischen Methoden erforschen.

Functional form selection



Staying healthy and years of education



Staying healthy and income group

$\Rightarrow$ (1) Bildung als linearer Spline (Knoten: 8 und 18 Jahre); (2) Einkommen linear modellieren.

Q: Waren diese Ergebnisse so zu erwarten?

LPM results

Probability of staying healthy - extended model

VARIABLES	Staying healthy	VARIABLES (cnt.)	
Current smoker (Y/N)	-0.061*	Income group	0.008*
	(0.024)		(0.003)
Ever smoked (Y/N)	0.015	BMI (for < 35)	-0.012**
	(0.020)		(0.003)
Female (Y/N)	0.033	BMI (for $>= 35$)	0.006
	(0.018)		(0.017)
Age	-0.003	Exercises regularly (Y/N)	0.053**
	(0.003)		(0.017)
Years of education (for < 8)	-0.001	Years of education (for $>= 18$)	-0.010
	(0.007)		(0.012)
Years of education (for $>= 8$ and < 18)	0.017**	Country fixed effects	YES
	(0.003)		
Observations	3,109		

Robust standard errors in parentheses. ** $p<0.01$, * $p<0.05$
Y/N denotes binary vars. BMI and education entered as spline. Age in years. Income in deciles. Constant omitted.

Q: Welche Ergebnisse sind statistisch und quantitativ signifikant?

LPM result's interpretation

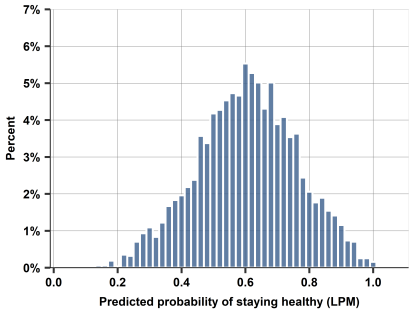
- Der Koeffizient für *current smoker* (derzeitiges Rauchen) beträgt -0.06
  - Das 95% CI ist relativ breit $[-0.11, -0.01]$, aber ***significant at the 5% level***
- Interessante Kontrollvariablen
  - **Keine signifikanten Unterschiede** in der Gesundheit zwischen Menschen, die noch nie geraucht haben und denen, die früher geraucht haben, **aber aufgehört haben**
  - Frauen bleiben tendentiell eher gesund, Unterschied aber nicht signifikant
  - Das Alter scheint in der Altersspanne von 50 bis 60 Jahren keine Rolle zu spielen
  - **Einkommen positiv korreliert**
  - **Regelmäßige körperliche Aktivität auch positiv korreliert**
  - Im mittleren bereich is Ausbildung positiv korreliert

Q: Wie wahrscheinlich ist es, dass wir ein *omitted variable problem* haben?

LPM's predicted probabilities

- Die ***predicted probabilties*** (vorhergesagte Wahrscheinlichkeiten) sind die *predicted values* des LPM.
  - `reg y x2 x2, robust`
  - `predict, xb`
- Die Wahrscheinlichkeit, gesund zu bleiben, reicht von 0,036 bis 1,011
  - Beim LPM kann sie unter 0 oder über 1 liegen...
  - Hier nur geringfügig über 1
    - Sieht gut aus...

Histogram of the predicted probabilities



Source: `share-health` dataset.

Compare predicted probability distribution

- Welche Leute verbergen sich hinter dieser Verteilung?
  - Wir betrachten die oberen (*top*) und unteren (*bottom*) 1% der *predicted probabilities*!
  - Für beide Kategorien berechnen wir die Durchschnittswerte der *covariates* (*explanatory variables*)!

Top 1% predicted probability:

- **Keine aktuellen Rauchenden**,
- Durchschnittlich 17,3 Jahre Ausbildung, relativ hohes Einkommen
- BMI von 20,7 und 90% von ihnen treiben Sport.

Bottom 1% predicted probability

- 37,5% aktuell Rauchende, 63% Männer
- 7,6 Jahre Ausbildung, niedrigeres Einkommen
- BMI von 30,5, 19% treiben Sport

Probability models: logit and probit

- Plausible ***predicted probabilities*** **müssen zwischen 0 und 1 liegen**
  - Mit dem LPM ist die Bedingung nicht notwendiger Weise erfullt
  - Für *predictions* verwenden wir daher auch **nichtlineare Modelle**
- Dafür können wir eine ***'Link-function'*** $F(z)$ nutzen
  - wobei $z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots$ analog zum LPM ist
  - $F(z)$ transformiert z in eine Ereigeniswahrscheinlichkeit, die zwischen 0 und 1 liegt
  - Entscheidend ist, dass die *'Link-function'* Wahrscheinlichkeiten produziert, die immer streng zwischen null und eins liegen.
- Zwei Optionen: **Logit** und **Probit**
  - verschiedene Link-Funktionen

Link functions I

- Das **Logit** Modell hat die folgende Form:

$$y^P = \Lambda(\beta_0 + \beta_1 x_1, \beta_2 x_2 + ...) = \frac{exp(\beta_0 + \beta_1 x_1, \beta_2 x_2 + ...)}{1 + exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + ...)}$$

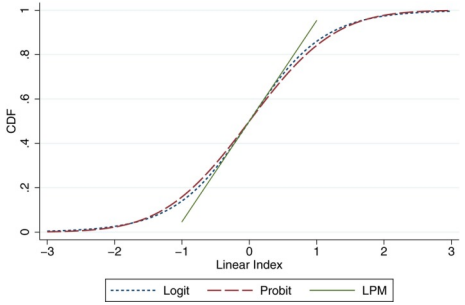
  - wobei die Link-Funktion $\Lambda(z) = \frac{exp(z)}{1+exp(z)}$ als die *logistic function* bezeichnet wird.
    - `logit y x1 x2`
- Das **Probit** Modell hat die folgende Form:

$$y^P = \Phi(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + ...)$$

  - wobei die Link-Funktion $\Phi(z) = \int_{-\infty}^{z} \frac{1}{\sqrt{2\pi}} exp\left(-\frac{z^2}{2}\right) dz$ die *comulative density function* (CDF) der *standard normal distribution* ist.
    - `probit y x1 x2`

Link functions II

- Sowohl Λ als auch Φ sind **ansteigende S-förmige Kurven**, die **zwischen 0 und 1 begrenzt** sind
- Gegen ihre jeweiligen "z"-Werte geplottet. (Hier -3 bis 3)
- Kleiner Unterschied (kaum unterscheidbar) Logit ist in der Nähe von null und eins weniger steil = *longer tails* als der Probit.
- 'z' ist eine lineare Kombination der β_is-und x_i. Die geschaetzten $\hat{\beta}$ unterscheiden sich in der Regel zwischen Probit und Logit.



Logit & Probit Interpretation

- Die Steigung der Link-Funktion Kurve ändert sich wenn sich z ändert
  - Die Steigung ist am steilsten, wenn $z = 0 \Rightarrow F(z) = y^P = 0.5$ ist;
  - sie sehr flach, wenn y^P nahe bei null oder eins ist.
- Wichtiger Unterschied zum LMP: Die ***marginal effects*** $\frac{\partial y^P}{\partial x}$ sind **nicht konstant**
  - Die partiellen Ableitungen hängen von den x Variablen ab
  - **Die gleiche Veränderung in z hat unterschiedliche Wirkungen auf Λ und Φ**
- Daher **keine intutive Interpretation der *raw coefficients*!** (Rohkoeffizienten)
  - Die Rohkoeffizienten geben $\frac{\partial z}{\partial x}$, nicht $\frac{\partial y^P}{\partial x}$
  - Die *marginal effects* ergeben sich als $\frac{\partial y^P}{\partial x_k} = \frac{\partial F(z)}{\partial z}\frac{\partial z}{\partial x_k} = F'(z)\beta_k$
    - Dabei hilft natürlich die Software...

Marginal differences

- Für eine intuitive Interpretation, transformieren wir Logit/Probit *raw coefficients* in ***'marginal differences'*** (marginale Differenzen) oder ***'marginal effects'***
- Das macht die Software für uns
  - `logit y x1 x2` oder `probit y x1 x2`
  - `margins, dydx(x1) at(x1=(Wert1, Wert2, ...))`
    - Wert1, Wert2, ... ist eine Liste beliebiger x1 für die dann $\frac{\partial y^P}{\partial x1}$ berechnet wird
    - Lässt man `at(x1=(Wert1, Wert2, ...))` weg, erhält man $\frac{\partial y^P}{\partial x1}$ am *mean* $\overline{x1}$
- **Gleiche Interpretation wie die *regression coefficients* des LPM**.
  - *Marginal effects* am *mean* von x sind meistens nah dran am LPM (OLS) *estimate*

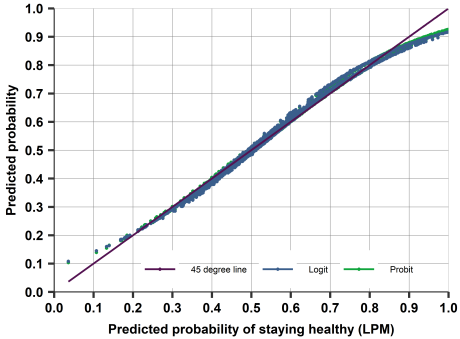
Maximum likelihood estimation

- Logit/Probit-Modelle werden mit der **'Maximum Likelihood'** Methode geschätzt
  - Wir geben eine (bedingte) Verteilung vor, welcher die *predicted values* folgen
    - Die logistische Verteilung für das Logit-Modell
    - Die Normalverteilung für das Probit-Modell
  - Unsere $\hat{\beta}$ **maximieren die Wahrscheinlichkeit** die **richtigen y Werte** zu erhalten
    - Diese wird durch die *likelihood function* beschrieben
    - Dafür vergleichen wir $y^P = F(z(\mathbf{x}_i'\beta))$ mit den beobachteten y_i
    - Es gibt keine *closed-form solutions*, daher müssen Suchalgorithmen verwendet werden.
- Der maximale Wert dieser Funktion ℓ wird dann für Modellvergleiche verwendet
  - z.B. für das Pseudo R^2.
- Bei Interesse, erfahren Sie mehr zur *likelihood function* im Lehrbuch

Predictions for LMP, Logit and Probit

- Vergleich der *predicted values*
  - Die 45-Grad-Linie entspricht dem LPM
  - Die anderen Kurven zeigen *predicted probabilities* aus dem Logit- und dem Probit-Modell relativ zum LPM.
- Insgesamt **sehr ähnlich**
  - Logit/Probit vermeiden extrem hohe und niedrige Wahrscheinlichkeiten an den Rändern

Comparing probabilities from models



Coefficient results for logit and probit

Dep.var.: stays healthy	(1) LPM	(2) logit coeffs	(3) logit marginals	(4) probit coeffs	(5) probit marginals
Current smoker	**-0.061***	-0.284**	**-0.061****	-0.171*	**-0.060***
	(0.024)	(0.109)	(0.023)	(0.066)	(0.023)
Ever smoked	0.015	0.078	0.017	0.044	0.016
	(0.020)	(0.092)	(0.020)	(0.056)	(0.020)
Female	0.033	0.161*	0.034*	0.097	0.034
	(0.018)	(0.082)	(0.018)	(0.050)	(0.018)
Years of education (if $<$ 8)	-0.001	-0.003	-0.001	-0.002	-0.001
	(0.007)	(0.033)	(0.007)	(0.020)	(0.007)
Years of education (if $>=$ 8 and $<$ 18)	0.017**	0.079**	0.017**	0.048**	0.017**
	(0.003)	(0.016)	(0.003)	(0.010)	(0.003)
Years of education (if $>=$ 18)	-0.010	-0.046	-0.010	-0.029	-0.010
	(0.012)	(0.055)	(0.012)	(0.033)	(0.012)
Income group	0.008*	0.036*	0.008*	0.022*	0.008*
	(0.003)	(0.015)	(0.003)	(0.009)	(0.003)
Exercises regularly	0.053**	0.255**	0.055**	0.151**	0.053**
	(0.017)	(0.079)	(0.017)	(0.048)	(0.017)
Age, BMI, Country	YES	YES	YES	YES	YES
Observations	3,109	3,109	3,109	3,109	3,109

- regress stayshealthy smoking ever_smoked female age eduy_08 eduy_818 eduy_18p income10 bmi_1635 bmi_3545 exerc i.country, robust
- logit stayshealthy smoking ever_smoked female age eduy_08 eduy_818 eduy_18p income10 bmi_1635 bmi_3545 exerc i.country, robust
- margins, dydx(_all)
- probit stayshealthy smoking ever_smoked female age eduy_08 eduy_818 eduy_18p income10 bmi_1635 bmi_3545 exerc i.country, robust
- margins, dydx(_all)

Does smoking pose a health risk?– logit and probit

- *Marignal effects* aus Logit und Probit sind meist nah an den LPM-Koeffizienten
  - **Nicht vergessen** die *marginal effects* nach *logit/probit* berechnen zu lassen!
- Allgemein gilt:
  - Wir wissen nicht, welches das "richtige Modell" für die Inferenz ist
  - **Oft ist LPM gut genug für die Interpretation**
    - Ein Blick auf die *predicted probabilities* beim LPM lohnt immer
    - Gut, wenn die *predicted probabilities* innerhap des [0,1] Intervalls liegen
  - Überprüfen, ob Logit/Probit sehr unterschiedlich sind
    - Falls nicht, sollte man sich *functional forms* näher ansehen

Goodness of fit (Modellgüte)

- **Normaler Weise** bewerten wir die ***goodness of fit* über das** R^2
  - **Hier** können wir das R^2 auch berechnen, ist aber **weniger sinnvoll**
    - Beobachtete y-Werte sind entweder 0 oder 1
    - Predicted $\hat{y}^P$-Werte sind Wahrscheinlichkeiten [0,1]
    - Wir **können also gar nicht richtig liegen**, $R^2 = 1$ von vornherein ausgeschossen
- **Pseudo** R^2 (viele Varianten, McFadden am populärsten)
  - Vergleicht die *log-likelihood* des Modells mit der Version ohne *explanatory variables*
  - Lässt sich für Logit und Probit berechnen
- **'log loss' Mass**
  - Ziel ist den **absoluten Wert des *log loss* zu minimieren**
  - Gibt für Logit Rankings, die konsistent mit Pseudo R^2 sind
    - aber nicht notwendiger Weise für Probit

Brier score

- ***Brier score***

$$Brier = \frac{1}{n}\sum_{i=1}^{n}(\hat{y}_i^P - y_i)^2$$

  - *mean squared difference* zwischen *predicted probabilities* und beobachteten y
  - aka *Mean Squared Error* (MSE)
- **Je kleiner der Brier-Score, desto besser**
  - Da im Durchschnitt kleinere (quadrierte) Fehler bei der *prediction*
- Daher speziell im Kontext der *prediciton* beliebt

Does smoking pose a health risk?—Goodness of fit

- **Logit und Probit** haben exakt die **gleichen *goodness of fit* Werte**
  - R^2 höher (besser)
  - Brier score niedriger (besser)
  - Geringeres *log-loss*, absolut gesehen (besser).
- **Logit/probit etwas besser in *prediction*** als OLS, der Unterschied is aber gering

Statistic	Linear probability	Logit	Probit
R-squared	0.103	0.104	0.104
Brier score	0.215	0.214	0.214
Pseudo R-squared	n.a.	0.080	0.080
Log-loss	-0.621	-0.617	-0.617

Source: `share-health` data. People of age 50 to 60 from 14 European countries who reported to be healthy in 2011. N=3109.

Bias of the predictions (Verzerrung der Vorhersagen)

- **Predictions sind *unbiased* wenn im Durchschnitt korrekt**

$$\underbrace{\left(\frac{1}{N}\right)\sum_{i=1}^{N}\hat{y}_i}_{\text{Durchschnitt der vorhergesagten Wahrscheinlichkeiten}} = \underbrace{\left(\frac{1}{N}\right)\sum_{i=1}^{N}y_i}_{\text{tatsächliche Wahrscheinlichkeit}}$$

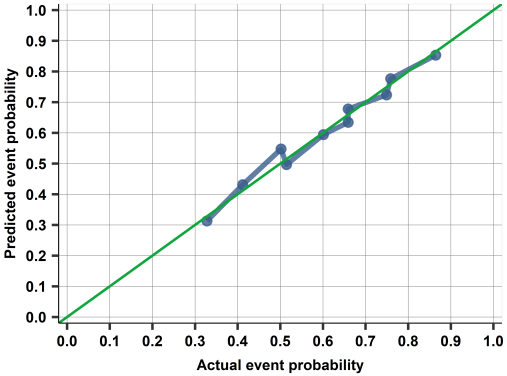
- Bespiel
  - 60% der Probanden bleiben gesund ($y = 1$) der Rest nicht ($y = 0$)
  - Der Durchschnitt unserer *predicted probabilities* beträgt $N^{-1}\sum_{i=1}^{N}\hat{y}_i = 0.6$
  - Das bedeutet, dass unsere Vorhersage *unbiased* (unverzerrt) ist.
- **Wir schätzen die Wahrscheinlichkeit eines Ereignisses richtig ein**

Calibration (Kalibrierung)

- Eine Vorhersage ist ***well calibrated*** (gut kalibriert), wenn folgendes gilt:
  - Tatsächliche Wahrscheinlichkeit = vorhergesagten Wahrscheinlichkeit
  - Und zwar **entlang der gesamten Verteilung** der *predicted probabilities*
- Beispiel
  - Wir nehmen vorhergesagte Wahrscheinlichkeiten, die sich um 10% bewegen
  - Für die gleichen Beobachtungen berechnen wir die Ereigniswahrscheinlichkeit
  - Beträgt die 10%, ist die *prediction* an dem Punkt der Verteilung *well calibrated*
- Ein Modell kann *unbiased* sein (im Durchschnitt richtig), aber nicht gut kalibriert
  - Es unterschätzt Ereignisse mit hoher Wahrscheinlichkeit
  - Es überschätzt solche mit niedriger Wahrscheinlichkeit

Calibration curve

- Zeigt wie das Modell kalibriert ist
  - Wir aggregieren die *predicted probabilities* ($\hat{y}^P$) aus dem Logit Modell auf *decile bins* und zeigen sie auf der x-Achse.
  - Für die gleichen Bins berechnen wir die durchschnittlichen beobachteten y -Werte und zeigen sie auf der y-Achse.
- Die *calibration curve* folgt der 45-Grad Linie (45-degree line)
  - Unser Modell ist *unbiased* und *well calibrated*



Probability models summary

- Das *linear probability model* ist in den meisten Fällen ausreichend
  - *Predicted values* können jedoch unter 0 oder über 1 liegen.
- Logit (und Probit) sind besser geeignet, wenn das Ziel die Vorhersage ist
  - Die vorhergesagten Werte liegen streng zwischen 0 und 1
- In den meisten Fällen sind LPM, Logit und Probit in der Inferenz ähnlich
  - Man muss allerdings die *marginal differences* berechnen (macht die Software)
- *Goodness of fit* ist nicht so leicht zu bestimmen
  - Am besten verschiedene Masse wie Brier-Score oder Pseudo-R^2 ausprobieren
- *Calibration* ist ein nützliches Diagnosewerkzeug
  - In gut kalibrierten Modellen entspricht die vorhergesagte Eventwahrscheinlichkeit der tatsächlichen Eventwahrscheinlichkeit, und zwar für alle vorhergesagten Wahrscheinlichkeiten