12. Zeitreihenanalyse

Gabriel M Ahlfeldt

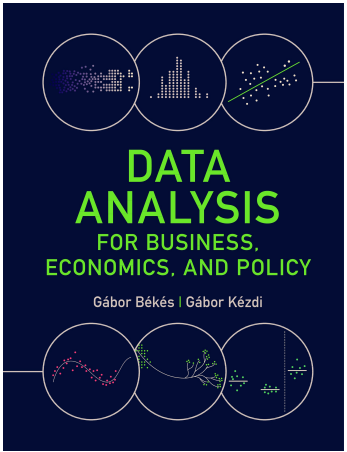
Einführung in die Ökonometrie

Humboldt-Universität zu Berlin, Sommersemester 2026

Acknowledgements

- This slide deck builds on material kindly shared by **Gabor Bekes** (Central European University)
- Most of the course is based on the textbook "Data Analysis for Business, Economics, And Policy", by Gabor Bekes and Gabor Kezdi

Slideshow for the Békés-Kézdi Data Analysis textbook



- Cambridge University Press, 2021
- **gabors-data-analysis.com**
  - Download all data and code: gabors-data-analysis.com/data-and-code/
- This slideshow is for **Chapter 12**

Motivation

- Wir wollen wissen wie **wie die Microsoft-Aktie im Vergleich zum S&P 500 performt**. Dazu verwenden wir Zeitreihen von Aktienkursen und Renditen.
- Wir wollen wissen, wie sich **Wetterbedingungen auf den Stromverbrauch** auswirken. Dazu verwenden wir monatliche *time series* (Zeitreihen) zur Temperatur und zum Wohnstromverbrauch in Arizona.
- Ziel ist es, geeignete **ökonometrische Modelle für Zeitreihendaten** zu formulieren und die interessierenden Zusammenhänge zu schätzen.

Besonderheiten der *time series analysis* (Zeitreihenanalyse)

- Wir haben *time series* Daten, wenn wir **eine Einheit** (z.B. Land, Unternehmen) über **viele Zeiträume** (*periods*) hinweg beobachten

$$y_t, \ t = 1, 2, \ldots, T$$

  - `xtset time`
  - wobei `time` eine Variable ist, die die Zeit misst, z.B. Jahre
  - Müssen wir immer definieren, damit *time series commands* (Befehle) funktionieren
- Zeitreihendaten bieten zusätzliche **Möglichkeiten**, stellen jedoch auch zusätzliche **Herausforderungen** wenn wir Zusamennenhänge zwischen Variablen untersuchen

Datenaufbereitung

- Auch in *time series* Daten können natürlich *extreme values* auftreten
  - Überlegen, ob wir e sich um relevantes Ereignis andelt (z.B. Wirtschaftskrise)
  - Wenn nicht, z.B. Beobachtung mit einem Dummy markieren
- ***Frequency*** einer *time series*
  - Die **Zeit**, die **zwischen zwei Beobachtungen** einer Variable verstrichen ist
- Praktische Probleme mit der *frequency*:
  - Es können regelmäßige/unregelmäßige Lücken auftreten
    - z. B. Wochenenden an der Börse, oder Arbeitslosigkeit einer Erwerbsperson.
  - Zwei Variablen sind in unterschiedlichen *frequencies* gemessen
- **Alle variablen** müssen in der **gleichen *frequency*** vorliegen
  - Ggf. müssen wir (mindestens) eine Variable anpassen...

Aggregation

- ***Aggregation***
  - Wir bringen unsere *time series* Variablen in die **gleiche *frequency***
- ***Flow variables*** (Stromgrößen)
  - Wir **summieren** die Werte innerhalb des Intervalls
    - z.B. tägliche Verkäufe $\rightarrow$ wöchentliche Verkäufe ist die Summe der täglichen Verkäufe in einer Woche.
- ***Stock variables*** (Bestandsgrößen):
  - Wir verwenden den **Wert am Ende** eines Zeitraums.
  - z.B. tägliche Aktienkurse verwenden den Schlusskurs an einem bestimmten Tag
- Die meisten **anderen Variablen**
  - Wir verwenden den **Durchschnitt** über die Werte in einem Zeitraum

Serial correlation (serielle Korrelation)

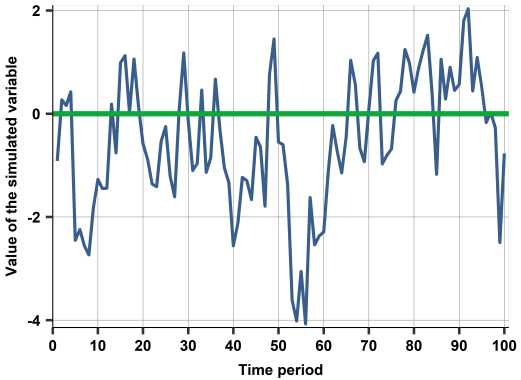
- ***Serial correlation***: Die Werte einer Variable sind **im Zeitverlauf korreliert**
  - Der *1st order serial correlation coefficient* ist wie folgt definiert:

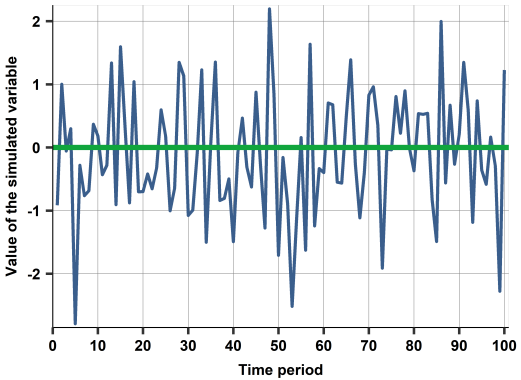
$$\rho_1 = Corr[y_t, y_{t-1}]$$

    - wobei wir das verzögert gemessene y_{t-1} als ***lag*** bezeichnen
    - Entspreichend ist der *2nd order serial correlation coefficient* $\rho_2 = Corr[y_t, y_{t-2}]$, etc.
  - Für eine ***positively serially correlated*** (positiv seriell korrelierte) Variable gilt
    - Wert wird **wahrscheinlich über dem Durchschnitt** liegen, wenn er wenn er **in der letzten Period über dem Durchschnitt lag**
- Macht die **time series analysis besonders**
  - **Spezialfall**: $\rho_1 = 0$: keine *serial correlation*, auch *"White Noise"* genannt.
    - Implikation: Die ***time series*** verhält sich **wie** eine ***cross section***

Illustration anhand simulierter Daten

- $y_t = \rho y_{t-1} + \epsilon_t$ mit $\rho = 0.8$ (links) sowie $\rho = 0$ (rechts). $\epsilon_t \sim N(0, 1)$
  - Solange $\rho < 1$, besteht **langfristige Konvergenz** gegen Null





Stationarity (Stationarität)

- ***Stationary time series*** haben immer dieselbe *conditional sampling distribution*.
  - Egal wann wir ein Sample aus dem *general pattern* ziehen

$$F(y_t|\cdot) = F(y_{t+\tau}|\cdot) \longrightarrow E\left[y_t|\cdot\right] = E\left[y_{t+\tau}|\cdot\right] = c, \quad \forall\ t \text{ and for any } \tau \in \mathbb{N}$$

- Die wichtige Implikation: **Stabilität im Zeitablauf** von
  - ***Expected value***
  - ***Covariance*** $cov(y_t, y_{t+\tau})$
    - Spezialfall: *Variance* $cov(y_t, y_t)$ stabil wenn *covariance* $cov(y_t, y_{t+\tau})$ stabil
- ***Non-stationary time series*** sind im Zeitverlauf nicht stabil
  - Das ist ein **gravierendes Problem**
  - *Serial correlation* $cov(y_t, y_{t+\tau}) \neq 0$ ist nicht gleichbedeutend mit **non-stationarity**
    - Solange $cov(y_t, y_{t+\tau})$ über die Zeit konstant!

Non-stationarity: Random Walk

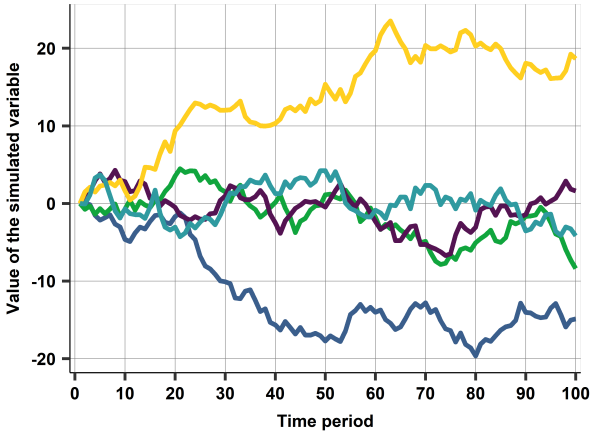
- **Random walk** liegt vor wenn $\rho = 1$ in $y_t = \rho y_{t-1} + \epsilon_t$
  - Wir sprechen auch von *'unit root'* (Einheitswurzel)
- *Time series* Variablen, die einem Random Walk folgen, sind **unvorhersehbar**

$$y_t = y_{t-1} + \epsilon_t$$

- **Konvergieren nicht** zu einem bestimmten Wert oder Trend
  - Anders als bei *serial correlation* mit $\rho < 1$
    - Setzen ihre Reise immer von y_{1-t} fort
    - Nach langer Zeit können sie überall enden
- Die ***variance*** der *smapling distribution* **nimmt** im Zeitablauf **zu**
  - Daher ist eine *random walk* Variable ***non-stationary***

Non-stationarity: Random walk

- 5 simulierter Random Walk-Verläufe
- Jeder Random Walk-Verlauf bewegt sich zufällig umher
- Einige **entfernen sich** im Laufe der Zeit immer weiter **vom Anfangspunkt**



Unit root Test

- Der **Phillips-Perron-Test** basiert auf folgender Idee:

$$y_t = \alpha + \rho y_{t-1} + \epsilon_t$$

  - Dieses Modell stellt einen **Random Walk dar, wenn** $\rho = 1$
  - Wenn $\alpha \neq 0$ liegt ein *'drift'* vor.
    - Es gibt einen Random Walk um eine systematische Bewegung herum.
- Getested wird die Hypothese $H_0 : \rho = 1$ gegen die Alternative $H_A : \rho < 1$.
  - **Wir wollen H_0 ablehnen (kleiner *p-value*)!**
    - `pperron y`
- Wenn der ***p-value* zu groß**, lehnen wir die Nullhypothese nicht ab
  - Typischer weise wenn *p-value* $> 0{,}05$
  - Nicht ausgeschlossen, dass die Zeitreihenvariable einem ***random walk*** folgt

Non-stationarity: Trends

- **Trend Erwartungswert** einer Zeitreihe systematisch verändert
  - Die Zeitreihe ist daher **nicht stationär**
- *First difference* (erste Differenz) gibt die Änderung über die Zeit an:

$$\Delta y_t = y_t - y_{t-1}$$

  - Es gibt positive $E[\Delta y_t] > 0$ und negative $E[\Delta y_t] < 0$ Trends
- Ein Trend ist **linear**, wenn $E[\Delta y_t] = c$ und **exponential**, wenn $E[\Delta \ln(y_t)] = c$
- Auf Trends testen wir mit der Regression $\Delta y_t = \alpha + \varepsilon_t$
  - Ist $\alpha \neq 0$, liegt ein Trend vor

Non-stationarity: Seasonality

- ***Seasonality*** (*Saisonalität*) bedeutet **periodische Variation**
  - Sie folgt den Jahreszeiten, den Tagen der Woche oder den Stunden des Tages
    - *linear*, wenn die saisonalen Unterschiede konstant sind
    - *exponential*, wenn saisonalen Unterschiede in *logs* konstant sind
- ***Non-stationarity***, da $E(Y_t)$, $cov(y_t, y_{t+\tau})$, und womöglich $var(y_t)$ nicht konstant
  - Zeitrehen werden deshalb oft *Seasonally adjusted* ("saisonal bereinigt")
    - Diese saisonale Komponente wird mit Hilfe ökonometrischer Verfahren entfernt
  - Alternativ werden Veränderungen *year-on-year* (von Jahr zu Jahr) berechnet
    - Z.B. Arbeitslosigkeit im Juli diesen Jahres relativ zu Juli letzen Jahres

Eigenschaften von *time series*—Zusammenfassung

- ***Stationary time series***
  - *expected value*, *variance* und *seriel correlation* im Zeitverlauf konstant
- Drei Beispiele für ***non-stationary*** betrachtet:
  - ***Random walk***: Die *variance* nimmt im Laufe der Zeit zu, aber es gibt keinen Trend
  - ***Trend***: Der *expected value* vergrössert oder verkleinert sich im Laufe der Zeit
  - ***Seasonality***: *expected value* schwankt zyklisch
- ***Stationarity* is wichtig**
  - Wenn die Variablen nicht *stationary* sind, erhalten wir irreführende Ergebnisse.

Microsoft and S&P 500 stock prices—data

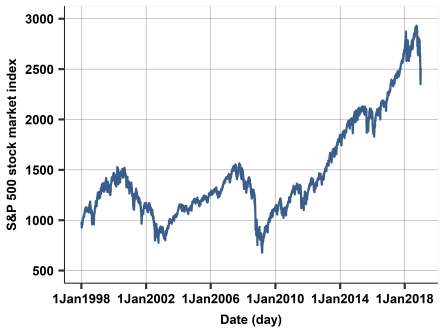
- Täglicher Preis der Microsoft-Aktien und Wert des S&P 500 Aktienmarktindex
- Die Daten umfassen 21 Jahre
  - beginnend am 31. Dezember 1997 und endend am 31. Dezember 2018
- Wir wollen wissen **wie die Microsoft Aktie relativ zum S&P 500 performt**

Q: Schlägt die Microsoft Aktie den S&P 500?

Microsoft and S&P 500 stock prices—ts plot



Microsoft, daily close price



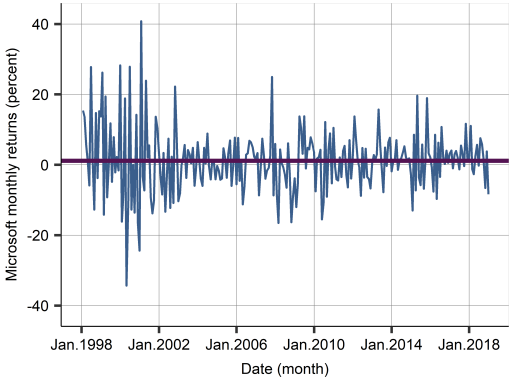
S&P 500 index value, daily close

Q: Welche Zeitreihe ist *stationary*?

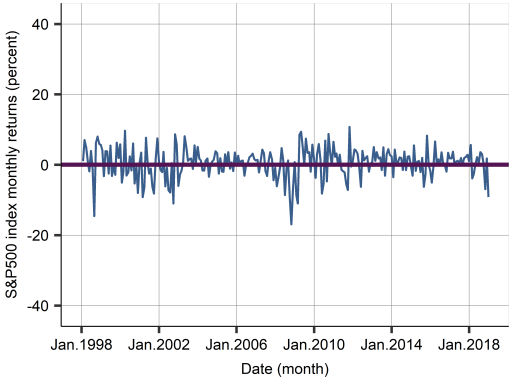
Microsoft and S&P 500 stock prices— decisions

- Wir treffen folgende Entscheidungen hinsichtlich der *frequency*:
  - Wir betrachten den **Schlusskurs am Monatsende** (letzter Werktag)
  - Lücken können somit ignoriert weden (Wochenenden, Feiertage)
- Alle Werte werden beibehalten
  - *extrem values* sind keine Fehler sondern Teil des relevanten Prozesses.
- Die Variablen sind offensichtlich **nicht *stationary***
  - Phillips-Perron-Test: sehr hoher p-Wert
- Wir verwenden *monatliche* ***Renditen***, da ***stationary***
  - Renditen: Prozentsatzänderung der Schlusskurse: $100 \times \frac{y_t - y_{t-1}}{y_{t-1}}$
    - `gen return = 100*(y-l.y)/l.y`
  - Alternative: *log differences* (erste Differenz der Log-Preise)

Microsoft and S&P 500 - index returns (pct)



Microsoft, monthly return (pct)



S&P 500 index value, monthly return (pct)

Returns on a company stock and market returns

- $pctchange(MSFT_t) = \alpha + \beta pctchange(SP500_t) + \varepsilon_t$
  - *Intercept* $\hat{\alpha} = 0.54$:
    - Rendite der Microsoft-Aktie im schnitt 0.54 Prozent höher als S&P500-Index
  - *Slope* $\hat{\beta} = 1.26$, das 95% CI is $[1.06, 1.46]$:
    - Die Rendite der Microsoft-Aktie bewegt sich 1.26 mal so stark wie die des Index
  - R-squared: 0.36
- Robustness checks
  - *First difference* in logs: $\hat{\beta} = 1.24$
  - Tagesrenditen (prozent): $\hat{\beta} = 1.1$
- Schlussfolgerung
  - Microsoft Aktie bietet langfristig eine **höhere Rendite, aber auch mehr Risiko**

Deskriptive Analyse

Time series regressions

- ***Time-series regression***:

$$y_t^E = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + ...$$

- **Interpretation ähnlich** wie in der *cross section*
  - β_0: Wir erwarten, dass $y = \beta_0$, wenn alle erklärenden Variablen null sind.
  - β_1: Wenn x_1 um eine Einheit steigt erwarten wir, dass y um β_1 zunimmt
    - Wenn alle anderen *explanatory variables* gleich bleiben
- Um mit ***non-stationarity*** umzugehen nutzen wir meistens ***first differences***
  - Wir verwenden die Notation Δ, um eine *first difference* zu kennzeichnen, z.B.

$$\Delta y_t = y_t - y_{t-1}$$

  - `gen delta_y = d.y`

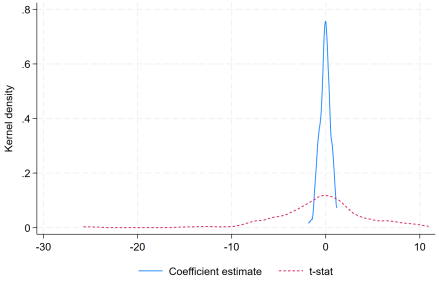
First differences regression

$$\Delta y_t = \alpha + \beta \Delta x_t + \Delta \varepsilon_t$$

- Weil wir Änderungen (über die Zeit) betrachten, sagen wir:
  - α ist die durchschnittliche Veränderung in y, wenn x unverändert bleibt.
  - β zeigt, um wie viel *mehr* sich y verändert, wenn x um eine Einheit zunimmt
    - "mehr", da wir erwarten, dass sich y um α ändert, wenn sich x nicht ändert.
- Wir "müssen" nicht immer y UND x in *first differences* transformieren
  - Wenn wir nur eine Varibale transformieren, ändert sich aber die Interpretation von β!
  - Wir **tranformieren** daher (ausser in Sonderfällen) eigentlich **immer beide**
- Somit bleibt die **Interpretation von β unverändert**
    - `reg d.y d.x`

Random Walk (non-stationarity) in regression

- **Random Walks** stellen ein **gravierendes Problem** dar
  - Es können sich **rein zufällig signifikante Zusammenhänge** ergeben
  - Einfache Simulation ergibt mehr als 50% zuffällig signifikante β
  - ***Spurious correlations***, Korrelationen ohne ökonomische Bedeutung




```
* Start from scratch, GA 2023-10-26
clear
set seed 201806
set obs 100
global sde=1
global ystart=0

gen t=_n
tsset t
* Generate variables
forvalue i=1/100 {
    gen y`i' = $ystart if t==1
    replace y`i' = y`i'[_n-1] + rnormal(0,$sde) if t>1
    }
forvalue i=1/100 {
    gen x`i' = $ystart if t==1
    replace x`i' = x`i'[_n-1] + rnormal(0,$sde) if t>1
    }
* Now regressions
display 0.85^_N^(1/3)
gen b = .
gen t_val = .
forvalue i=1/100 {
    newey  y`i' x`i', lag(4)
    replace b = _b[x`i'] if _n == `i'
    replace t_val = _b[x`i']/_se[x`i'] if _n == `i'
    }
twoway (kdensity b) (kdensity t_val, lpattern(shortdash)) , legend(order(1 "Coefficient estimate" 2 "t-stat") ///
cols(2) pos(6)) ytitle("Kernel density") xtitle("") xsize(7.55) ysize(5) xlabel(-25[2.5]10)
graph export "$output\ch12-figure-1-randomwalks-Stata-MC.png" , replace width(1800) height(1200)
```

First difference & random walk

- *Random walk* gekennzeichnet durch folgenden Prozess:

$$y_t = \alpha + y_{t-1} + \epsilon_t \tag{1}$$

  - wobei wir annehmen, dass ϵ einem ***stationary process*** folgt
- y_t in *first difference*:

$$\Delta y_t = y_t - y_{t-1} \tag{2}$$

- Wenn wir (1) und (2) gleichsetzen, erhalten wir:

$$\Delta y_t = \alpha + \epsilon_t$$

  - Δy_t ist *stationary* wenn ϵ_t *stationary*
- ***First differencing*** **entfernt** ***random walk*****!**

First differences & trends

- Folgender *data generating process* (datengenerierenden Prozess):

$$y_t = c + \alpha t + \beta x_t + \varepsilon_t,$$

  - wobei $cov(t, x_t) \neq 0 =>$ ***omitted variable bias*** wenn nicht berücksichtigt
    - Z.B. unbeobachteter Trend in realem BIP und Preisniveau
  - ε_t ist unproblematisch weil wir $cov(\varepsilon_t, x_t) = 0$ annehmen.
- Die lineare Regression in *first differences* wird zu:

$$\Delta y_t = \alpha + \beta \Delta x_t + \Delta \varepsilon_t$$

  - wobei $t - (t-1) = 1$ und $c_t - c_{t-1} = 0$
- Der **problematische Trend verschwindet** und wir schätzen das wahre β

First differences & seasonality

- Jetzt stellen wir uns folgenden *data generating process* vor:

$$y_t = c + \alpha t + \beta x_t + \sum_{m=2}^{12} \delta_m (D_m \times t) + \varepsilon_t$$

  - wobei m Monate indiziert. D_m ist ein dummy für Monat m. δ_m beschreibt die Differenz in der Veränderung in y über eine Period während Monat m gegenüber Monat 1 (Januar), die *reference cateogry*.

- In *first differences*:

$$\Delta y_t = \alpha + \beta \Delta x_t + \sum_{m=2}^{12} \delta_m D_m + \Delta \varepsilon_t$$

  - Wir haben ein Problem, weil x_t sich in verschiedenen Monaten unterschiedlich verändert: $\mathbb{E}(\Delta x | D_m = 1) - \mathbb{E}(\Delta x | D_m = 0) \neq 0 \Rightarrow$ *omitted variable bias*
  - Wir müssen **Monats-Dummies als *control variables*** hinzufügen.

Standard errors in *time series regressions*

- *Serial correlation* in y, ($Corr[y_t, y_{t-1}] \neq 0$), führt dazu, dass
  - es *serial correlation* in den *residuals* gibt
  - ***heteroscedasticity-robust standard errors* falsch** sind, u.U. sogar sehr falsch
- Verwenden Sie **`Newey-West standard errors`**
  - `neway y x, lag('l')` wobei 'l' der Wert des *lag* ist
  - Faustregel für die Wahl des *lag*: $0.85 \times T^{\frac{1}{3}}$ (Andrews, 1991)
    - Grösseres *lag* grundsätzlich besser
    - Darf relativ zur Länge der *time series*, T, aber auch nicht zu gross sein
  - funktionieren auch bei *heteroscedasticity*
- Man kann auch ***lagged dependent variables*** in die Regression aufzunehmen:

$$y_t = \alpha + \beta x_t + \gamma_1 y_{t-1} + \gamma_2 y_{t-2} \ldots + \varepsilon_t$$

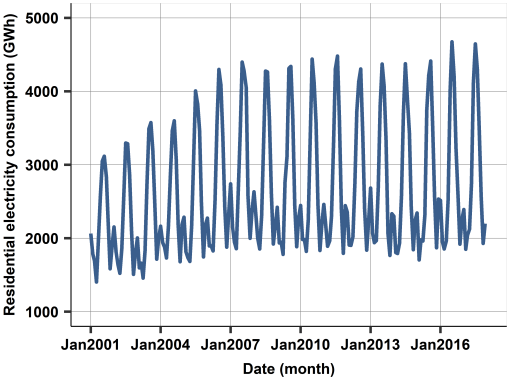
  - `reg y x l1.y l2.y`

Electricity consumption and temperature

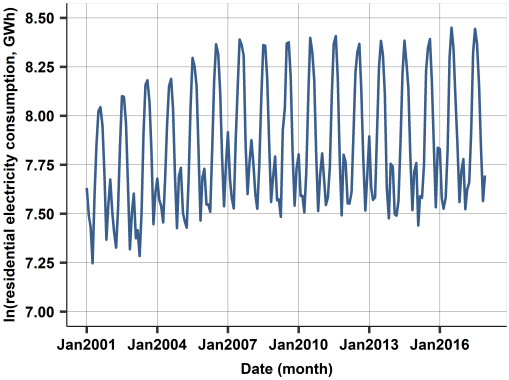
- **Forschungsfrage**
  - Wie wirken sich hohe und niedrige Temperaturen auf den Stromverbrauch aus?
- **Daten**
  - Monatliche Wetter- und Stromverbrauchsdaten für Phoenix, Arizona
    - Beginnend im Januar 2001 und endend im Dezember 2017. Insgesamt 204 Monate.
  - Die Wetterdaten umfassen
    - "cooling degree days": Temperaturen unter 18°, über alle Tage in einem Monat aufaddiert $\Rightarrow$ Transformiert in durchschnittliche **positive Abweichung von 18°**, d.h. 24° *degrees* entsprechen 6° *cooling degrees*
    - "heating degrees days": Temperaturen über 18°, über alle Tage in einem Monat aufaddiert $\Rightarrow$ Transformiert in durchschnittliche **negative Abweichung von 18°**, d.h. 12° *degrees* entsprechen 6° *heating degrees*

Details zu Degree Days

(Log) Electricity consumption

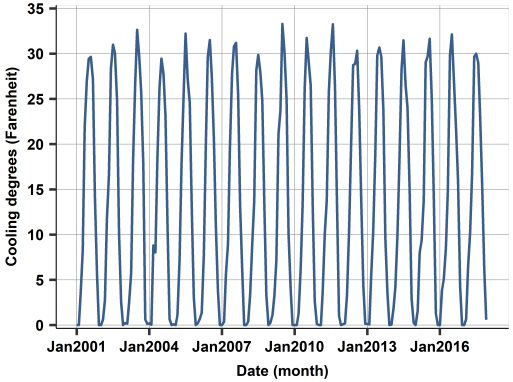


Electricity consumption

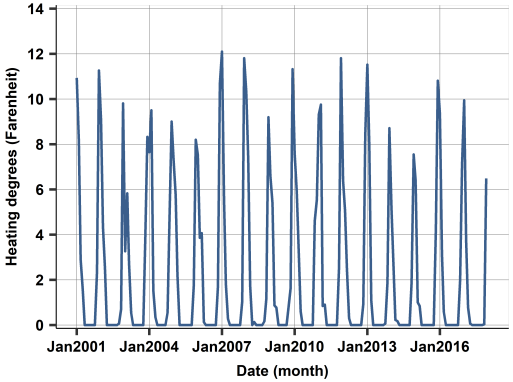


Log of electricity consumption

Average cooling/heating degrees



Average cooling degrees



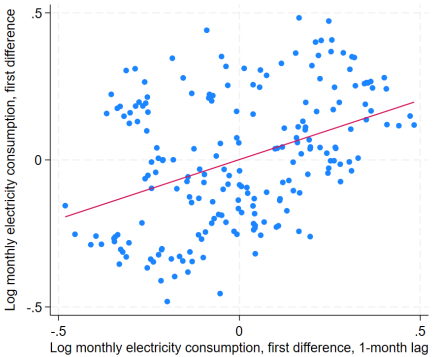
Average heating degrees

Wrangling and modelling decisions

- Wir **berechnen die *cooling degrees* und *heating degrees***
  - *degree days* weniger intuitiv, wir transformieren *degree days* in *degrees*
    - Indem wir duch die Anzahl der Tage pro Monat geteilt haben
- Es gibt einen **exponentiellen Trend im Stromverbrauch –> *log differences***
  - Wir nehmen auch die erste Differenz (FD) der *cooling degrees* und *heating degrees*.
  - Sonst würde sich die Interpretation ändern
  - Wobei *first differences* keinen grossen Unterschied machen
  - Alternative Option
    - *year-on-year changes* betrachten (die Wettervariablen haben keinen starken Trend)
- **Starke *seasonality* –> Monats-Dummies** (Januar als Referenz)
  - Kann vom Wetter kommen, aber auch andere Ursachen haben

Standard errors

- *Serial correlation plot*
  - `twoway (scatter dlnQ l.dlnQ) ///`
    `(lfit dlnQ l.dlnQ)`
- *Serial correlation* scheint vorzuliegen
  - Wir verwenden Newey-West-Standardfehler
  - Lag
    - Faustregel: Lag=0,85*T^(1/3)=5
    - Wir folgen Lehrbuch 12
    - Konservativere *standard errors*



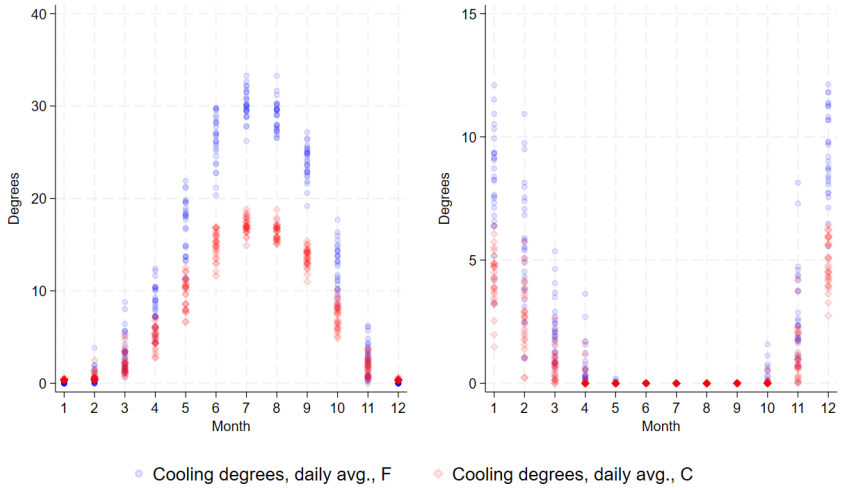
Fahrenheit vs Celsius

- *Data wrangling*, um **intuitive Dimensionen** zu erhalten
  - Wir sind **Grad Celsius** gewohnt
    1. Tranformiere *heating & cooling degrees* in absolute Fahrenheit *degrees*
    2. Transformiere Fahrenheit in Celsius
    3. Berechne *heating & cooling degrees* in Celsius *degrees*

```
* GA code starts In centigrade
    set scheme stcolor
    gen fcdavg_abs = cdavg + 65 // absolute temperature in F
    gen ccdavg_abs = (fcdavg_abs - 32)*5/9 // absolute temperature in C
    gen cdavg_centi = ccdavg_abs - 18
    label var cdavg_centi "Cooling degrees, daily avg., C"
    scatter cdavg  month , mcolor(blue%10)  legend(pos(6) cols(2))
ytitle(Degrees) xtitle(Month) xlabel(1[1]12) name(cooling, replace) ///
    || scatter cdavg_centi  month, msymbol(diamond) mcolor(red%10)

    gen fhdavg_abs = 65 - hdavg // absolute temperature in F
    gen chdavg_abs = (fhdavg_abs - 32)*5/9 // absolute temperature in C
    gen hdavg_centi = max(0,18 - chdavg_abs)
    label var hdavg_centi "Heating degrees, daily avg., C"
    scatter hdavg  month , mcolor(blue%10)  legend(pos(6) cols(2))
ytitle(Degrees) xtitle(Month) xlabel(1[1]12) name(heating, replace) ///
    || scatter hdavg_centi  month, msymbol(diamond) mcolor(red%10)
    grc1leg cooling heating, cols(2) xsize(10) ysize(5)
    graph export "$output\ch12-figure-electricity_F2C.png" , replace
```

Fahrenheit vs. Celsius



Model estimates and interpretation

VARIABLES	(1) dlnQ	(2) dlnQ	(3) dlnQ	(4) dlnQ
ΔCD, F	0.031**	0.017**		
	(0.001)	(0.002)		
ΔHD, F	0.037**	0.014**		
	(0.003)	(0.003)		
ΔCD, C			**0.054****	**0.030****
			(0.001)	(0.004)
ΔHD, C			**0.066****	**0.025****
			(0.006)	(0.006)
Constant	0.001	0.092**	0.001	0.092**
	(0.002)	(0.013)	(0.002)	(0.013)
Month effects	–	Yes	–	Yes
Observations	203	203	203	203

- **Modell (4)**
  - +1 *Cooling Degree*
    - Stromverbrauch **+3.0%**
  - +1 *Heating Degree*
    - Stromverbrauch **+2.5%**
- **Month effects**
  - Reduzieren die geschätzten Temperatureffekte um etwa 50%
  - Saisonale Faktoren führen sonst zu einer Überschätzung der Temperatureffekte
  - Monatsdummies absorbieren aber auch einen Teil der Temperaturvariation

Propagation effect (Ausbreitungseffekt): *Lags*

- Es kann informativ sein, ***lagged independent variables*** zu verwenden
  - x_{t-1} ist das first lag von x_t, der wert der in der vorherigen Periode gemessen wurde
- Betrachten wir nun den folgenden *data generating process*:

$$\Delta y_t = \alpha + \beta_0 \Delta x_t + \beta_1 \Delta x_{t-1} + \beta_2 \Delta x_{t-2} + \varepsilon_t$$

- Änderung in y wird durch eine Änderung in x
  - in der **aktuellen Periode** herbeigeführt $\Rightarrow \beta_0$
  - in der **letzten Periode** herbeigeführt $\Rightarrow \beta_1$
  - in der **vorletzten Periode** herbeigeführt $\Rightarrow \beta_2$
- Demenstsprechend ist der *cumulative effect* (der Gesamteffekt über alle Perioden):

$$\beta_{cumul} = \beta_0 + \beta_1 + \beta_2$$

Den *cumulative effect* direkt schätzen

- Um den *cumulative effect* direkt zu schätzen, transformieren wir die Gleichung
  - Wir erweitern um $\beta_0 \Delta x_{t-2}$ und $\beta_1 \Delta x_{x-2}$ und erhalten
    $\Delta y_t^E = \alpha + \beta_0 \Delta x_t + \beta_1 \Delta x_{t-1} + \beta_0 \Delta x_{t-2} - \beta_0 \Delta x_{t-2} + \beta_1 \Delta x_{t-2} - \beta_1 \Delta x_{t-2} + \beta_2 \Delta x_{t-2}$
  - Jetzt fassen wir die Δx_{t-2} Terme zusammen und vereinfachen den Rest:
    $\Delta y_t^E = \alpha + \beta_0(\Delta x_t - \Delta x_{t-1}) + (\beta_1 - \beta_0)(\Delta x_{t-2} - \Delta x_{t-1}) + (\beta_0 + \beta_1 + \beta_2)\Delta x_{t-2}$
  - **Regression**: $\Delta y_t = \alpha + \beta_{cumul} \Delta x_{t-2} + \delta_0 \Delta(\Delta x_t) + \delta_1 \Delta(\Delta x_{t-1}) + \varepsilon_t$
    - β_{cumul} in dieser Regression entspricht genau $\beta_0 + \beta_1 + \beta_2$ in der vorherigen Regression.
    - Vorteil: Wir bekommen auch ein *estimate* des *standard error*.
- Häufig sinnvoll **beide Ansätze** auszuprobieren.
  - Einfache *lags* geben **intuitive *point estimates*** und wir verstehen die lag-Stuktur
  - Der direkte Test liefert den ***standard error* des *cumulated effect***

Model summary with lags

VARIABLES	(1) $\Delta \ln Q$	VARIABLES	(2) $\Delta \ln Q$
ΔCD	0.020**	ΔCD cumulative coeff	0.027**
	(0.002)		(0.005)
ΔCD 1st lag	0.006**		
	(0.002)		
ΔCD 2nd lag	0.001		
	(0.002)		
ΔHD	0.019**	ΔHD cumulative coeff	0.030**
	(0.003)		(0.007)
ΔHD 1st lag	0.011**		
	(0.003)		
ΔHD 2nd lag	0.000		
	(0.003)		
Observations	201		201
R-squared	0.957		0.957
Month binary variables	Yes		Yes

Newey-West standard errors in parentheses; ** $p < 0.01$, * $p < 0.05$
Source: `arizona-electricity` data.

- **Cumulative effect**
  - Summe der Koeffizienten über alle *lags*
  - Cooling: $0.020 + 0.006 + 0.001 = 0.027$ ✓
  - Heating: $0.019 + 0.011 + 0.000 = 0.030$ ✓
- **Lag-Effekte**
  - Temperatur wirkt auch mit Verzögerung.
  - Mögliche Erklärung:
    - Anpassung der Haushalte
    - Oder ausgelassene korrelierte Faktoren.
- **Fazit**
  - Höhere und niedrigere Temperaturen erhöhen den Stromverbrauch auch unter Berücksichtigung von *seasonality*.

```
newey d.lnQ d.cdavg l.d.cdavg l2.d.cdavg d.hdavg l.d.hdavg l2.d.hdavg i.month, lag(12)
newey d.lnQ l2.d.cdavg d.d.cdavg l.d.d.cdavg l2.d.hdavg d.d.dhdavg l.d.d.hdavg i.month, lag(12)
```

Stata bootcamp

- Überprüfen Sie, ob Ihre Variablen *stationary* sind
  - Visualisieren Sie:
    - ts time
    - tsline y time
  - Untersuchen Sie auf *seriel correlation*
    - scatter y l.y
    - reg y l.y
  - Führen Sie einen unit-root Test durch
    - pperron y
    - pperron x

Stata bootcamp

- Bei *seriel correlation*
  - Newey standard errors (bei Monatsdaten und 1-Jahr lag)
    - gen ly = ln(y)
    - gen lx = ln(x)
    - global lag = 0.85*T^(1/3)
    - newey d.ly d.lx i.month, lag('lag')
  - Lag der *dependent variable*
    - xtreg d.ly d.lx i.month l.d.ly
  - Aequivalent zu
    - gen dlylag = l.dly
    - xtreg dly dlx i.month dlylag

Stata bootcamp

- Scheint ein Trend oder Random Walk vorzuliegen
  - ***first differences*** Δy_t verwenden
    - newey d.y d.x, lag($lag) oder
    - gen dy = d.y
    - gen dx = d.x
    - newey dy dx, lag(`lag')
  - oder ***log differences***
    - gen dly = ln(y)-ln(l.y)
    - gen dlx = ln(x)-ln(l.x)
    - newey dly dlx, lag('lag')
  - Zweimal differenzieren, wenn eine Variable immer noch eine *unit root* aufweist.
    - gen d2ly = d.dly
    - gen d2lx = d.dlx
    - newey d2ly d2lx, lag('lag')

Stata bootcamp

- Wenn die Variable saisonale Schwankungen aufweist (*seasonality*)
  - Saisonale Dummies (z.B. fuer Monate) verwenden
    - newey dly dlx i.month, lag('lag')
  - Oder die gleichen Monate in verschiedenen Jahren zu vergleichen
    - gen dlyYearOnYear = ln(y)-ln(l12y)
    - gen dlxYearOnYear = ln(x)-ln(l12x)
    - newey dlyYearOnYear dlxYearOnYear, lag($lag)

Stata bootcamp

- Um den *cumulative effect* abzuschätzen
  - Lags der *explanatory variables* hinzufügen, um Ausbreitung zu verstehen
  - So viele lags hinzufügen, dass der Effekt erkennbar abgekungen ist.
    - newey d.ly d.lx l.d.lx l2.d.lx i.month , lag('lag')
  - *Cumulative effect* direkt schaetzen, um *standard errors* zu erhalten
  - Über die Perioden schätzen, über die sich die Effekte erkennbar ausbreiten.
    - newey d.ly l2.d.lx d.d.lx l.d.d.lx i.month, lag('lag')

Summary of the process

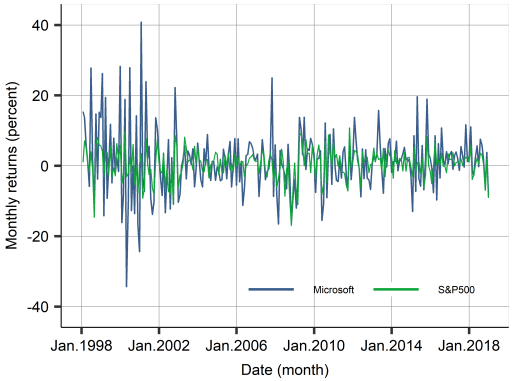
1. Sinnvolle *frequency wählen*; mit Lücken, falls erforderlich.
2. Mit *seriel correlation* umgehen, oft Newey S.E.
3. Zeitreihen plotten. Merkmale und Probleme identifizieren.
4. Trends behandeln, oft indem Variablen transformiert werden (oft: erste Differenz).
5. Mit *seasonality umgehen*, normalerweise durch Einbeziehung von Saisondummies.
6. Den *cumulated effect* verstehen und schätzen.

- ***Log-differences und NW standard errors* funktionieren meistens gut**
- Zeitreihen haben noch sehr viel mehr zu bieten: *Time-series analysis* Vorlesung.
- Diese Schritte sind ein guter Start...

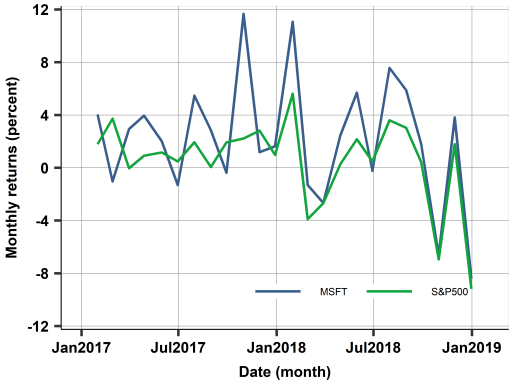
Literatur

- Andrews, Donald W. K. (1991): Heteroskedasticity and Autocorrelation Consistent Covariance Matrix Estimation. Econometrica, 59(3), pp. 817-858. https://doi.org/10.2307/2938229

Microsoft and S&P 500 index returns - comparisons



The entire time series, 1998–2018



2017–18

Returns on a company stock and market returns

- **Positive *correlation***: Der Preis der Microsoft-Aktie tendiert dazu
  - zu steigen, wenn die Marktpreise steigen
  - zu fallen, wenn die Marktpreise fallen.
- **Volatilität des Marktes ist geringer**
  - Besonders deutlich im Zeitraum 2017–18.
- Wir können den Zusammenhang der Renditen nun
  - mit einer Regression schätzen
  - (Variation des *Capital Asset Pricing Model*, CAPM)

Zurück Zur Regression

Electricity consumption and temperature—details

- Die *cooling degree days* messen die durchschnittliche Temperatur innerhalb eines jeden Tages, subtrahieren eine Referenztemperatur (65F oder 18C) und summieren diese täglichen Werte auf.
  - Wenn die durchschnittliche Temperatur an einem Tag beispielsweise 75F (24C) beträgt, beträgt das *cooling degree* 10F (6C).
  - Die entsprechenden Werte für jeden der Tage im Monat werden aufaddiert.
  - Tage, an denen die durchschnittliche Temperatur unter 65F liegt, erhalten den Wert Null.
- Für die *heating degree days* ist es umgekehrt:
  - Null für Tage mit 65F oder wärmer und die Differenz zur Referenztemperatur, wenn sie darunter liegt.
  - Beispiel: Bei 45F (7C) ergeben sich 20F (11C) *heating degrees*.

Zur Fallstudie